MODÈLES GÉNÉRATIFS PROFONDS • SEMAINE 15

Projet final

Quel modèle génératif choisir ?

Analyse du besoin · choix du modèle · preuve de concept · évaluation critique

1 But du projet

Objectif du projet final

L'objectif n'est pas d'implémenter le modèle le plus complexe ni d'obtenir la meilleure performance possible.

Le projet doit montrer que vous êtes capable de :

comprendre un besoin → identifier les contraintes → choisir le bon modèle → justifier ce choix → le vérifier

La compétence finale évaluée est donc la capacité à **choisir et défendre une famille de modèles génératifs en fonction d'un problème donné**.

À retenir

Le projet final est une **synthèse** des compétences acquises de S1 à S14. Il ne s'agit pas d'introduire une nouvelle architecture ni de refaire un gros projet technique. Vous pouvez réutiliser et adapter du code provenant des mini-projets précédents.

2 Jeu de données commun

Jeu de données

Jeu de données conseillé : Fashion-MNIST
Fashion-MNIST contient des images en niveaux de gris de taille 28×28, réparties en 10 catégories de vêtements.

Lien : https://github.com/zalandoresearch/fashion-mnist

Tous les étudiants utilisent le même jeu de données afin que l'évaluation porte sur le **choix du modèle** et non sur les différences entre jeux de données.
Pour limiter le coût, un sous-ensemble de 20 000 à 30 000 images peut être utilisé.

3 Choisir un scénario

Chaque étudiant choisit **un seul scénario**. Le modèle n'est pas imposé : il doit être choisi et justifié.

Scénario A — Génération contrôlée

Une application doit générer un type précis de vêtement à la demande : chaussure, sac, pantalon, etc. On souhaite également disposer d'un espace latent permettant l'interpolation.

Question : quelle famille de modèle est la plus adaptée à ce besoin ?

Scénario B — Vraisemblance calculable

On souhaite générer de nouvelles observations, mais il est également important de pouvoir calculer une vraisemblance explicite ou exacte des observations.

Question : quelle famille de modèle permet le mieux de répondre à cette contrainte ?

Scénario C — Génération rapide

Une application interactive doit produire rapidement de nouvelles images. La qualité visuelle est importante et il n'est pas nécessaire de connaître explicitement $p_\theta(x)$.

Question : quel modèle privilégier si la vitesse d'échantillonnage est une contrainte principale ?

Scénario D — Génération progressive et stable

On privilégie la stabilité de l'apprentissage et une bonne couverture de la distribution. Une génération plus lente est acceptable.

Question : quelle famille correspond le mieux à ce compromis ?

À retenir

Aucun scénario n'impose une réponse unique. Un modèle différent de la solution la plus naturelle peut être retenu s'il répond aux contraintes du scénario, si le choix est techniquement justifié et si cette justification est ensuite vérifiée par une expérience adaptée.

4 Familles de modèles disponibles

L'étudiant doit considérer au minimum trois familles avant de faire son choix.

Famille	Vraisemblance	Vitesse	Contrôle	Point d'attention
Auto-régressif	Exacte	Lente	Possible	Génération séquentielle
VAE / CVAE	Marginale souvent intractable ; apprentissage par ELBO	Rapide	Fort avec condition	Qualité parfois plus lissée
Flot normalisant	Exacte	Rapide ou modérée	Possible	Contraintes d'inversibilité
GAN	Non explicite	Très rapide	Possible	Instabilité / effondrement des modes
Diffusion / DDPM	Objectif de débruitage ; borne ou vraisemblance selon formulation	Lente	Forte avec condition	Échantillonnage itératif

À retenir

Ce tableau fournit des **repères pédagogiques** et non des lois universelles. Le choix doit être argumenté en fonction du scénario donné.

À retenir

Faisabilité du scénario B. Sur Fashion-MNIST, appliquer un flot directement aux pixels discrets demande des précautions supplémentaires (déquantification, architecture inversible et gestion de la dimension). Pour ce projet, un flot peut donc être appliqué à une **représentation continue de faible dimension**, par exemple une projection PCA ou des plongements issus d'un encodeur. Un **modèle auto-régressif simple** est également un choix valide si la vraisemblance exacte sur les pixels est la priorité.

5 Travail demandé

Travail demandé

Le projet comporte cinq étapes obligatoires.

1. **Analyser le besoin.**
   Identifier les contraintes importantes du scénario : génération contrôlée, vraisemblance calculable, vitesse de génération, stabilité, qualité/diversité et espace latent interprétable.
2. **Comparer au moins trois familles.**
   Construire un petit tableau comparatif et expliquer :

   pourquoi choisir X et pourquoi ne pas choisir Y ou Z.

3. **Choisir un seul modèle.**
   Le modèle peut être :

Auto-régressif	CVAE	RealNVP / Flow	GAN	DDPM / Diffusion

4. **Réaliser une preuve de concept simple.**
   Le modèle doit être volontairement petit. Quelques époques ou un sous-ensemble des données suffisent. Le but est de vérifier le raisonnement, pas de rechercher l'état de l'art.
5. **Vérifier le critère qui a motivé le choix.**
   La propriété invoquée pour choisir le modèle doit être mesurée ou observée expérimentalement.

6 Exemples de vérification

Modèle choisi	Raison principale	Ce qu'il faut vérifier
Auto-régressif	Vraisemblance exacte	Calculer la NLL / log-vraisemblance et mesurer le coût de la génération séquentielle.
CVAE	Génération contrôlée	Conditionner sur une classe et vérifier que les images générées correspondent à la classe demandée.
Flot	Vraisemblance calculable	Calculer des log-vraisemblances et vérifier l'inversibilité dans l'espace continu utilisé.
GAN	Échantillonnage rapide	Mesurer le temps de génération et évaluer la diversité par une grille d'échantillons, la distribution des classes prédites par un classificateur de référence, ou une mesure simple de diversité entre images générées.
DDPM	Génération progressive / stabilité	Montrer plusieurs étapes de débruitage et analyser la qualité ainsi que la diversité des échantillons obtenus.

7 Contraintes techniques

— L'entraînement doit pouvoir être réalisé sur un GPU standard ou, à défaut, sur un sous-ensemble raisonnable du jeu de données.

— Les architectures doivent rester pédagogiques : réseaux légers, nombre d'époques limité et images à la résolution de Fashion-MNIST.

— Les modèles pré-entraînés, APIs externes de génération d'images et grands modèles téléchargés ne sont pas autorisés comme **cœur de la preuve de concept**.

— Les bibliothèques standard sont autorisées, à condition que le rapport explique clairement le mécanisme du modèle utilisé.

— La réutilisation de code provenant des mini-projets S1–S14 est autorisée et encouragée si l'étudiant sait expliquer et adapter ce code au scénario choisi.

8 5 éléments à évaluer

Évaluation

1. **Identification correcte des besoins — 20 %.**
2. **Choix et justification du modèle — 30 %.**
   Le choix doit être relié aux concepts du cours :

   vraisemblance, latent, échantillonnage, contrôle, stabilité.
3. **Preuve de concept fonctionnelle — 20 %.**
4. **Évaluation du critère principal — 15 %.**
5. **Analyse critique — 15 %.**

Indicateurs de niveau

— **Excellent :** contraintes correctement hiérarchisées, comparaison nuancée, modèle choisi cohérent et vérification expérimentale directement alignée sur le besoin.

— **Satisfaisant :** modèle fonctionnel et justification correcte, mais comparaison limitée ou évaluation partielle du critère principal.

— **Insuffisant :** modèle entraîné sans justification claire, comparaison absente, ou métriques / résultats sans lien avec le scénario choisi.

9 5 questions finales

5 questions finales

1. Quel est le besoin principal de votre application et pourquoi influence-t-il le choix du modèle ?
2. Pourquoi avez-vous choisi cette famille plutôt qu'au moins deux autres familles étudiées dans le cours ?
3. Votre modèle permet-il de calculer une vraisemblance exacte, utilise-t-il une borne / un objectif probabiliste approché, ou définit-il principalement une procédure d'échantillonnage ?
4. Comment votre modèle génère-t-il concrètement un nouvel échantillon ?
5. Si l'on modifiait une contrainte du problème, par exemple exiger une vraisemblance exacte, une génération beaucoup plus rapide ou davantage de contrôle, changeriez-vous de modèle ? Pourquoi ?

10 Livrables

Livrables

1. un carnet Jupyter reproductible ou un script clairement organisé ;
2. un rapport de **3 pages maximum** ;
3. un tableau comparatif d'au moins trois familles avant le choix final ;
4. quelques résultats expérimentaux : figures, générations ou mesures adaptées au scénario ;
5. les réponses aux cinq questions finales ;

11 Structure suggérée du rapport

1. **Problème et contraintes** — environ un demi-page.
2. **Comparaison des modèles et choix** — environ une page.
3. **Expérience et résultats** — environ une page.
4. **Analyse critique et conclusion** — environ un demi-page.

12 Exemple de raisonnement attendu

Exemple

Besoin : générer une catégorie précise de vêtement et disposer d'un espace latent manipulable.

L'étudiant identifie :

$$\text{contrôle} + \text{latent structuré}.$$

Il compare ensuite plusieurs familles et peut conclure qu'un CVAE constitue un choix naturel.

Il doit alors vérifier expérimentalement que :

$$y = \text{“sac”} \quad \Longrightarrow \quad \text{générations majoritairement cohérentes avec la classe “sac”}.$$

Le projet est évalué sur la cohérence :

$$\boxed{\text{besoin} \rightarrow \text{choix} \rightarrow \text{expérience} \rightarrow \text{conclusion}}$$

13 Synthèse

À retenir

Les mini-projets S1–S14 servent à apprendre **comment fonctionnent** les principales familles, y compris les modèles auto-régressifs, VAE, flots, GAN, EBM, diffusion et approches hybrides. Le projet final S15 vérifie une compétence différente :

$$\boxed{\text{savoir choisir le modèle génératif adapté à un besoin donné}}$$

La qualité du raisonnement, de la justification et de l'analyse compte davantage que la quantité de code.