SEMAINE 2

Discriminatif vs Génératif

$p(y \mid x)$ · $p(x)$ · Explicite · Implicite

VOCABULAIRE DE BASE (À GARDER SOUS LES YEUX)

- **Densité** $p(x)$ **:** fonction qui attribue une « plausibilité » à chaque x (continu).
- **Vraisemblance :** une fois x observé, $p_\theta(x)$ mesure la compatibilité avec θ.
- **Échantillonnage :** produire un nouveau x selon le modèle : $x_{\text{new}} \sim p_\theta(x)$.
- **Latent** z **:** variable intermédiaire (code) utilisée pour générer x.

Note : en continu, $p(x)$ est une densité, pas une probabilité d'un point exact.

FIL CONDUCTEUR DE LA SEMAINE

En S1, nous avons étudié comment un réseau construit une **représentation** interne des données. Cette semaine, nous changeons de point de vue : nous allons demander **quelle distribution le modèle cherche à apprendre**.

La question centrale est donc :

Que modèle-t-on ? $\quad p(y \mid x),\ p(x)$ ou $p(x, y)$

Pour chaque nouveau concept, nous suivrons la même logique : **problème concret** $\rightarrow$ **limite** $\rightarrow$ **solution**.

QUESTION CENTRALE DE LA SEMAINE

Quelle distribution veut-on modéliser : $p(y \mid x)$**,** $p(x)$ **ou** $p(x, y)$ **?**

CONTEXTE : DEUX APPROCHES FONDAMENTALES

En apprentissage automatique, les **modèles génératifs** et les **modèles discriminatifs** représentent deux façons complémentaires d'apprendre à partir des données. Les deux sont essentielles, mais elles visent des objectifs différents : à quel point veut-on **décrire** le monde (la distribution des données) ou simplement **décider** (la classe à prédire) ? Comprendre cette différence est crucial pour choisir la bonne approche selon la tâche (classification, génération, séries temporelles, données manquantes, etc.).

S2 — OBJECTIFS (CE QUE VOUS SAUREZ FAIRE À LA FIN)

1. **Lire une formule** et dire : discriminatif ou génératif.
2. Comprendre ce que signifie **modéliser une distribution** (densité + likelihood + sampling).
3. Distinguer **génération explicite** vs **implicite**.
4. Placer **AR, VAE, Flows, GAN, Diffusion** dans une **taxonomie globale**.
5. Comprendre pourquoi on a besoin de **S3–S4** (MLE, latents, inférence).

Pont vers S3 : si $p_\theta(x)$ est calculable $\Rightarrow$ apprentissage par **MLE**.
Pont vers S4 : si $p(x) = \int p(x|z)p(z)\,dz \Rightarrow$ l'**inférence** sur z devient centrale.

1 Du latent à la probabilité

MISE EN CONTEXTE — DE LA REPRÉSENTATION À LA LOI DES DONNÉES

"En S1, on a vu où vivent les représentations (CNN/RNN/attention) et pourquoi le latent est utile.
Mais pour générer, il manque une pièce : **quelle est la loi des données ?**
Aujourd'hui, on met une boussole probabiliste : **Que modèle-t-on ?**"

TRANSITION S1 → S2 *(problème → échec → solution)*

Problème : produire des x plausibles, pas juste prédire y.
Échec : $x \to z \to y$ ne dit pas comment choisir z sans x.
Solution : apprendre une loi : $p(y|x)$ (décision) vs $p(x)$ (structure du monde).

COMMENT LIRE CES PROBABILITÉS ?

$p(y \mid x)$ **:** connaissant une observation x, quelle est la probabilité de chaque classe y ?
Exemple : connaissant une image, quelle est la probabilité qu'elle représente un chat ?

$p(x)$ **:** comment le modèle décrit-il la distribution des observations x dans le domaine étudié ?
Exemple : quelles images sont plausibles sous le modèle appris ?

$p(x, y)$ **:** distribution jointe des observations et des classes. Elle décrit simultanément quels x sont plausibles et avec quels labels y ils sont associés.

PIÈGE CLASSIQUE

« Un modèle génératif = un modèle qui génère des images » **(faux / incomplet).**
Correct : génératif = **modèle qui définit une distribution** sur x (ou (x, y)).
La génération n'est qu'une **conséquence** : on peut **sampler** de cette distribution.

2 Partie A : Discriminatif vs Génératif

A0 — Les données comme distribution

DU DATASET À LA DISTRIBUTION

Un dataset n'est pas seulement une liste d'exemples : on le considère comme un **échantillon** provenant d'une distribution réelle mais inconnue $p_{\text{data}}(x)$.

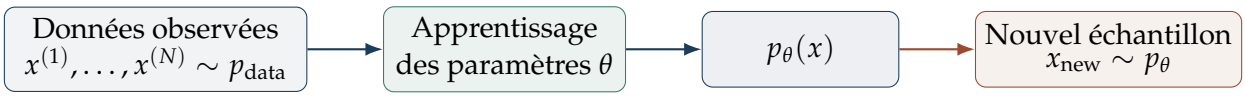
On n'observe donc pas directement p_{data} ; on observe seulement un nombre fini d'exemples :

$$x^{(1)}, \ldots, x^{(N)} \sim p_{\text{data}}.$$

Le modèle introduit alors une distribution paramétrée $p_\theta(x)$ et cherche des paramètres θ tels que :

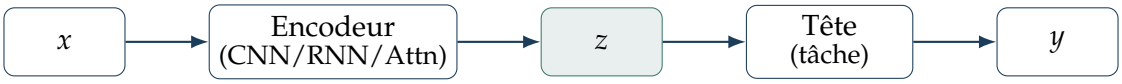
$$p_\theta(x) \approx p_{\text{data}}(x).$$

Lecture : les données observées nous donnent des indices sur la distribution réelle ; l'apprentissage ajuste p_θ pour en capturer les régularités et permettre ensuite de produire de nouveaux exemples plausibles.



Du dataset au modèle : les données observées sont des échantillons de p_{data} ; le modèle apprend p_θ afin de capturer cette distribution et de produire de nouveaux échantillons plausibles.

A1 — De $x \to z \to y$ (S1) à la question probabiliste



S1 : où vit z ? **S2 : que modèle-t-on ?**

A2 — Discriminatif : modéliser $p(y|x)$

- **ANALOGIE — MODÈLE DISCRIMINATIF : « TRACER UNE RÈGLE DE TRI »**

Imaginez maintenant qu'on donne à l'enfant des images mélangées de chats et de chiens, et qu'on lui demande seulement : **« chat ou chien ? »**. Il va apprendre des **indices de décision** (oreilles pointues vs tombantes, museau plus long, etc.) et construire une **règle de séparation** pour classer rapidement chaque image. Mais si on lui demande ensuite : **« dessine un chat »**, ce n'est pas garanti qu'il sache le faire, parce que son apprentissage était centré sur **la frontière de décision** (dire la classe), pas sur la **structure complète** des images. C'est l'idée d'un **modèle discriminatif** : il apprend surtout $p(y \mid x)$ (décider la classe) plutôt que **la distribution de** x (décrire/générer les données).

> DISCRIMINATIF — NOTIONS CLÉS
>
> - Le modèle apprend une loi **conditionnelle** : $\boxed{p_\theta(y|x)}$.
> - C'est un **modèle de décision** : « à partir de x, quel y ? »
> - Le seul conditionnel $p_\theta(y \mid x)$ ne fournit pas une loi sur x permettant d'échantillonner naturellement de nouvelles observations.

- **INTUITION APPROFONDIE**

Un modèle discriminatif vise avant tout à **tracer une frontière de décision** entre les classes : il apprend à prédire directement l'étiquette à partir des caractéristiques observées. Autrement dit, il se concentre sur **la question « Quel y pour ce x ? »** sans chercher à expliquer comment les x ont été générés. Cette focalisation rend souvent les modèles discriminatifs très performants en classification supervisée, car tout l'effort d'apprentissage est orienté vers la décision.

> FORMULE D'ENTRAÎNEMENT TYPIQUE (CLASSIFICATION)
>
> $$\min_\theta \; -\log p_\theta(y|x)$$
>
> **Lecture simple :** on ajuste θ pour que la bonne classe y soit probable *sachant* x.
> **En pratique :** le modèle apprend à reconnaître les indices qui distinguent les classes.

> A2 — POURQUOI ÇA NE GÉNÈRE PAS ? *(problème → échec → solution)*
>
> **Problème :** produire un x plausible (ex. dessiner un chat).
> **Échec :** connaître $p_\theta(y \mid x)$ ne dit pas comment les images x sont distribuées.
> **Solution :** il faut un modèle de $p_\theta(x)$ ou $p_\theta(x, y)$ pour pouvoir générer.
> *Analogie : savoir dire « chat ou chien » n'apprend pas à dessiner un chat.*

• **EXEMPLES COURANTS DE MODÈLES DISCRIMINATIFS**

La **régression logistique** estime directement une probabilité conditionnelle comme $p(y = 1 \mid x)$ pour effectuer une classification binaire. Un **SVM**, de son côté, apprend une frontière de décision séparant les classes.
Idée à retenir : ces modèles cherchent avant tout à prendre une décision à partir de x ; ils ne cherchent pas à modéliser la distribution complète des observations x.

MICRO-QUIZ

Dire si la phrase décrit un modèle discriminatif ou génératif :

- « Je prédis le label à partir des features. » **(Discriminatif)**
- « Je sais produire des exemples et leur donner une probabilité. » **(Génératif)**

A3 — Génératif : modéliser $p(x)$ ou $p(x, y)$

• **ANALOGIE — MODÈLE GÉNÉRATIF : « APPRENDRE À DESSINER »**

Imaginez un enfant à qui l'on montre des centaines de dessins de chats (différentes poses, tailles, couleurs). Petit à petit, il ne mémorise pas chaque image : il apprend des **régularités** (une tête, deux oreilles, des moustaches, une certaine forme du corps). Après un moment, même sans modèle sous les yeux, il peut **dessiner un nouveau chat plausible**. C'est l'idée d'un **modèle génératif** : il apprend **comment les données sont distribuées** (la « forme » générale des exemples) et peut ensuite **générer** de nouveaux exemples qui ressemblent à ceux du dataset.

GÉNÉRATIF — NOTIONS CLÉS

- **Génération pure :** apprendre $p_\theta(x)$.
- **Génération jointe :** apprendre $p_\theta(x, y)$.
- Classification possible (en théorie) via Bayes :

$$p(y|x) = \frac{p(x, y)}{p(x)}.$$

POURQUOI UN MODÈLE GÉNÉRATIF PEUT-IL CLASSIFIER ?

Si le modèle apprend $p(x \mid y)$ et $p(y)$, alors la règle de Bayes donne :

$$p(y \mid x) = \frac{p(x \mid y)\, p(y)}{\sum_k p(x \mid y = k)\, p(y = k)}.$$

Pour choisir la classe la plus probable, le dénominateur est identique pour toutes les classes :

$$\hat{y} = \arg\max_y p(x \mid y)\, p(y).$$

Lecture : le modèle apprend d'abord comment les observations de chaque classe sont distribuées, puis utilise cette information pour classifier.

• **INTUITION**

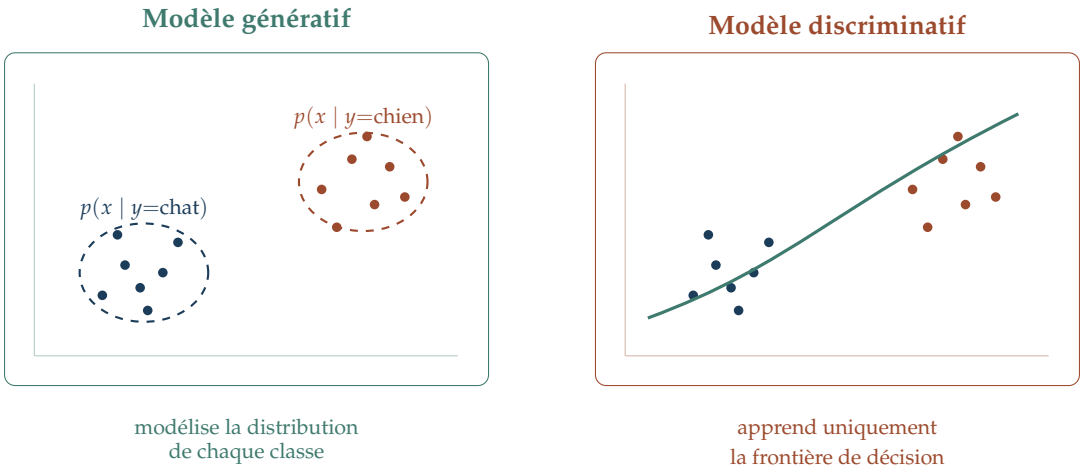
Un modèle génératif cherche à comprendre **comment les données sont produites**. En modélisant $p(x)$, il attribue une probabilité aux exemples possibles et peut **générer** de nouveaux x plausibles par échantillonnage $x \sim p_\theta$. En modélisant $p(x, y)$, il modélise aussi le lien entre données et labels, et peut retrouver un classifieur via Bayes. Cette approche est particulièrement utile lorsque l'on doit **simuler des données**, **gérer des données manquantes**, exploiter des données non étiquetées, ou capturer une

structure complexe du monde.

MESSAGE À RETENIR

Discriminatif : apprendre directement à décider. **Génératif :** apprendre une structure probabiliste permettant de décrire ou de produire les données.

Discriminatif	Génératif
Modélise principalement $p(y \mid x)$	Modélise une distribution sur x, sur (x, y), ou définit un mécanisme qui induit une distribution sur x
Objectif principal : prédiction / décision	Objectif principal : représenter la structure probabiliste des données et permettre la génération / simulation
Critère souvent supervisé (p. ex. entropie croisée)	Critère dépend de la famille : likelihood, ELBO, objectif adversarial, score matching, etc.
$p(y \mid x)$ seul ne fournit pas un modèle de x	Peut permettre d'échantillonner de nouvelles observations x



Comparaison visuelle : à gauche, un modèle génératif modélise la distribution de chaque classe (nuages de points) ; à droite, un modèle discriminatif apprend uniquement la frontière de décision entre les classes.

- **DEUX EXEMPLES POUR SITUER L'IDÉE**

Le **Naïve Bayes** est un modèle génératif classique : il apprend $p(x \mid y)$ et $p(y)$, puis peut classifier via la règle de Bayes.
Les **GAN**, que nous étudierons plus tard, suivent une logique très différente : ils peuvent produire des échantillons réalistes sans fournir directement une densité $p_\theta(x)$ facilement calculable.
Pourquoi ces deux exemples ? Ils montrent déjà qu'il existe plusieurs manières d'être « génératif » ; la taxonomie de la fin de cette semaine servira précisément à les organiser.

A4 — Comment choisir en pratique ? (règle simple)

Le choix dépend de l'objectif. Si vous voulez **prédire une étiquette rapidement et avec une forte précision** en supervision classique, un modèle discriminatif est souvent un excellent choix. Si vous devez **générer/simuler des données**, **modéliser une structure de données** (y compris non étiquetées) ou exploiter une logique probabiliste riche (incertitude, données manquantes, modèles séquentiels), un modèle génératif devient plus pertinent.

MINI-INTERACTION

Question : ce modèle est-il discriminatif ou génératif ?

$$p_\theta(\text{spam} \mid \text{email})$$

Attendu : discriminatif.

MINI-INTERACTION

Question : ce modèle est-il discriminatif ou génératif ?

$$p_\theta(x)$$

Attendu : génératif.

3 Interlude essentiel : modéliser une distribution

Avant de distinguer les modèles explicites et implicites, il faut clarifier trois mots qui reviendront souvent dans le cours : **densité**, **vraisemblance** et **échantillonnage**.

DISTRIBUTION, DENSITÉ, VRAISEMBLANCE ET SAMPLING

- Pour une variable **discrète**, $p(x)$ représente une masse de probabilité.
- Pour une variable **continue**, $p(x)$ désigne généralement une **densité**. La probabilité d'un point exact est alors nulle ; les probabilités concernent des intervalles ou des régions.
- **Vraisemblance (likelihood) :** une fois l'observation x fixée, $p_\theta(x)$ nous indique à quel point les paramètres θ rendent cette observation compatible avec le modèle. La S3 expliquera précisément comment utiliser cette quantité pour apprendre θ.
- **Échantillonnage (sampling) :** produire une nouvelle observation selon le modèle :

$$x_{\text{new}} \sim p_\theta(x).$$

EXEMPLE 1D — UNE GAUSSIENNE

Supposons que des tailles soient décrites par une loi normale :

$$p_\theta(x) = \mathcal{N}(x; \mu, \sigma^2).$$

Ici, $\theta = (\mu, \sigma)$ représente les paramètres du modèle.
Modéliser signifie ajuster μ et σ pour que la distribution soit compatible avec les tailles observées.
Générer signifie ensuite tirer une nouvelle valeur :

$$x_{\text{new}} \sim \mathcal{N}(\mu, \sigma^2).$$

Nous verrons en S3 comment la **vraisemblance** permet précisément d'estimer les paramètres θ à partir des données.

• DU CONCEPT AU CODE — ÉVALUER UNE DENSITÉ ET ÉCHANTILLONNER

Le fragment suivant ne constitue pas un exercice de programmation. Il montre simplement comment les deux opérations vues ci-dessus apparaissent dans une bibliothèque de calcul probabiliste.

```
import torch
from torch.distributions import Normal
```

```
mu, sigma = torch.tensor(170.0), torch.tensor(8.0)
dist = Normal(mu, sigma)

log_density = dist.log_prob(torch.tensor(175.0))
x_new = dist.sample()
```

À observer : `log_prob` évalue la **log-densité** attribuée à une valeur observée, tandis que `sample()` produit une **nouvelle observation** selon le modèle. Dans le cas continu, il s'agit bien d'une densité et non de la probabilité d'un point exact.

PIÈGE : « JE PEUX GÉNÉRER » $\neq$ « JE PEUX CALCULER LA DENSITÉ »

Un modèle peut disposer d'un mécanisme permettant de produire des échantillons sans fournir une formule exploitable pour calculer $p_\theta(x)$ en chaque point.
Cette distinction conduit directement aux deux grandes notions de la section suivante : **modèles explicites** et **modèles implicites**.

4 Partie B : Génération explicite vs implicite

Attention : explicite vs implicite concerne uniquement les modèles génératifs.

B1 — Problème : comment sait-on qu'un modèle de $p(x)$ est « bon » ?

B1 — ÉVALUER UN MODÈLE GÉNÉRATIF *(problème → échec → solution)*

Problème : comparer des modèles.
Échec : jugement visuel subjectif.
Solution : si $p_\theta(x)$ est calculable $\Rightarrow$ critère clair (likelihood) ; sinon, on passe par d'autres signaux.

B2 — Explicite : likelihood calculable

EXPLICITE — NOTIONS CLÉS (REFORMULÉ)

- Le modèle spécifie explicitement une distribution ou une densité probabiliste sur x.
- **Deux cas :**
  - **Likelihood exacte :** on peut calculer $p_\theta(x)$ pour tout x (ex. AR, Flows).
  - **Likelihood approximée :** on utilise une borne ou une approximation (ex. VAE avec ELBO).
- **Pourquoi c'est utile :** si on peut calculer $p_\theta(x)$, on peut apprendre par MLE (S3).
- **Slogan : Explicite = on sait (au moins approximativement) calculer** $p_\theta(x)$.
- Exemples pour situer : **AR**, **Flows**, **VAE**; les modèles de diffusion / score seront présentés séparément car leur position dans une taxonomie simple demande davantage de nuance.

MOT RENCONTRÉ EN AVANCE : ELBO

ELBO est une borne calculable liée à la vraisemblance, utilisée notamment pour entraîner les VAE lorsque $p_\theta(x)$ n'est pas directement exploitable sous une forme simple.
À ce stade, vous n'avez pas à savoir la dériver ni la calculer : elle sera expliquée en détail en **S7**. Ici, retenez seulement que certaines familles probabilistes utilisent une **borne** plutôt qu'une vraisemblance exacte.

B3 — Implicite : sample oui, likelihood non

IMPLICITE — NOTIONS CLÉS (REFORMULÉ)

- Le modèle définit surtout un **mécanisme de génération** qui induit une distribution sur x, sans fournir une densité $p_\theta(x)$ directement calculable.
- Exemple typique :
$$z \sim p(z), \qquad x = G_\theta(z).$$
Ici, la lettre z a un rôle plus précis qu'en S1 : elle représente une **variable latente aléatoire** tirée selon une loi $p(z)$, puis transformée par le générateur. Les modèles à variables latentes seront étudiés plus en détail en S4 puis en S7.
- **Conséquence :** on sait sampler ($x = G_\theta(z)$), mais on ne sait pas calculer $p_\theta(x)$.
Exemple : un GAN peut produire des images réalistes, mais ne peut pas dire « quelle est la probabilité de cette image ».
- **Slogan : Implicite = sample oui, likelihood non.**
- Exemple phare : **GAN**.

• DU CONCEPT AU CODE — GÉNÉRATION IMPLICITE EN QUELQUES LIGNES

Dans un modèle implicite, on sait produire un échantillon en passant d'un bruit latent z à une sortie x, même si l'on ne dispose pas d'une formule simple pour calculer $p_\theta(x)$.

```
latent_dim = 64
z = torch.randn(1, latent_dim) # z ~ N(0, I)
x_new = generator(z) # x = G_theta(z)
```

À observer : le code montre directement le mécanisme $z \sim p(z) \to x = G_\theta(z)$. On peut générer `x_new`, mais ce fragment ne fournit aucune commande permettant de calculer directement une densité $p_\theta(x_{\text{new}})$.

Type	Likelihood $p_\theta(x)$	Entraînement (idée)
Explicite	Exacte ou traitée via une formulation probabiliste / borne, selon la famille	MLE / ELBO / objectifs probabilistes associés
Implicite	Non disponible directement	Adversarial / divergences / matching de moments

MESSAGE-CLÉ (ORGANISATION DU COURS)

Le semestre se déplie ainsi :

Est-ce qu'on peut calculer $p_\theta(x)$?

5 Partie C : Taxonomie globale des DGMs (vue d'ensemble)

C0 — Objectif : ranger les familles avant de les détailler

C0 — POURQUOI UNE TAXONOMIE ? *(problème → échec → solution)*

Problème : beaucoup de familles, on s'y perd.
Échec : apprendre par liste = pas de structure.
Solution : 3 axes : (1) structure probabiliste, (2) explicite/implicite, (3) objectif d'apprentissage.

C1 — Axe 1 : structure probabiliste (deux mécanismes importants)

AXE 1 — DEUX MÉCANISMES QUE NOUS ÉTUDIERONS D'ABORD

- **(i) Factorisation séquentielle (autoregressif) :**

$$p(x) = \prod_{i=1}^{D} p(x_i \mid x_{<i}).$$

- **(ii) Variables latentes :**

$$p(x) = \int p(x|z)\, p(z)\, dz.$$

NOTE DE LECTURE : DEUX MÉCANISMES FONDAMENTAUX

Ces deux mécanismes (AR et latent) sont les **briques de base** que nous étudierons en premier.
AR : je construis x **pas à pas** (comme écrire un texte mot par mot).
Latent : je tire un code z puis je **décode** en x (comme decoder un message compressé).
D'autres mécanismes existent (Flows, Diffusion, etc.) et seront vus plus tard.

CETTE LISTE N'EST PAS EXHAUSTIVE

Les modèles autoregressifs et les modèles à variables latentes sont deux mécanismes fondamentaux, mais ils ne couvrent pas toutes les constructions génératives. Les **flows**, les modèles à énergie, ainsi que les modèles de **diffusion / score** introduisent d'autres mécanismes que nous étudierons plus tard.

LECTURE INTUITIVE

AR : je construis x **pas à pas**.
Latent : je tire un code z puis je **décode** en x.

C2 — Axe 2 : densité explicite vs implicite

AXE 2 (RAPPEL)

Explicite : une distribution / densité est spécifiée explicitement ; sa vraisemblance est exacte ou traitée via une formulation probabiliste, selon la famille. **Implicite :** sampling possible, densité $p_\theta(x)$ non disponible directement.

C3 — Axe 3 : objectif d'apprentissage (1 ligne par famille)

Ce tableau est une **carte du semestre**, pas une liste de formules à mémoriser aujourd'hui.
L'objectif est seulement de reconnaître les grandes familles et de savoir **où elles se situent**.
Les notions techniques comme ELBO, Jacobien ou score matching seront expliquées dans leurs semaines respectives.

Famille	Type	Objectif (idée intuitive)
Autoregressif (AR)	Explicite	Prédire pas à pas (MLE via règle de chaîne)
VAE	Explicite (approx.)	Reconstruire + régulariser le latent (ELBO, S7)
Flows	Explicite (exact)	Déformer une distribution simple (Jacobian, S8)
GAN	Implicite	Tromper un discriminateur (adversarial, S10)
Diffusion	Score-based / probabiliste	Débruiter progressivement (score matching, S11–S12)

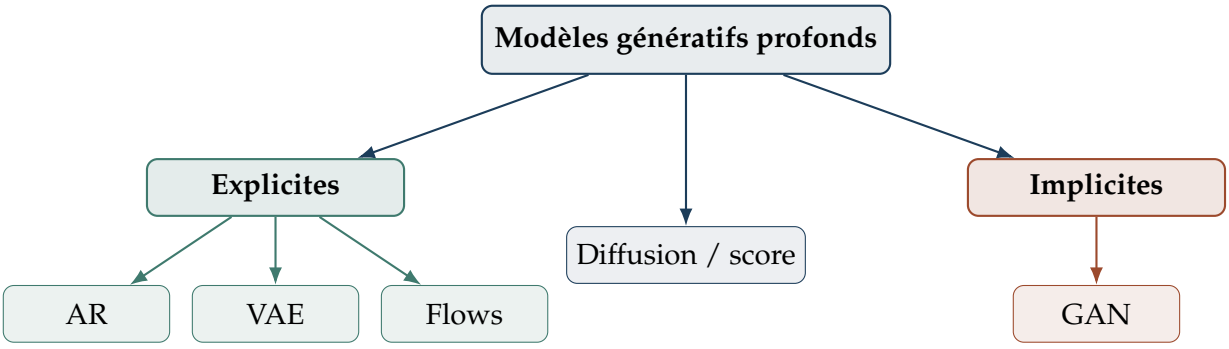
COMMENT UTILISER CE TABLEAU ?

Ce tableau est une **carte du semestre**, pas une liste de formules à mémoriser aujourd'hui.
À retenir : chaque famille a une **idée centrale** (prédire pas à pas, reconstruire, tromper, débruiter, etc.).
Les détails techniques (ELBO, Jacobien, score matching) seront expliqués dans leurs semaines respectives.

TAXONOMIE PÉDAGOGIQUE, PAS FRONTIÈRE ABSOLUE

Les catégories de cette séance servent de **carte conceptuelle**. Certaines familles modernes se situent à l'interface de plusieurs catégories. Par exemple, le VAE définit un modèle probabiliste explicite mais optimise généralement une borne ELBO ; les modèles de diffusion / score disposent de formulations probabilistes riches sans se réduire au cas simple « likelihood directement calculée ». Nous préciserons ces nuances dans les semaines consacrées à chaque famille.

Carte mentale de synthèse



Chaque module ouvre une branche.

6 Synthèse de la semaine 2

• SYNTHÈSE

Les modèles discriminatifs sont conçus pour **distinguer** les classes en apprenant $p(y|x)$ et une frontière de décision. Les modèles génératifs cherchent à **décrire** la distribution (souvent $p(x)$ ou $p(x, y)$), ce qui ouvre la voie à la génération de nouvelles données, à la simulation et à une gestion probabiliste plus riche. Cette leçon fixe la « carte » : $p(y|x)$ vs $p(x)$, puis explicite vs implicite.

TRANSITION VERS S3–S4

"Aujourd'hui, on a fixé la carte : discriminatif $p(y|x)$ vs génératif $p(x)$, et explicite vs implicite.
S3 : on apprend l'outil standard des modèles explicites : **maximum de vraisemblance** + **factorisation**.
S4 : on introduit les **variables latentes** : apprendre $p(x)$ devient un problème d'**inférence**."

TRANSITION VERS S3 (1 FORMULE)

Nous savons maintenant **ce que** peut représenter $p_\theta(x)$. La question suivante est : **comment ajuster les paramètres θ à partir des données ?**
Si $p_\theta(x)$ est calculable, une réponse fondamentale consiste à apprendre par :

$$\boxed{\max_\theta \sum_n \log p_\theta(x^{(n)})}$$

CHECKLIST DE FIN DE SEMAINE (AUTO-ÉVALUATION)

À la fin de cette semaine, vous devriez pouvoir :

- Dire si un modèle est discriminatif ou génératif à partir de sa formule.
- Expliquer la différence entre explicite et implicite avec un exemple.
- Citer un exemple de modèle pour chaque famille (AR, VAE, Flow, GAN, Diffusion).
- Comprendre pourquoi on a besoin de S3 (MLE) et S4 (inférence).

Si une case n'est pas claire, relisez les encadrés correspondants.