SEMAINE 3

Maximum de vraisemblance & Factorisation de densité

Vraisemblance · NLL · Règle de la chaîne · MLE

S3 — OBJECTIFS (CE QUE VOUS SAUREZ FAIRE À LA FIN)

- Expliquer la différence **probabilité** vs **vraisemblance**.
- Écrire une **vraisemblance** $L(\theta)$ et une **log-vraisemblance** $\ell(\theta)$.
- Comprendre pourquoi on minimise la **NLL** en machine learning.
- Dériver une MLE sur un cas simple (Bernoulli).
- Expliquer la **malédiction de la dimension**.
- Factoriser une densité jointe $p(x)$ via la **règle de la chaîne** et comprendre l'idée auto-régressive.

PRÉ-REQUIS — CE QU'IL FAUT MAÎTRISER POUR SUIVRE SANS BLOCAGE

- **Logarithme :** $\log(ab) = \log a + \log b$ (transforme un produit en somme).
  Aussi : si $a > b > 0$, alors $\log a > \log b$ (**fonction monotone**).
- **Argmax / Argmin :** $\arg\max_\theta f(\theta)$ est la valeur de θ qui **maximise** f, et $\arg\min_\theta f(\theta)$ celle qui **minimise** f.
  Mini-exemple : si $f(\theta)$ est maximal en $\theta = 2$, alors $\arg\max_\theta f(\theta) = 2$.
- **Dérivée (idée) :** un maximum/minimum se trouve souvent là où $f'(\theta) = 0$.
  On confirme le **maximum** si $f''(\theta) < 0$ et le **minimum** si $f''(\theta) > 0$ (quand c'est applicable).

1 Fil conducteur : de S1/S2 à S3

RAPPEL EXPRESS (S1 → S2 → S3)

- **S1** : apprendre des **représentations** (features, embeddings) avec NN/CNN/RNN/attention.
- **S2** : distinguer **discriminatif** ($p(y|x)$) et **génératif** ($p(x)$ ou $p(x, y)$).
- **S3** : apprendre réellement un **modèle génératif** :

Comment estimer $p_\theta(x)$ à partir des données ?

QUESTION CENTRALE DE LA SEMAINE

Comment apprendre une distribution $p_\theta(x)$ à partir des données observées ?

Idée clé : *apprendre un modèle génératif = apprendre une densité $p_\theta(x)$ qui explique les données.*

2 Notations

NOTATIONS UTILISÉES

- $D = \{x^{(1)}, \ldots, x^{(m)}\}$: dataset d'entraînement de taille m (**donc** $|D| = m$).
- $x^{(i)}$: la i-ème observation (ex : une image, un texte, un vecteur).
- $p_{\text{data}}(x)$: distribution réelle (inconnue) qui génère les données.
- $p_\theta(x)$: modèle probabiliste paramétré par θ (poids d'un réseau, paramètres d'une loi, etc.).

- Hypothèse **iid** : les $x^{(i)}$ sont **indépendants** et **identiquement distribués**.
  Lecture : indépendant $\Rightarrow$ produit ; identiquement distribué $\Rightarrow$ même $p_\theta(\cdot)$ pour tous les exemples.

3 Probabilité vs densité (discret vs continu)

POURQUOI ON ÉCRIT PARFOIS « PROBABILITÉ » ET PARFOIS « DENSITÉ » ?

- **Cas discret** (ex : pile/face, classe 0/1) : $p(X = x)$ est directement une **probabilité**.
  Elle vérifie :
$$0 \leq p(X = x) \leq 1, \qquad \sum_x p(X = x) = 1.$$

- **Cas continu** (ex : taille, température) : on travaille avec une **densité** $f(x)$.
  Une densité n'est pas elle-même une probabilité ponctuelle et peut même être supérieure à 1.
  La probabilité d'observer une valeur dans un intervalle se calcule par l'aire sous la courbe :
$$P(a \leq X \leq b) = \int_a^b f(x)\,dx, \qquad \int_{-\infty}^{+\infty} f(x)\,dx = 1.$$

  Pour une variable continue, la probabilité d'obtenir exactement une valeur précise est nulle :
$$P(X = x) = 0.$$

INTUITION À RETENIR

Discret : une valeur précise peut recevoir directement une probabilité. **Continu :** la probabilité vient de l'**aire sous la densité** sur un intervalle.

$$\boxed{\text{Discret : } P(X = x) \qquad \text{vs} \qquad \text{Continu : } P(a \leq X \leq b) = \int_a^b f(x)\,dx}$$

CONVENTION DE NOTATION (TRÈS IMPORTANTE)

Dans tout le cours, on utilisera la notation $p_\theta(x)$ aussi bien pour une **masse de probabilité** dans le cas discret que pour une **densité** dans le cas continu.

Dans les deux cas, le principe du maximum de vraisemblance reste le même : pour des données observées, on cherche les paramètres θ qui leur attribuent une vraisemblance élevée.

On travaillera généralement avec la log-vraisemblance :
$$\log p_\theta(x).$$

Ainsi, selon le contexte, cette quantité désigne soit une **log-probabilité**, soit une **log-densité**.

4 Objectif global : apprendre une densité

On observe :
$$D = \{x^{(1)}, x^{(2)}, \ldots, x^{(m)}\},$$
où les observations sont supposées provenir d'une distribution réelle mais inconnue $p_{\text{data}}(x)$.

Autrement dit, on ne connaît pas directement p_{data} : on ne dispose que d'un échantillon fini de

cette distribution.

Objectif : apprendre un modèle paramétré $p_\theta(x)$ tel que

$$p_\theta(x) \approx p_{\text{data}}(x).$$

POURQUOI APPRENDRE $p_\theta(x)$ EST UTILE ?

- **Génération :** tirer $x_{\text{new}} \sim p_\theta(x)$ pour produire de nouvelles observations plausibles.
- **Détection d'anomalies :** une très faible compatibilité avec le modèle peut servir de signal d'anomalie, avec prudence en grande dimension.
- **Compréhension de la structure :** le modèle cherche à capturer les régularités récurrentes des données.

5 Probabilité vs vraisemblance : la confusion la plus fréquente

DEUX POINTS DE VUE SUR LA MÊME EXPRESSION $p(x|\theta)$

- **Probabilité (ou densité)** : θ est fixé, x varie.
  Question : « si le modèle est θ, quels x sont probables ? »
- **Vraisemblance** : x est fixé (observé), θ varie.
  Question : « quel θ explique le mieux les données observées ? »

ERREUR FRÉQUENTE : « LA PROBABILITÉ DES PARAMÈTRES »

Beaucoup d'étudiants disent : « je calcule la probabilité des paramètres ».
Non : on ne calcule pas $p(\theta)$ ici ; on évalue la **plausibilité** de θ via $L(\theta) = p(x|\theta)$.

6 MLE : définition et intuition

6.1 La vraisemblance $L(\theta)$

Sous hypothèse iid :

$$L(\theta) = p_\theta(x^{(1)}, \ldots, x^{(m)}) = \prod_{i=1}^{m} p_\theta(x^{(i)}).$$

Important : $L(\theta)$ n'est pas une probabilité sur θ. Les données sont considérées comme fixées ; c'est θ qui varie. Autrement dit, $L(\theta)$ sert à **comparer des valeurs de** θ : elle n'est pas construite comme une distribution normalisée sur les paramètres.

- $p_\theta(x^{(i)})$ = probabilité (cas discret) **ou** densité (cas continu) attribuée par le modèle à l'exemple i.
- Le produit $\prod$ vient de l'indépendance : la probabilité jointe des observations indépendantes est le produit des termes individuels.
- Si un exemple est jugé très improbable par le modèle ($p_\theta(x^{(i)})$ proche de 0), alors la vraisemblance totale diminue fortement.

POURQUOI LE PRODUIT ? (PREUVE EN 2 LIGNES)

Pour deux observations indépendantes :

$$p(a, b) = p(a)\, p(b).$$

En répétant ce raisonnement pour m observations indépendantes :

$$p(x^{(1)}, \ldots, x^{(m)}) = \prod_{i=1}^{m} p(x^{(i)}).$$

REMARQUE IMPORTANTE SUR L'HYPOTHÈSE IID

Sous l'hypothèse iid, les observations du dataset sont indépendantes, ce qui permet d'écrire :

$$p_\theta(x^{(1)}, \ldots, x^{(m)}) = \prod_{i=1}^{m} p_\theta(x^{(i)}).$$

Si les observations ne sont pas indépendantes (par exemple dans une série temporelle), il faut modéliser explicitement leur dépendance :

$$p_\theta(x^{(1)}, \ldots, x^{(m)}) = \prod_{i=1}^{m} p_\theta\big(x^{(i)} \mid x^{(1)}, \ldots, x^{(i-1)}\big).$$

Plus loin, nous utiliserons la même règle de chaîne pour factoriser les **composantes d'une observation** $x = (x_1, \ldots, x_n)$ dans les modèles auto-régressifs.

6.2 Objectif MLE

Le maximum de vraisemblance cherche les paramètres qui rendent les données observées aussi vraisemblables que possible :

$$\theta^\star = \arg\max_\theta L(\theta) = \arg\max_\theta \prod_{i=1}^{m} p_\theta(x^{(i)}).$$

INTUITION

La MLE choisit les paramètres θ qui rendent **le dataset observé aussi vraisemblable que possible** dans la famille de modèles considérée.

6.3 Pourquoi passer au log ?

On définit la log-vraisemblance :

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^{m} \log p_\theta(x^{(i)}).$$

Chaque observation contribue maintenant par un **terme additif** à la fonction objectif.

Pourquoi utiliser le logarithme ?

- **Produit $\rightarrow$ somme :**
$$\log(ab) = \log a + \log b.$$
Les calculs et l'optimisation deviennent plus simples.
- **Stabilité numérique :** multiplier de nombreuses petites valeurs peut conduire à un **underflow**.

- **Même optimum :** le logarithme est une fonction strictement croissante. Ainsi :

$$\arg\max_\theta L(\theta) = \arg\max_\theta \ell(\theta).$$

SOUS-FLUX NUMÉRIQUE (*UNDERFLOW*)

En machine, le produit d'un grand nombre de valeurs très petites peut devenir si petit qu'il est numériquement arrondi à 0.

Travailler avec les logarithmes permet d'éviter ce problème en transformant le produit en somme.

6.4 NLL : la forme utilisée en machine learning

Plutôt que de maximiser la log-vraisemblance, on minimise généralement son opposé :

$$\mathcal{L}(\theta) = -\ell(\theta) = -\sum_{i=1}^{m} \log p_\theta(x^{(i)}).$$

Cette quantité est appelée **Negative Log-Likelihood** (**NLL**), ou **log-vraisemblance négative**. Ainsi :

$$\arg\max_\theta \ell(\theta) = \arg\min_\theta \big[-\ell(\theta) \big].$$

Apprendre par maximum de vraisemblance

$$\Longleftrightarrow$$

minimiser la NLL.

POURQUOI MINIMISE-T-ON PLUTÔT QUE MAXIMISER ?

En machine learning, les fonctions objectif sont généralement écrites sous forme de **loss à minimiser**.

Exemples concrets :

- PyTorch : `nn.NLLLoss()`, `nn.CrossEntropyLoss()`
- TensorFlow : `tf.keras.losses.NegativeLogLikelihood()`

On transforme donc naturellement :

$$\max_\theta \ell(\theta) \qquad \Longleftrightarrow \qquad \min_\theta -\ell(\theta).$$

Des optimiseurs comme SGD ou Adam peuvent alors être utilisés pour réduire cette fonction de perte.

AUTO-VÉRIFICATION

Si le modèle attribue une très faible probabilité ou densité à une observation, c'est-à-dire

$$p_\theta(x) \approx 0,$$

que devient

$$-\log p_\theta(x) \ ?$$

Réponse attendue : la valeur devient **très grande**. L'observation est donc fortement pénalisée par la NLL.

RÉSUMÉ DE LA DÉMARCHE MLE

$$\boxed{p_\theta(x) \longrightarrow L(\theta) \longrightarrow \ell(\theta) \longrightarrow \text{NLL} \longrightarrow \theta^\star}$$

Idée centrale : on ajuste les paramètres du modèle pour que les observations du dataset soient aussi vraisemblables que possible dans la famille de modèles choisie.

DU CONCEPT AU CODE — LOG-VRAISEMBLANCE ET NLL

La relation mathématique

$$\mathcal{L}(\theta) = -\sum_i \log p_\theta(x^{(i)})$$

se traduit directement par quelques opérations simples :

```
log_likelihood = torch.log(p_theta_x).sum()
nll = -log_likelihood
```

À observer : le code ne change pas le principe mathématique. On additionne les log-probabilités (ou log-densités), puis on change le signe pour obtenir une fonction de perte à minimiser.

7 Approfondissement : interprétation via KL

COMMENT LIRE CETTE SECTION ?

Cette section est **optionnelle** pour une première lecture.
À retenir absolument : MLE = maximiser la log-vraisemblance des données.
Pour aller plus loin : la KL montre *pourquoi* ce critère est naturel.
Si vous êtes à l'aise avec les espérances et les divergences, lisez-la ; sinon, passez directement à l'exemple Bernoulli.

Cette section donne une justification théorique du MLE. Elle est utile pour comprendre *pourquoi* le critère de vraisemblance est naturel, mais l'idée principale à retenir reste la chaîne : données → log-vraisemblance → optimisation.

La divergence de Kullback–Leibler compare la distribution réelle $p_{\text{data}}(x)$ au modèle $p_\theta(x)$. Elle vérifie $D_{\text{KL}} \geq 0$ et elle est **asymétrique** : en général,

$$D_{\text{KL}}(p \,\|\, q) \neq D_{\text{KL}}(q \,\|\, p).$$

Ici, on l'utilise uniquement pour montrer que rapprocher p_θ de p_{data} conduit au MLE.

AVANT LA FORMULE : QUE SIGNIFIE $\mathbb{E}$?

$\mathbb{E}_{p_{\text{data}}}[g(x)]$ désigne la **moyenne de** $g(x)$ **lorsque** x **suit la distribution des données**. Dans le cas discret :

$$\mathbb{E}_{p_{\text{data}}}[g(x)] = \sum_x p_{\text{data}}(x)\, g(x).$$

Lecture : on fait une moyenne pondérée par la fréquence/probabilité des différentes valeurs de x.

LIEN ESSENTIEL ENTRE KL ET MLE

On peut écrire :

$$D_{\text{KL}}(p_{\text{data}} \,\|\, p_\theta) = \mathbb{E}_{p_{\text{data}}}[\log p_{\text{data}}(x)] - \mathbb{E}_{p_{\text{data}}}[\log p_\theta(x)].$$

Le premier terme ne dépend pas de θ. Ainsi :

$$\arg\min_\theta D_{\mathrm{KL}}(p_{\text{data}} \,\|\, p_\theta) \iff \arg\max_\theta \mathbb{E}_{x\sim p_{\text{data}}}[\log p_\theta(x)].$$

Lecture : minimiser l'écart KL revient donc, pour ce sens de la KL, à rendre la log-vraisemblance moyenne sous les vraies données aussi grande que possible.

Comme p_{data} est inconnue, on remplace cette moyenne théorique par la moyenne sur les observations disponibles :

$$\mathbb{E}_{x\sim p_{\text{data}}}[\log p_\theta(x)] \approx \frac{1}{m}\sum_{i=1}^{m} \log p_\theta(x^{(i)}).$$

À RETENIR

Le MLE donne une manière pratique d'ajuster p_θ à partir d'un dataset fini : on choisit les paramètres qui maximisent la log-vraisemblance des données observées.

8 Exemple pratique : MLE d'une Bernoulli

8.1 Exemple 1 : dé biaisé (Bernoulli sur « six » / « pas six »)

On observe $n = 12$ lancers, avec $k = 4$ fois « six ». On note $X_i = 1$ si « six », sinon 0. Alors $X_i \sim \text{Bernoulli}(\theta)$.

ÉTAPE A — ÉCRIRE LA VRAISEMBLANCE

La probabilité d'obtenir exactement k succès sur n essais (en iid) est proportionnelle à :

$$L(\theta) = \theta^k(1-\theta)^{n-k}.$$

Ici :

$$L(\theta) = \theta^4(1-\theta)^8.$$

Lecture : 4 fois « six » $\Rightarrow \theta^4$, et 8 fois « pas six » $\Rightarrow (1-\theta)^8$.

ÉTAPE B — LOG-VRAISEMBLANCE

$$\ell(\theta) = \log L(\theta) = 4\log\theta + 8\log(1-\theta).$$

Pourquoi c'est utile ? On transforme un produit en somme.

ÉTAPE C — DÉRIVER ET ANNULER

On cherche le maximum de $\ell(\theta)$, donc on trouve où la pente est nulle :

$$\frac{d}{d\theta}\ell(\theta) = 0.$$

Pourquoi ? Au sommet d'une courbe (maximum), la tangente est horizontale.

Or :

$$\frac{d}{d\theta}\ell(\theta) = \frac{4}{\theta} - \frac{8}{1-\theta}.$$

En posant à zéro :

$$\frac{4}{\theta} = \frac{8}{1-\theta} \quad\Longrightarrow\quad 4(1-\theta) = 8\theta \quad\Longrightarrow\quad 4 = 12\theta \quad\Longrightarrow\quad \hat\theta = \frac{1}{3}.$$

Interprétation : la meilleure probabilité estimée est « fréquence observée » k/n.

PETIT « CHECK » : EST-CE BIEN UN MAXIMUM ?

Ici $\ell(\theta)$ est **concave** sur $(0,1)$, donc la solution trouvée correspond bien à un maximum.

DU CONCEPT AU CODE — MLE D'UNE BERNOULLI

Après la dérivation, l'estimateur obtenu est simplement la fréquence observée des succès :

$$\hat{\theta} = \frac{k}{n}.$$

```
n = 12
k = 4
theta_hat = k / n
print(theta_hat)    # 0.333...
```

À observer : ces quelques lignes appliquent directement le résultat obtenu par le calcul : $\hat{\theta} = 4/12 = 1/3$.

9 Malédiction de la dimension : pourquoi $p(x)$ est difficile

Lorsque les données vivent dans un espace de grande dimension, apprendre directement une distribution $p(x)$ devient très difficile : l'espace des configurations possibles augmente extrêmement vite, alors que le dataset n'en observe qu'une petite partie.

Considérons une image binaire de taille 28×28 pixels. Chaque pixel peut prendre deux valeurs (0 ou 1), donc le nombre total d'images possibles est :

$$|\mathcal{X}| = 2^{784} \approx 10^{236}.$$

Même plusieurs millions d'images ne couvriraient qu'une fraction infinitésimale de cet espace.

CONSÉQUENCE ESSENTIELLE

En grande dimension, les données sont très clairsemées : estimer naïvement la densité jointe

$$p(x_1, \ldots, x_n)$$

devient difficile. Il faut donc introduire de la **structure** dans le modèle.

Deux stratégies que nous étudierons prochainement sont :

- **factoriser la distribution jointe** (modèles auto-régressifs) ;
- introduire des **variables latentes** (par exemple les VAE).

Nous allons maintenant voir comment la règle de la chaîne permet de factoriser $p(x)$ et de rendre la modélisation plus tractable.

ATTENTION AUX NOTATIONS !

- **Jusqu'ici :** $x^{(i)}$ = i-ième **exemple** du dataset (ex : i-ième image).
- **Maintenant :** x_i = i-ième **pixel/token** *dans* une image/texte.

Astuce : le parenthèse $(\cdot)$ indique un indice de dataset ; sans parenthèse, c'est une composante.

10 Factorisation de $p(x)$: rendre l'apprentissage faisable

Jusqu'ici, l'indice i a souvent servi à numéroter les **observations du dataset**, comme $x^{(i)}$. Dans cette section, on change de point de vue : on considère **une seule observation** $x = (x_1, \ldots, x_n)$ et l'indice i désigne maintenant sa i-ème composante (pixel, token, variable, etc.).

10.1 Règle de la chaîne (toujours vraie)

Pour $x = (x_1, \ldots, x_n)$:

$$p(x_1, \ldots, x_n) = \prod_{i=1}^{n} p(x_i \mid x_1, \ldots, x_{i-1}).$$

Lecture : au lieu de modéliser directement une grande distribution jointe, on la décompose en une suite de distributions conditionnelles :

$$p(x_1), \quad p(x_2 \mid x_1), \quad p(x_3 \mid x_1, x_2), \quad \ldots$$

Chaque nouvelle composante est modélisée en utilisant celles qui la précèdent comme contexte.

POURQUOI CETTE RÈGLE EST VRAIE ? (MINI-JUSTIFICATION)

Pour $n = 3$:

$$p(x_1, x_2, x_3) = p(x_1)\, p(x_2, x_3 \mid x_1),$$

puis

$$p(x_2, x_3 \mid x_1) = p(x_2 \mid x_1)\, p(x_3 \mid x_1, x_2).$$

En combinant les deux expressions :

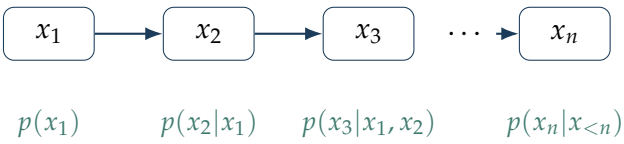
$$p(x_1, x_2, x_3) = p(x_1)\, p(x_2 \mid x_1)\, p(x_3 \mid x_1, x_2).$$

EXEMPLE CONCRET : FACTORISER $p(x_1, x_2, x_3)$

$$p(x_1, x_2, x_3) = p(x_1)\, p(x_2 \mid x_1)\, p(x_3 \mid x_1, x_2).$$

Lecture :

- d'abord, on modélise x_1 sans contexte antérieur ;
- ensuite, on modélise x_2 en connaissant x_1 ;
- enfin, on modélise x_3 en connaissant (x_1, x_2).



10.2 Idée auto-régressive

Cette même factorisation conduit à l'écriture :

$$p_\theta(x) = \prod_{i=1}^{n} p_\theta(x_i \mid x_{<i}), \qquad x_{<i} = (x_1, \ldots, x_{i-1}).$$

IDÉE À RETENIR

Un modèle auto-régressif apprend chaque conditionnelle $p_\theta(x_i \mid x_{<i})$ et construit ainsi la distribution complète **pas à pas**. Pour le texte, x_i peut être un token ; pour une image, x_i peut être un pixel ou une composante de pixel.

DU CONCEPT AU CODE — GÉNÉRATION AUTO-RÉGRESSIVE

La factorisation

$$p_\theta(x) = \prod_i p_\theta(x_i \mid x_{<i})$$

correspond à une génération pas à pas :

```
sequence = []
for i in range(n):
    p_next = model(sequence)
    x_i = sample(p_next)
    sequence.append(x_i)
```

À observer : à chaque étape, le modèle calcule la distribution du prochain élément à partir des éléments déjà présents, puis en échantillonne un nouveau. Le détail de l'entraînement auto-régressif sera étudié en S5.

LIEN AVEC LA S5

Des modèles comme **GPT** ou **PixelCNN** exploitent cette idée. En S5, nous verrons comment ces conditionnelles sont paramétrées, entraînées par MLE/NLL et utilisées pour générer séquentiellement. Ici, l'objectif est seulement de comprendre la **factorisation probabiliste** qui rend cette famille possible.

LIMITES À GARDER EN TÊTE

- **Famille mal choisie :** le MLE ne peut optimiser que les modèles contenus dans la famille p_θ choisie.
- **Surapprentissage :** une forte vraisemblance sur l'entraînement ne garantit pas une bonne généralisation.
- **Haute dimension :** il faut généralement exploiter une structure adaptée, comme une factorisation ou des variables latentes.

11 Synthèse de la semaine 3 et transition vers S4

SYNTHÈSE — CE QU'IL FAUT RETENIR

Au cours de cette semaine, nous avons vu comment apprendre un modèle probabiliste $p_\theta(x)$ à partir de données observées.

Les idées essentielles sont :

- la **vraisemblance** mesure à quel point les paramètres θ expliquent les données observées ;
- le **maximum de vraisemblance** cherche

$$\theta^\star = \arg\max_\theta \sum_{i=1}^{m} \log p_\theta(x^{(i)});$$

- en pratique, maximiser la log-vraisemblance revient à **minimiser la NLL** ;
- en grande dimension, modéliser directement une densité jointe devient difficile : il faut introduire de la **structure** ;
- une première stratégie consiste à factoriser la distribution par la règle de la chaîne :

$$p_\theta(x) = \prod_{i=1}^{n} p_\theta(x_i \mid x_{<i}).$$

TRANSITION VERS LA SEMAINE 4

"La factorisation auto-régressive constitue une première manière de rendre $p(x)$ plus facile à modéliser.

Mais il existe une autre idée fondamentale : supposer que les observations complexes sont générées à partir de variables cachées plus simples.

On introduit alors une variable latente z et un modèle de la forme :

$$p_\theta(x) = \int p_\theta(x \mid z)\, p(z)\, dz.$$

Une nouvelle question apparaît immédiatement :

si z n'est pas observé, comment l'inférer à partir de x ?

C'est précisément le sujet de la Semaine 4 : ***variables latentes, problème d'inférence et inférence approximative.***"

APERÇU DE LA S4

$$\boxed{x \longleftarrow z \qquad \Rightarrow \qquad \text{Comment estimer } p(z \mid x) \text{ ?}}$$

La S4 introduira les **modèles à variables latentes**, le **problème d'inférence** et les premières idées d' **inférence approximative**.