SEMAINE 4

Variables latentes et inférence

Latents · Loi a posteriori · Inférence exacte / approximée · VI

NOTATION IMPORTANTE (PROBABILITÉ OU DENSITÉ)

Dans tout le cours, on notera $p(\cdot)$ indifféremment une **probabilité** (cas discret) ou une **densité** (cas continu). Les méthodes restent identiques : on manipule et on optimise des termes comme $\log p(\cdot)$.

OBJECTIFS DE LA SÉANCE (CE QUE VOUS DEVEZ SAVOIR FAIRE À LA FIN)

1. Comprendre pourquoi on a besoin de **variables latentes** z pour modéliser des données complexes
2. Formuler le **problème d'inférence** : $p(z|x) = \frac{p(x|z)p(z)}{p(x)}$
3. Distinguer **inférence exacte** (rare) et **inférence approximée** (générale)
4. Expliquer l'idée de l'**inférence variationnelle** : approximer $p(z|x)$ par $q_\phi(z|x)$
5. Comprendre qu'une **borne calculable** sera utilisée plus tard pour apprendre les VAE
6. Placer les modèles latents dans la taxonomie du cours (VAE, HMM, etc.)

1 Fil conducteur : transition S3 $\rightarrow$ S4

MISE EN CONTEXTE — DES MODÈLES EXPLICITES AUX VARIABLES LATENTES

"La semaine dernière (S3), on a appris à faire du Maximum de Vraisemblance : $p_\theta(x)$ est calculable, et on maximise $\sum \log p_\theta(x)$.

Mais ça repose sur une hypothèse forte : on peut écrire $p_\theta(x)$ directement. Et si les données dépendaient de facteurs qu'on n'observe pas ?

— *Le style d'écriture dans une image de chiffre*

— *La pose, l'éclairage, l'identité dans une photo de visage*

— *Le sujet latent dans un document*

Ces facteurs, on ne les a pas dans nos données. Pourtant, ils expliquent la variabilité. Comment les modéliser ?"

RAPPEL EXPRESS S3

— **MLE** : $\theta^* = \arg\max_\theta \sum \log p_\theta(x)$

— **Factorisation** : $p(x) = \prod_i p(x_i|x_{<i})$ (auto-régressifs)

— **Malédiction de la dimension** : espace trop grand pour une estimation naïve

QUESTION CENTRALE DE LA SEMAINE

Comment inférer une variable latente z non observée à partir d'une observation x ?

DEUX TÂCHES DIFFÉRENTES : APPRENTISSAGE OU INFÉRENCE

Dans les modèles à variables latentes, il y a souvent **deux problèmes** :

— **Apprentissage :** ajuster les paramètres θ du modèle (ex : $p_\theta(x|z)$)

— **Inférence :** estimer le latent z pour chaque observation x via la loi a posteriori $p(z|x)$

2 Partie 1 : Pourquoi des variables latentes ?

2.1 Le problème des facteurs non observés

LE PROBLÈME DES FACTEURS NON OBSERVÉS *(problème → échec → solution)*

Problème concret : une base d'images de chiffres manuscrits (MNIST).
Non observé mais influent :

- Style d'écriture (inclinaison, épaisseur)
- Identité du scripteur
- Intention (chiffre voulu)

Limite d'une modélisation directe : on peut modéliser $p(x)$ sans latent, mais il peut être difficile d'y représenter explicitement les facteurs cachés qui structurent la variabilité.
Solution : introduire une **variable latente** z qui résume ces facteurs.

2.2 Solution : modèle à variables latentes

MODÈLE À VARIABLES LATENTES — PRINCIPE

On suppose que chaque observation x est générée par :

1. Tirage d'un facteur latent $z \sim p(z)$ (**loi a priori / loi a priori** : distribution choisie avant d'observer x)
2. Génération de x à partir de z : $x \sim p(x|z)$ (décodeur / générateur)

Pour obtenir la probabilité (ou densité) globale d'une observation x, on doit tenir compte de **toutes les valeurs possibles du latent** z. On "moyenne" donc les distributions conditionnelles $p(x|z)$ selon leur poids $p(z)$. Cela donne la distribution marginale :

$$\boxed{p(x) = \int p(x|z)\, p(z)\, dz}$$

Lecture : pour chaque valeur possible de z, on regarde à quel point elle peut produire x, puis on additionne ces contributions par intégration.

SCHÉMA GÉNÉRATIF (VERSION ULTRA-SIMPLE)

La génération suit donc deux étapes successives : on choisit d'abord un latent selon la loi a priori, puis on génère l'observation conditionnellement à ce latent :

$$z \sim p(z) \quad \Longrightarrow \quad x \sim p_\theta(x|z).$$

Idée : z capture des facteurs cachés ; $p_\theta(x|z)$ génère x à partir de ces facteurs.

DU CONCEPT AU CODE — GÉNÉRER À PARTIR D'UN LATENT

La relation

$$z \sim p(z) \quad \longrightarrow \quad x \sim p_\theta(x|z)$$

se traduit conceptuellement par deux opérations : tirer un latent, puis le décoder.

```
# Pseudo-code conceptuel
z = sample_prior()          # z ~ p(z)
x_new = decoder(z)          # x ~ p_theta(x | z)
```

À observer : le code ne remplace pas la définition probabiliste ; il montre simplement le sens génératif de la formule.

2.3 Analogie intuitive

ANALOGIE DU GÂTEAU

— z = la recette (ingrédients, proportions) — on ne la voit pas
— x = le gâteau qu'on observe
— $p(z)$ = la probabilité d'utiliser certaines recettes
— $p(x|z)$ = la probabilité d'obtenir ce gâteau sachant la recette
— $p(x)$ = la probabilité d'observer ce gâteau (toutes recettes confondues)

Message : la variabilité des gâteaux s'explique par la variabilité des recettes sous-jacentes.

2.4 Exemples classiques de modèles latents

Modèle	**Observation** x	**Latent** z
Mixture de Gaussiennes	Point dans $\mathbb{R}^d$	Composante (1..K)
Analyse factorielle	Mesures	Facteurs sous-jacents
HMM (Markov caché)	Observation x_t	État caché h_t
VAE	Image	Code (style, orientation)
LDA (topic modeling)	Mots d'un doc	Sujet du document

EXEMPLE DISCRET : MIXTURE (SOMME AU LIEU D'INTÉGRALE)

Si z est discret (par ex. $z \in \{1, \ldots, K\}$), alors l'intégrale devient une somme :

$$p(x) = \sum_{k=1}^{K} p(x \mid z = k)\, p(z = k).$$

Lecture : on additionne la contribution de chaque composante latente.

MINI-INTERACTION (1 MIN)

Dans une vidéo, on observe les images $x_1, \ldots, x_T$. Proposez un latent possible.
Réponse attendue : la pose, l'identité de la personne, le fond, l'éclairage, le mouvement, etc.

3 Partie 2 : Le problème d'inférence

3.1 La question fondamentale

LE PROBLÈME D'INFÉRENCE

Étant donné une observation x, que peut-on dire du latent z qui l'a générée ? La règle de Bayes permet de passer du modèle génératif $p(x|z)p(z)$ à une distribution sur le latent **après observation de** x :

$$p(z|x) = \frac{p(x|z)\, p(z)}{p(x)}$$

C'est la **loi a posteriori** de z sachant x. Le terme $p(x)$ au dénominateur est appelé **évidence** ou **vraisemblance marginale**.

Interprétation : après avoir observé x, on met à jour notre croyance sur z.

LES 3 DISTRIBUTIONS CLÉS DES MODÈLES LATENTS

Nom	Notation	Rôle
Loi a priori	$p(z)$	Distribution *avant* d'observer x
Vraisemblance	$p(x\|z)$	Comment z génère x
Loi a posteriori	$p(z\|x)$	Distribution *après* avoir observé x

Formule de Bayes :

$$\boxed{p(z|x) = \frac{p(x|z)\,p(z)}{p(x)}} \qquad \text{(posterior = vraisemblance} \times \text{ prior / évidence)}$$

3.2 Pourquoi c'est difficile ?

LE PROBLÈME FONDAMENTAL

Le terme $p(x)$ est souvent **intraitable exactement en pratique** : l'intégrale ou la somme requise ne possède généralement pas de forme fermée simple ou coûte trop cher à calculer :

$$p(x) = \int p(x|z)\,p(z)\,dz.$$

Conséquence : on ne peut pas calculer $p(z|x)$ exactement dans la plupart des modèles modernes.

En pratique :

— Si z est continu et $p(x|z)$ est un réseau de neurones ⇒ l'intégrale ne possède généralement pas de forme fermée simple et devient difficile à calculer exactement

— Si z est discret avec beaucoup de valeurs ⇒ somme très coûteuse (souvent exponentielle)

3.3 Illustration du problème

EXEMPLE JOUET 1D (OÙ ÇA MARCHE)

Supposons $p(z) = \mathcal{N}(0,1)$ et $p(x|z) = \mathcal{N}(z,1)$. Pour obtenir la loi marginale de x, on élimine le latent z en intégrant sur toutes ses valeurs possibles :

$$p(x) = \int \mathcal{N}(x;z,1)\,\mathcal{N}(z;0,1)\,dz.$$

C'est calculable : **marginalement** on obtient $x \sim \mathcal{N}(0,2)$. **Important :** ici, $\mathcal{N}(0,2)$ est la loi de x, pas de z.

C'est un **cas particulier où le calcul est simple**. Avec des réseaux neuronaux, $p(x|z)$ est généralement plus complexe : l'intégrale ne possède souvent pas de forme fermée simple et devient difficile à calculer exactement.

EXEMPLE DE LOI A POSTERIORI (CAS GAUSSIEN CONJUGUÉ)

Supposons :

$$p(z) = \mathcal{N}(0,1), \qquad p(x|z) = \mathcal{N}(z,1).$$

Après observation de x, la loi a posteriori est :

$$p(z|x) = \mathcal{N}\left(z; \frac{x}{2}, \frac{1}{2}\right).$$

Interprétation :
— La moyenne passe de 0 (loi a priori) à $x/2$ (compromis entre loi a priori et observation)
— La variance diminue : on est plus certain sur z après avoir vu x
Important : ce cas simple (gaussien linéaire) est l'un des rares où la loi a posteriori est calculable exactement.

3.4 Les deux grandes familles d'inférence

Lorsqu'on cherche la loi a posteriori $p(z \mid x)$, deux situations peuvent se présenter : soit il peut être calculé exactement, soit ce calcul est trop difficile et l'on doit utiliser une approximation.

INFÉRENCE EXACTE OU INFÉRENCE APPROXIMÉE

— **Inférence exacte**
On parle d'inférence exacte lorsque l'on peut calculer la loi a posteriori

$$p(z \mid x)$$

de manière analytique ou avec un algorithme qui donne la solution exacte.
Cela est possible seulement pour certaines structures de modèles, par exemple :

- des modèles simples ou conjugués, comme certains modèles gaussiens linéaires ;
- des modèles graphiques possédant une structure particulière, comme certaines chaînes ou certains arbres.

Idée à retenir : on obtient la loi a posteriori exacte $p(z \mid x)$, ou une représentation exacte de celui-ci selon la structure du modèle.

— **Inférence approximée**
Dans les modèles complexes, notamment lorsque des réseaux de neurones interviennent, la loi a posteriori exacte est souvent difficile à calculer.
On cherche alors une approximation suffisamment bonne de $p(z \mid x)$.
Quelques grandes approches sont :

- **Inférence variationnelle (VI)** : on remplace $p(z \mid x)$ par une distribution plus simple $q_\phi(z \mid x)$ que l'on apprend à ajuster ;
- **Méthodes de Monte Carlo (MCMC)** : on génère des échantillons qui permettent d'approximer la loi a posteriori ;
- **Échantillonnage par importance** : on échantillonne à partir d'une distribution plus facile, puis on pondère les échantillons ;
- **Méthodes séquentielles** : par exemple le filtre de Kalman ou le filtre particulaire, utilisés lorsque les données évoluent dans le temps.

Idée à retenir : on ne calcule pas exactement $p(z \mid x)$; on construit une approximation suffisamment précise pour pouvoir poursuivre l'apprentissage ou la génération.

AUTO-VÉRIFICATION

Pourquoi ne peut-on pas calculer $p(x)$ directement dans un modèle latent complexe ?

Réponse attendue : parce qu'il faut intégrer (ou sommer) sur tous les z possibles ; lorsque $p(x|z)$ est complexe, cette marginalisation ne possède généralement pas de forme fermée simple et peut devenir très coûteuse à calculer exactement.

4 Partie 3 : Inférence approximée — Introduction à l'inférence variationnelle

4.1 L'idée centrale

LE PROBLÈME *(problème → échec → solution)*

On veut connaître la loi a posteriori $p(z|x)$, c'est-à-dire déterminer quelles valeurs du latent z sont plausibles après avoir observé x.

Dans les modèles complexes, cette loi a posteriori est souvent difficile à calculer exactement, car son expression dépend de la quantité $p(x)$, qui nécessite généralement une marginalisation sur toutes les valeurs possibles de z.

Échec : l'inférence exacte n'est généralement pas disponible sous une forme simple.
Solution : approximer $p(z|x)$ par une distribution plus simple $q_\phi(z|x)$.

IDÉE PRATIQUE (TRÈS IMPORTANTE)

Comme $p(z|x)$ est difficile à calculer exactement, on introduit une approximation $q_\phi(z|x)$ et on cherchera un **objectif calculable** permettant de l'apprendre sans calculer explicitement la loi a posteriori exacte.

Pourquoi ? La divergence KL fait intervenir $p(z|x)$, qui dépend de $p(x)$ (intraitable). On contournera ce problème en S7 avec une **borne inférieure calculable** (ELBO).

La construction détaillée de cet objectif sera étudiée en S7.

4.2 Principe de l'inférence variationnelle

INFÉRENCE VARIATIONNELLE — PRINCIPE

On choisit une famille de distributions $q_\phi(z|x)$ paramétrée par ϕ (ex : gaussienne diagonale). On cherche ϕ qui rend $q_\phi(z|x)$ la plus proche possible de $p(z|x)$.

Pour mesurer cet écart, on utilise la divergence de Kullback–Leibler. La notation $\mathbb{E}_{z\sim q_\phi}[\cdot]$ signifie que l'on prend une **moyenne** lorsque z est tiré selon $q_\phi(z|x)$:

$$D_{\mathrm{KL}}\big(q_\phi(z|x) \,\|\, p(z|x)\big) = \mathbb{E}_{z\sim q_\phi}\left[\log \frac{q_\phi(z|x)}{p(z|x)}\right].$$

Interprétation : cette divergence mesure l'écart entre $q_\phi(z|x)$ et $p(z|x)$ au sens de la divergence de Kullback–Leibler. Plus sa valeur est faible, plus $q_\phi(z|x)$ est proche de la loi a posteriori cible selon ce critère.

NOTATION : $q_\phi(z|x)$ OU $q_\phi(z)$

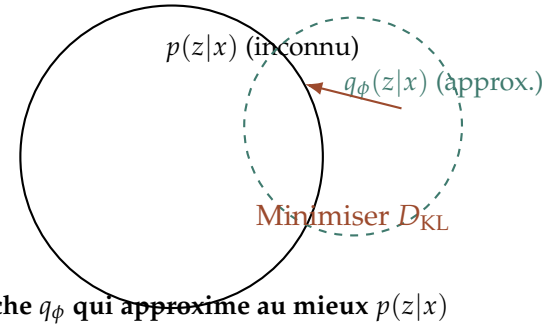
— $q_\phi(z|x)$ **:** inférence **amortie** (réseau d'inférence). La loi a posteriori approximée dépend de x (ex : VAE).

— $q_\phi(z)$ **:** inférence **non amortie**. On apprend un q différent pour chaque x (ex : VI classique).

Dans ce cours, on utilisera surtout $q_\phi(z|x)$ (VAE, S7).

4.3 Représentation géométrique

Avant de regarder le schéma, retenez l'idée suivante : on dispose d'une loi a posteriori exacte $p(z|x)$ que l'on voudrait connaître, mais qui est difficile à manipuler directement. L'inférence variationnelle consiste donc à construire une distribution plus simple $q_\phi(z|x)$ et à l'ajuster pour qu'elle se rapproche autant que possible de la loi a posteriori exacte.



On cherche q_ϕ qui approxime au mieux $p(z|x)$

INTERPRÉTATION GÉOMÉTRIQUE

Le schéma ci-dessus illustre le principe de l'inférence variationnelle :

- Le **grand cercle** représente $p(z|x)$, la véritable distribution a posteriori. Elle est complexe, inconnue, et difficile à manipuler directement.
- Le **cercle bleu en pointillés** représente $q_\phi(z|x)$, notre approximation. Plus simple (souvent une gaussienne), elle est paramétrée par ϕ.
- La **flèche rouge** symbolise la divergence de Kullback-Leibler $D_{\mathrm{KL}}(q \parallel p(z|x))$, une mesure de dissimilarité entre les deux distributions.
- L'objectif est de **réduire cette divergence** en ajustant ϕ, c'est-à-dire rendre $q_\phi(z|x)$ aussi proche que possible de $p(z|x)$ au sens de la divergence KL.

Pourquoi une borne ? Minimiser $D_{\mathrm{KL}}(q \parallel p(z|x))$ directement est impossible car $p(z|x)$ dépend de $p(x)$ (intraitable). On maximisera donc une **borne inférieure** de $\log p(x)$ appelée **ELBO**, ce qui revient à minimiser la KL sans calculer $p(x)$.

En pratique : cette divergence fait apparaître une difficulté : la loi a posteriori exacte $p(z|x)$ n'est justement pas disponible. On utilisera donc en S7 une borne calculable appelée **ELBO** pour entraîner concrètement un VAE.

APERÇU — CE QUI SERA DÉVELOPPÉ EN S7

À retenir pour l'instant :

$$p(z|x) \text{ difficile} \quad \Longrightarrow \quad q_\phi(z|x) \text{ approximation.}$$

En S7, nous verrons comment transformer cette idée en un objectif d'apprentissage calculable à l'aide de la **KL** et de l'**ELBO**, puis comment l'utiliser dans un VAE.

5 Partie 4 : Synthèse et taxonomie

5.1 Où se situent les modèles latents ?

Famille	Exemples	Type d'inférence
Modèles à variables latentes simples	Mixture de Gaussiennes	Parfois exacte
Modèles séquentiels	HMM, modèles linéaires-gaussiens de type Kalman	Inférence exacte dans certains cas structurés (ex : forward–backward)
Modèles profonds	VAE, modèles gaussiens latents profonds	Variationnelle (approximée)
Diffusion (vue simple)	Suite d'états bruités x_t	Processus inverse (approx.)

NOTE (DIFFUSION, FORMULATION SIMPLE ET SÛRE)

Diffusion : suite d'états bruités x_t (variables intermédiaires) et génération via un **processus inverse** appris. On évite ici les détails ; on y reviendra dans le module Diffusion.

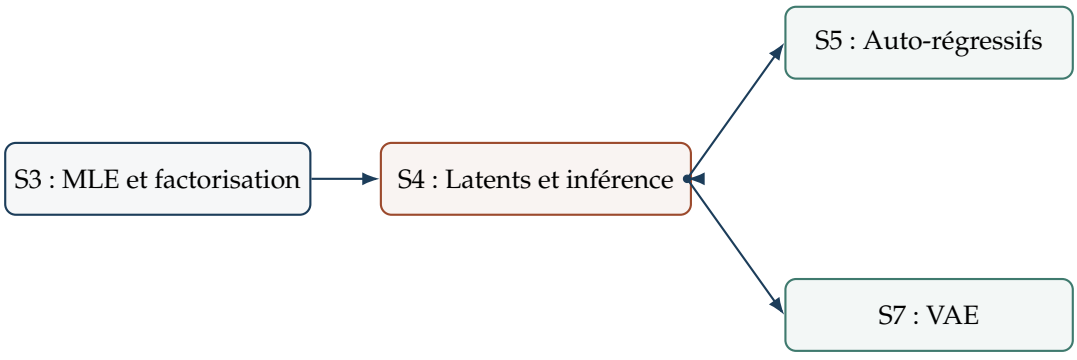
5.2 Lien avec le reste du cours

OÙ VA-T-ON MAINTENANT ?

— **S5 (Auto-régressifs)** : pas de latents, $p(x)$ calculable directement
— **S6 (Autoencodeurs)** : prélude aux VAE (compression sans contrainte)
— **S7 (VAE)** : latents + inférence variationnelle (application concrète)
— **S9 (EBM)** : pas de latents explicites, mais fonction d'énergie
— **S10 (GAN)** : latents implicites (pas d'inférence, génération)
— **S12 (Diffusion)** : états bruités x_t et génération par processus inverse

CLARIFICATION (S3 OU S5)

S3 introduit la **factorisation** et la **MLE** ; S5 met ces idées en œuvre avec des réseaux (PixelRNN / PixelCNN) pour modéliser concrètement $p(x)$.



6 Synthèse de la semaine 4 et transition vers S5

SYNTHÈSE ET TRANSITION VERS S5

"Aujourd'hui, on a vu que :

- *Les **variables latentes** z modélisent des facteurs sous-jacents*
- *Le **problème d'inférence** $p(z|x)$ est central mais souvent difficile à résoudre exactement*
- *L'**inférence variationnelle** approxime $p(z|x)$ par $q_\phi(z|x)$*
- *La **KL** et l'**ELBO** fourniront en S7 les outils permettant d'entraîner concrètement un VAE*

*La semaine prochaine (S5), on revient à des modèles sans latents, où $p(x)$ est calculable directement : les **modèles auto-régressifs** (PixelRNN, PixelCNN)."*

SYNTHÈSE — CE QU'IL FAUT RETENIR

- Modèle latent : $p(x) = \int p_\theta(x|z)p(z)\,dz$ (ou somme si z discret)
- Inférence : estimer $p(z|x)$ (souvent difficile à calculer exactement)
- Solution pratique : approximer $p(z|x)$ par $q_\phi(z|x)$
- La construction de l'objectif variationnel (KL + ELBO) sera étudiée en détail en S7.