SEMAINE 9

Modèles fondés sur l’énergie (EBM)

Énergie · Fonction de partition · Échantillonnage · Divergence contrastive · RBM

S9 — OBJECTIFS (CE QUE VOUS SAUREZ FAIRE À LA FIN)

1. Expliquer le principe d'un **modèle fondé sur l'énergie** et interpréter une fonction d'énergie $E_\theta(x)$.
2. Définir la **fonction de partition** $Z(\theta)$ et comprendre pourquoi elle rend la normalisation difficile.
3. Lire et interpréter le **gradient de la log-vraisemblance** d'un EBM.
4. Distinguer **phase positive** et **phase négative**.
5. Comprendre pourquoi les méthodes de Monte-Carlo par chaînes de Markov (MCMC), notamment la dynamique de Langevin ou l'échantillonnage de Gibbs, interviennent dans l'apprentissage.
6. Expliquer le principe de la **divergence contrastive** et le rôle historique des **machines de Boltzmann restreintes (RBM)**.
7. Comprendre le lien conceptuel entre les EBM et les GAN, sans confondre leurs représentations probabilistes.

1 Fil conducteur : de S8 à S9

MISE EN CONTEXTE — DE L'INVERSIBILITÉ À L'ÉNERGIE

En S8, les flots normalisants conservaient une vraisemblance exacte en imposant des transformations inversibles et des Jacobiennes calculables. Les EBM adoptent une stratégie différente : on ne construit plus directement la densité par une transformation. On apprend plutôt une ***fonction d'énergie*** *qui indique quelles configurations sont plausibles.*

QUESTION CENTRALE DE LA SEMAINE

Comment apprendre une distribution complexe à partir d'une fonction d'énergie lorsque sa normalisation est difficile à calculer ?

FIL LOGIQUE POUR L'ÉTUDIANT AUTONOME

Suivez cette chaîne :

énergie → normalisation → $Z(\theta)$ → gradient de vraisemblance → échantillonnage → CD → RBM

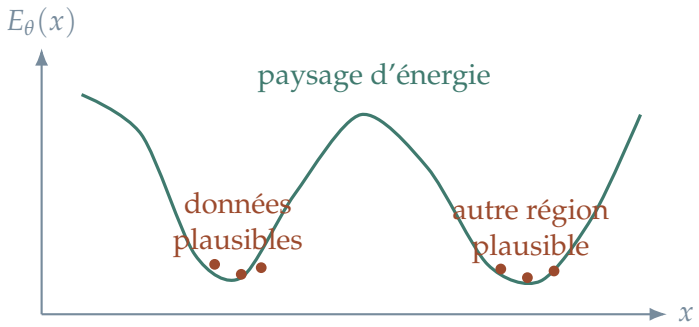
Chaque étape répond à une difficulté introduite par la précédente.

2 L'idée centrale d'un modèle fondé sur l'énergie

2.1 Attribuer une énergie plutôt qu'une probabilité directe

Un EBM associe à chaque configuration x une valeur scalaire $E_\theta(x)$ appelée **énergie**. L'idée est simple :

énergie faible ⇒ configuration privilégiée énergie élevée ⇒ configuration peu probable.



LECTURE INTUITIVE

Le réseau n'a pas besoin de produire directement une probabilité entre 0 et 1. Il doit surtout apprendre un **classement relatif** des configurations : les vraies données doivent se retrouver dans des vallées d'énergie.

3 De l'énergie à une distribution de probabilité

3.1 La distribution de Boltzmann

Pour transformer l'énergie en densité, on utilise :

$$p_\theta(x) = \frac{\exp(-E_\theta(x))}{Z(\theta)},$$

avec :

$$Z(\theta) = \int \exp(-E_\theta(x))\, dx$$

dans le cas continu, ou une somme dans le cas discret.

RÔLE DE LA FONCTION DE PARTITION

$Z(\theta)$ garantit que la distribution est normalisée :

$$\int p_\theta(x)\, dx = 1.$$

Elle ne change pas le classement relatif des points, mais elle est nécessaire pour obtenir une vraie densité.

3.2 Pourquoi $Z(\theta)$ est le problème

En grande dimension, calculer :

$$Z(\theta) = \int \exp(-E_\theta(x))\, dx$$

revient à tenir compte de toutes les configurations possibles. Pour une image ou un objet de grande dimension, ce calcul exact est généralement impraticable.

LE PROBLÈME FONDAMENTAL *(problème → échec → solution)*

Problème : la densité est bien définie par $E_\theta(x)$ et $Z(\theta)$.
Échec : $Z(\theta)$ est généralement impossible à calculer exactement en grande dimension.
Solution : apprendre malgré tout le modèle en exploitant des gradients, des ratios ou des méthodes d'échantillonnage qui n'exigent pas le calcul explicite de $Z(\theta)$.

3.3 Une propriété utile : les ratios

Pour deux points x et x' :

$$\frac{p_\theta(x)}{p_\theta(x')} = \exp\big(-E_\theta(x) + E_\theta(x')\big).$$

POURQUOI EST-CE UTILE ?

La même constante $Z(\theta)$ apparaît au numérateur et au dénominateur, donc elle s'annule. Cela permet de comparer des configurations sans connaître la normalisation exacte.

4 Apprentissage par maximum de vraisemblance

4.1 Objectif

Pour une observation :

$$\log p_\theta(x) = -E_\theta(x) - \log Z(\theta).$$

Le premier terme favorise directement une faible énergie sur les données. Le second empêche le modèle de donner une énergie faible partout : il impose une compétition globale entre les configurations.

4.2 Gradient pour une observation

La dérivation donne :

$$\boxed{\nabla_\theta \log p_\theta(x) = -\nabla_\theta E_\theta(x) + \mathbb{E}_{x' \sim p_\theta}\left[\nabla_\theta E_\theta(x')\right]}$$

COMMENT LIRE CETTE FORMULE

— **Phase positive :**

$$-\nabla_\theta E_\theta(x)$$

pousse à **baisser l'énergie des données observées**.

— **Phase négative :**

$$\mathbb{E}_{x' \sim p_\theta}\left[\nabla_\theta E_\theta(x')\right]$$

pousse à **remonter l'énergie des configurations générées par le modèle**.

GRADIENT MOYEN SUR LES DONNÉES

Sur la distribution réelle des données, l'objectif MLE cherche à maximiser :

$$\mathbb{E}_{x \sim p_{\text{data}}}[\log p_\theta(x)].$$

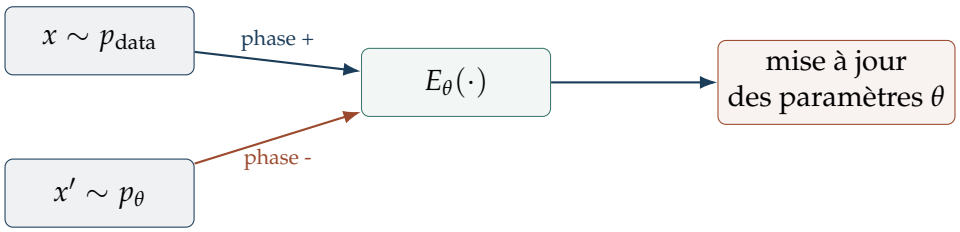
Son gradient est :

$$\nabla_\theta \mathbb{E}_{x \sim p_{\text{data}}}[\log p_\theta(x)] = -\mathbb{E}_{x \sim p_{\text{data}}}[\nabla_\theta E_\theta(x)] + \mathbb{E}_{x' \sim p_\theta}[\nabla_\theta E_\theta(x')].$$

Lecture : on baisse l'énergie des données réelles et on augmente l'énergie des configurations que le modèle favorise actuellement.

MINI-EXEMPLE CONCEPTUEL

Supposons qu'une vraie image ait une énergie de 2 et qu'un échantillon peu réaliste du modèle ait une énergie de 1. Ce classement est mauvais : le modèle préfère la mauvaise image. L'apprentissage cherche donc à diminuer l'énergie de la vraie image et à augmenter celle de l'échantillon incorrect.



LA VRAIE DIFFICULTÉ

La phase positive utilise directement les données du jeu de données. La phase négative exige des échantillons :

$$x' \sim p_\theta.$$

Or échantillonner exactement un EBM est justement difficile. C'est ici qu'interviennent les méthodes de Monte-Carlo par chaînes de Markov (MCMC).

5 Échantillonnage par dynamique de Langevin

5.1 Principe

Comme :

$$\log p_\theta(x) = -E_\theta(x) - \log Z(\theta),$$

on obtient :

$$\nabla_x \log p_\theta(x) = -\nabla_x E_\theta(x),$$

car $Z(\theta)$ ne dépend pas de x.

On peut alors construire une chaîne de Langevin :

$$x_{t+1} = x_t - \frac{\eta}{2}\nabla_x E_\theta(x_t) + \sqrt{\eta}\,\varepsilon_t, \qquad \varepsilon_t \sim \mathcal{N}(0, I).$$

LECTURE DE L'ÉQUATION

— le gradient :

$$-\nabla_x E_\theta(x_t)$$

attire l'échantillon vers des zones de basse énergie ;

— le bruit gaussien empêche la trajectoire de devenir une simple descente déterministe et favorise l'exploration ;

— η contrôle la taille des pas.

NUANCE : CHAÎNE DE LANGEVIN APPROCHÉE

Avec un pas fini η et un nombre fini d'itérations, la chaîne produite par la dynamique de Langevin est une approximation de p_θ.

L'algorithme présenté ici est souvent appelé **ULA** (*Unadjusted Langevin Algorithm*). Une version corrigée, **MALA**, ajoute une étape d'acceptation-rejet pour cibler plus précisément la distribution voulue.

Dans les EBM profonds, on utilise souvent des chaînes courtes pour des raisons de coût : les échantillons négatifs restent donc approximatifs.

DU CONCEPT AU CODE — UNE ÉTAPE DE LANGEVIN

```
x.requires_grad_(True)
grad = torch.autograd.grad(model(x).sum(), x)[0]
x = x - 0.5 * eta * grad + eta**0.5 * torch.randn_like(x)
x = x.detach()
```

À observer : le gradient est calculé par rapport à x, pas par rapport aux paramètres du réseau.

6 Divergence contrastive

6.1 Pourquoi une approximation supplémentaire ?

Pour obtenir de bons échantillons par MCMC, il faudrait théoriquement laisser la chaîne évoluer suffisamment longtemps. C'est coûteux à chaque étape d'entraînement.

IDÉE DE CD-k

La divergence contrastive initialise la chaîne à partir d'une donnée réelle et n'effectue que k pas de chaîne de Markov. Le point obtenu sert d'approximation pour la phase négative.

Schématiquement :

$$x^{(0)} = x_{\text{data}} \longrightarrow x^{(1)} \longrightarrow \cdots \longrightarrow x^{(k)} = x_{\text{CD}}.$$

L'apprentissage compare alors l'énergie de la donnée réelle à celle de l'échantillon reconstruit après quelques transitions.

CE QU'IL FAUT COMPRENDRE

CD-k ne calcule pas le gradient exact du maximum de vraisemblance. C'est une approximation pratique, historiquement très utilisée pour entraîner les RBM.

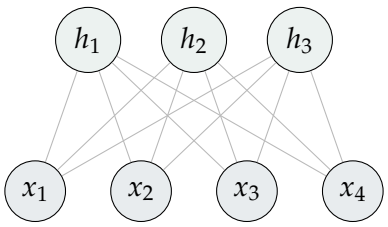
Plus k est petit, plus le calcul est rapide, mais plus l'échantillon négatif reste proche de la donnée initiale.

7 Machine de Boltzmann restreinte (RBM)

7.1 Pourquoi la RBM est-elle importante ici ?

La RBM est un exemple historique d'EBM avec variables visibles x et cachées h. Sa structure bipartite rend certaines distributions conditionnelles faciles à échantillonner, ce qui permet d'utiliser efficacement l'échantillonnage de Gibbs et la divergence contrastive.

unités cachées



unités visibles

Pour une RBM binaire :

$$E_\theta(x, h) = -x^\top W h - b^\top x - c^\top h.$$

La structure bipartite implique :

$$p(h_j = 1 \mid x) = \sigma\left(\sum_i W_{ij} x_i + c_j\right),$$

et :

$$p(x_i = 1 \mid h) = \sigma\left(\sum_j W_{ij} h_j + b_i\right).$$

POURQUOI GIBBS DEVIENT SIMPLE

Conditionnellement à x, les unités cachées sont indépendantes entre elles ; conditionnellement à h, les unités visibles le sont aussi. On peut donc alterner :

$$x^{(t)} \to h^{(t)} \to x^{(t+1)} \to \cdots$$

sans devoir échantillonner toutes les variables conjointement.

8 Produit d'experts : complément optionnel

Supposons que plusieurs experts non négatifs attribuent un score aux observations :

$$q_1(x), \ldots, q_m(x).$$

Un produit d'experts définit :

$$p(x) = \frac{1}{Z} \prod_{j=1}^{m} q_j(x).$$

Dans une écriture énergétique, si :

$$q_j(x) = \exp(-E_j(x)),$$

alors :

$$p(x) = \frac{1}{Z} \exp\left(- \sum_{j=1}^{m} E_j(x) \right).$$

À RETENIR

Une mixture ressemble à un "OU" : un composant peut expliquer un point.

Un produit d'experts ressemble à un "ET" : plusieurs contraintes doivent être satisfaites simultanément.

La normalisation globale Z reste toutefois difficile à calculer en général.

9 Lien avec les GAN : seulement l'idée nécessaire

Les réseaux antagonistes génératifs (GAN) seront étudiés en détail en S10. Ici, il suffit de comprendre la comparaison suivante.

Aspect	**EBM**	**GAN**
Représentation	énergie $E_\theta(x)$ et densité non normalisée	générateur implicite $x = G_\theta(z)$
Normalisation	$Z(\theta)$ existe mais est difficile à calculer	pas de densité explicite requise
Échantillonnage	généralement MCMC ou procédures apparentées	direct via le générateur
Entraînement	objectif lié à la vraisemblance ou au contraste, souvent approximé	jeu adversarial
Difficulté centrale	échantillonnage et normalisation	stabilité et couverture des modes

NE PAS CONFONDRE

Un EBM n'est pas un modèle implicite au même sens qu'un GAN : il définit bien une densité :

$$p_\theta(x) = \frac{e^{-E_\theta(x)}}{Z(\theta)},$$

mais sa constante de normalisation est souvent inaccessible.

Le GAN, lui, permet de générer sans fournir directement une densité explicite.

10 Avantages et limites

Avantages	Limites
Architecture très flexible pour $E_\theta(x)$	Normalisation exacte souvent intractable
Pas d'inversibilité obligatoire	Échantillonnage potentiellement lent
Ratios de probabilités accessibles sans Z	Phase négative coûteuse à approximer
Lien naturel avec le score	Sensible au choix de la procédure MCMC

LIEN VERS LES SEMAINES SUIVANTES

La relation :

$$\nabla_x \log p_\theta(x) = -\nabla_x E_\theta(x)$$

est fondamentale : elle prépare directement la S11 sur l'**appariement du score**.

Les modèles de diffusion établiront ensuite un lien particulier entre estimation du score et débruitage. Entre les deux, la S10 étudiera les modèles implicites et les GAN.

11 Synthèse de la semaine 9 et transition vers S10

SYNTHÈSE — CE QU'IL FAUT RETENIR

— un EBM associe une énergie scalaire $E_\theta(x)$ à chaque configuration ;

— la densité est :

$$p_\theta(x) = \frac{e^{-E_\theta(x)}}{Z(\theta)};$$

— $Z(\theta)$ assure la normalisation mais est généralement difficile à calculer ;

— le gradient du maximum de vraisemblance oppose une **phase positive** sur les données à une **phase négative** sur les échantillons du modèle ;

— Langevin et Gibbs sont des méthodes d'échantillonnage utiles pour cette phase négative ;

— CD-k approxime cette phase avec quelques transitions MCMC ;

— la RBM est un exemple historique où la structure bipartite facilite l'échantillonnage de Gibbs ;

— le lien avec les GAN est la flexibilité, mais leurs représentations probabilistes sont différentes.

AUTO-VÉRIFICATION

À la fin de cette semaine, vous devriez pouvoir :

1. expliquer comment une énergie définit une densité ;
2. dire pourquoi la fonction de partition est difficile à calculer ;
3. interpréter les phases positive et négative ;

4. expliquer pourquoi il faut échantillonner le modèle ;
5. décrire le principe de Langevin et de CD-k ;
6. expliquer pourquoi les conditionnelles d'une RBM sont faciles à échantillonner ;
7. distinguer un EBM d'un GAN.

TRANSITION VERS S10

En S9, la distribution existe explicitement mais sa normalisation et son échantillonnage sont difficiles. En S10, nous étudierons une autre stratégie : apprendre directement à générer des échantillons sans exiger de densité calculable. Cela conduira aux GAN, à MMD-GAN et aux problèmes d'évaluation des modèles implicites.