SEMAINE 10

Modèles génératifs implicites

GAN · MMD-GAN · absence de vraisemblance · évaluation

S10 — OBJECTIFS (CE QUE VOUS SAUREZ FAIRE À LA FIN)

1. Expliquer ce qu'est un modèle génératif implicite et pourquoi sa vraisemblance n'est pas directement calculable.
2. Comprendre l'idée des tests à deux échantillons comme alternative à la comparaison de densités.
3. Décrire le jeu antagoniste GAN entre générateur et discriminateur et son objectif minimax.
4. Relier, sous les hypothèses théoriques du GAN original, l'objectif optimal à la divergence de Jensen–Shannon.
5. Expliquer les difficultés pratiques des GAN, notamment l'instabilité et le mode collapse.
6. Comprendre le principe du MMD et du MMD-GAN.
7. Choisir et interpréter des métriques d'évaluation adaptées aux modèles implicites : IS, FID, KID, précision/rappel, densité/couverture.

MISE EN CONTEXTE — DE S9 À S10

En S9, nous avons vu qu'un modèle fondé sur l'énergie peut associer une énergie aux données, mais que sa normalisation et son échantillonnage peuvent être coûteux. En S10, nous changeons de perspective : au lieu d'exiger une densité explicite, nous apprenons directement une ***procédure de génération*** *et nous comparons les échantillons produits aux données réelles.*

QUESTION CENTRALE DE LA SEMAINE

Peut-on apprendre à générer des données réalistes sans jamais calculer explicitement leur vraisemblance $p_\theta(\mathbf{x})$?

LIEN AVEC LE PLAN DU COURS

Cette semaine est centrée sur les quatre éléments prévus pour S10 : **GAN comme cas particulier**, **MMD-GAN**, **absence de vraisemblance** et **problèmes d'évaluation**. Les développements théoriques ci-dessous servent directement à comprendre ces quatre points.

VUE D'ENSEMBLE

Ce cours présente les modèles génératifs implicites, une classe de modèles qui contournent la nécessité de définir explicitement une fonction de vraisemblance. Nous verrons les limites des approches basées sur la vraisemblance, les fondements théoriques des tests à deux échantillons, puis nous plongerons en détail dans les réseaux antagonistes génératifs (GAN) et leurs variantes comme les MMD-GAN. Nous analyserons également les avantages et inconvénients de l'absence de vraisemblance dans ces modèles, ainsi que les métriques d'évaluation appropriées.

1 Introduction aux modèles génératifs implicites

1.1 Rappel sur les modèles génératifs classiques

Les modèles génératifs ont pour objectif d'apprendre la distribution sous-jacente des données $p_{\text{data}}(\mathbf{x})$ à partir d'un ensemble d'échantillons $\{\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_n\}$. Jusqu'à présent, nous avons étudié plusieurs familles de modèles qui partagent une caractéristique commune : ils définissent explicitement une fonction de vraisemblance.

Définition 1.1 — Familles de modèles génératifs classiques. — **Modèles autorégressifs** :

$$p_\theta(\mathbf{x}) = \prod_{i=1}^{n} p_\theta(x_i|\mathbf{x}_{<i})$$

— **Autoencodeurs variationnels (VAE)** :

$$p_\theta(\mathbf{x}) = \int p_\theta(\mathbf{x}, \mathbf{z}) d\mathbf{z}$$

— **Modèles à flot normalisant** :

$$p_{\mathbf{x}}(\mathbf{x};\theta) = p_{\mathbf{z}}(\mathbf{f}_\theta^{-1}(\mathbf{x})) \left| \det \left(\frac{\partial \mathbf{f}_\theta^{-1}(\mathbf{x})}{\partial \mathbf{x}} \right) \right|$$

Pour les modèles à vraisemblance explicite, maximiser la log-vraisemblance revient, au niveau population, à minimiser la divergence de Kullback–Leibler

$$D_{\mathrm{KL}}(p_{\mathrm{data}} \,\|\, p_\theta)\,.$$

Pour les modèles autorégressifs et les flots normalisants, la vraisemblance est directement calculable dans les formulations usuelles ; pour les VAE, la vraisemblance marginale est définie mais généralement difficile à calculer exactement, et l'apprentissage s'appuie sur une borne variationnelle (ELBO).

1.2 Pourquoi remettre en question la maximisation de vraisemblance ?

La maximisation de vraisemblance possède des propriétés théoriques attrayantes :

Propriété 1.1 — Pourquoi la vraisemblance reste importante. Sous des hypothèses de régularité et lorsque le modèle est correctement spécifié, l'estimation par maximum de vraisemblance possède de solides propriétés asymptotiques : cohérence, normalité asymptotique et efficacité dans des cadres classiques. Elle fournit aussi un lien naturel avec le codage probabiliste : attribuer une probabilité élevée aux données peut conduire à des codes plus courts. Ces propriétés ne signifient toutefois pas qu'une meilleure vraisemblance garantit une meilleure qualité perceptuelle des échantillons.

Cependant, une question fondamentale se pose : **la vraisemblance est-elle un bon indicateur de la qualité des échantillons générés par le modèle ?**

1.3 Le paradoxe vraisemblance vs. qualité d'échantillons

1.3.1 Cas 1 : Bonne vraisemblance, mauvais échantillons

Considérons un modèle de bruit discret défini par :

$$p_\theta(\mathbf{x}) = 0.01 p_{\mathrm{data}}(\mathbf{x}) + 0.99 p_{\mathrm{bruit}}(\mathbf{x})$$

Dans ce modèle, 99% des échantillons sont simplement du bruit. Pourtant, en prenant le logarithme, nous obtenons une borne inférieure :

$$\begin{aligned} \log p_\theta(\mathbf{x}) &= \log[0.01 p_{\mathrm{data}}(\mathbf{x}) + 0.99 p_{\mathrm{bruit}}(\mathbf{x})] \\ &\geq \log 0.01 p_{\mathrm{data}}(\mathbf{x}) = \log p_{\mathrm{data}}(\mathbf{x}) - \log 100 \end{aligned}$$

Pour l'espérance de la log-vraisemblance, nous avons :

— **Borne inférieure** :

$$\mathbb{E}_{p_{\mathrm{data}}}[\log p_\theta(\mathbf{x})] \geq \mathbb{E}_{p_{\mathrm{data}}}[\log p_{\mathrm{data}}(\mathbf{x})] - \log 100.$$

— **Borne supérieure** : par non-négativité de $D_{\mathrm{KL}}(p_{\text{data}} \,\|\, p_\theta)$,

$$\mathbb{E}_{p_{\text{data}}}[\log p_{\text{data}}(\mathbf{x})] \geq \mathbb{E}_{p_{\text{data}}}[\log p_\theta(\mathbf{x})].$$

Lorsque la dimension n de $\mathbf{x} = (x_1, \ldots, x_n)$ augmente, la valeur absolue de $\log p_{\text{data}}(\mathbf{x}) = \sum_{i=1}^{n} \log p(x_i|\mathbf{x}_{<i})$ augmente proportionnellement à n, tandis que $\log 100$ reste constant. Par conséquent, en très haute dimension, $\mathbb{E}_{p_{\text{data}}}[\log p_\theta(\mathbf{x})] \approx \mathbb{E}_{p_{\text{data}}}[\log p_{\text{data}}(\mathbf{x})]$: la vraisemblance est excellente alors que la plupart des échantillons sont de mauvaise qualité.

1.3.2 Cas 2 : Bons échantillons, mauvaise vraisemblance

Un cas extrême est celui d'un modèle qui mémorise l'ensemble d'entraînement :

— Les échantillons sont parfaits (identiques aux données d'entraînement)

— La probabilité assignée aux données de test est nulle

— La vraisemblance sur le test est donc infiniment mauvaise

1.4 Conclusion de l'introduction

Ces observations suggèrent qu'il est utile de **dissocier la vraisemblance de la qualité des échantillons**. L'apprentissage sans vraisemblance considère des objectifs d'entraînement alternatifs qui ne dépendent pas directement d'une fonction de vraisemblance. Au lieu de minimiser $D_{\mathrm{KL}}(p_{\text{data}} \,\|\, p_\theta)$, nous allons considérer d'autres choix de divergence $d(p_{\text{data}}, p_\theta)$.

2 Tests à deux échantillons : fondement théorique

2.1 Principe général

Définition 2.1 — Test à deux échantillons. Étant donné deux ensembles finis d'échantillons $S_1 = \{\mathbf{x} \sim P\}$ et $S_2 = \{\mathbf{x} \sim Q\}$, un test à deux échantillons cherche à déterminer si ces échantillons proviennent de la même distribution (i.e., $P = Q$).

Les hypothèses statistiques sont :

— **Hypothèse nulle** $H_0 : P = Q$

— **Hypothèse alternative** $H_1 : P \neq Q$

Une **statistique de test** T compare S_1 et S_2. Par exemple, la différence des moyennes :

$$T(S_1, S_2) = \left| \frac{1}{|S_1|} \sum_{\mathbf{x} \in S_1} \mathbf{x} - \frac{1}{|S_2|} \sum_{\mathbf{x} \in S_2} \mathbf{x} \right|$$

Une grande valeur de la statistique peut constituer une évidence contre H_0, mais la décision dépend de sa distribution sous l'hypothèse nulle. Le niveau α désigne un **niveau de signification**, pas directement un seuil universel sur T. En pratique, on utilise par exemple une valeur critique ou une *p-value*.

Remarque 2.1 — Propriété fondamentale. La statistique de test est **sans vraisemblance** car elle n'implique pas les densités P ou Q, seulement des échantillons.

2.2 Défi en haute dimension

En haute dimension, trouver une bonne statistique de test est difficile. Dans le contexte des modèles génératifs, nous savons que S_1 et S_2 proviennent respectivement de distributions différentes : p_{data} et p_θ.

L'idée clé est d'**apprendre une statistique** pour identifier automatiquement en quoi les deux ensembles d'échantillons diffèrent. Comment ? En entraînant un classificateur (appelé discriminateur) !

2.3 Test à deux échantillons via un discriminateur

Définition 2.2 — Discriminateur. Un classificateur binaire D_ϕ (par exemple, un réseau de neurones) qui essaie de distinguer :

— Les échantillons "réels" ($y = 1$) provenant du jeu de données

— Les échantillons "faux" ($y = 0$) générés par le modèle

La performance du classificateur fournit alors une **statistique de séparation** entre les deux ensembles :

— **Erreur de classification faible / exactitude élevée** : les échantillons réels et générés sont faciles à distinguer ⇒ les distributions diffèrent fortement ;

— **Performance proche du hasard** : les deux ensembles sont difficiles à distinguer ⇒ ils sont plus proches selon les caractéristiques exploitées par le classificateur.

Pour entraîner le discriminateur, on minimise sa perte de classification (ou, de façon équivalente selon la convention choisie, on maximise son objectif de log-vraisemblance binaire). Une bonne capacité de séparation fournit alors une preuve empirique que les deux distributions ne coïncident pas.

2.4 Objectif d'entraînement du discriminateur

Pour un modèle génératif fixé p_θ, l'objectif d'entraînement du discriminateur est :

$$V(p_\theta, D_\phi) = \sum_{\mathbf{x} \in S_1} \log D_\phi(\mathbf{x}) + \sum_{\mathbf{x} \in S_2} [\log(1 - D_\phi(\mathbf{x}))]$$

C'est un problème de classification binaire avec l'objectif d'entropie croisée :

— Assigner une probabilité 1 aux points de données réels $\mathbf{x} \sim p_{\text{data}}$ (ensemble S_1)

— Assigner une probabilité 0 aux échantillons faux $\mathbf{x} \sim p_\theta$ (ensemble S_2)

Théorème 2.1 — Discriminateur optimal. Pour un générateur fixé p_θ, le discriminateur optimal est :

$$D^*_\theta(\mathbf{x}) = \frac{p_{\text{data}}(\mathbf{x})}{p_{\text{data}}(\mathbf{x}) + p_\theta(\mathbf{x})}$$

Démonstration. La preuve s'obtient en maximisant $V(p_\theta, D)$ par rapport à D. Considérons la fonction objectif pour un $\mathbf{x}$ fixé :

$$f(D) = p_{\text{data}}(\mathbf{x}) \log D(\mathbf{x}) + p_\theta(\mathbf{x}) \log(1 - D(\mathbf{x}))$$

En dérivant par rapport à $D(\mathbf{x})$ et en annulant :

$$\frac{p_{\text{data}}(\mathbf{x})}{D(\mathbf{x})} - \frac{p_\theta(\mathbf{x})}{1 - D(\mathbf{x})} = 0$$

Ce qui donne $p_{\text{data}}(\mathbf{x})(1 - D(\mathbf{x})) = p_\theta(\mathbf{x})D(\mathbf{x})$, d'où le résultat. □

Remarque 2.2 — Vérification. Si $p_\theta = p_{\text{data}}$, le classificateur ne peut pas faire mieux que le hasard : $D^*_\theta(\mathbf{x}) = 1/2$.

3 Réseaux antagonistes génératifs (GAN)

3.1 Architecture et principe

Les réseaux antagonistes génératifs (GAN), introduits par Goodfellow et al. en 2014, mettent en œuvre l'idée du test à deux échantillons via un discriminateur dans un cadre d'apprentissage antagoniste.

Définition 3.1 — Architecture GAN. Un GAN est composé de deux réseaux de neurones qui jouent à un jeu minimax à deux joueurs :

— **Générateur** G_θ : Transforme un vecteur de bruit latent $\mathbf{z} \sim p(\mathbf{z})$ en un échantillon $\mathbf{x} = G_\theta(\mathbf{z})$. $p(\mathbf{z})$ est une distribution simple (par exemple, gaussienne).

— **Discriminateur** D_ϕ : Classifie les échantillons comme "réels" (provenant des données) ou "faux" (provenant du générateur).

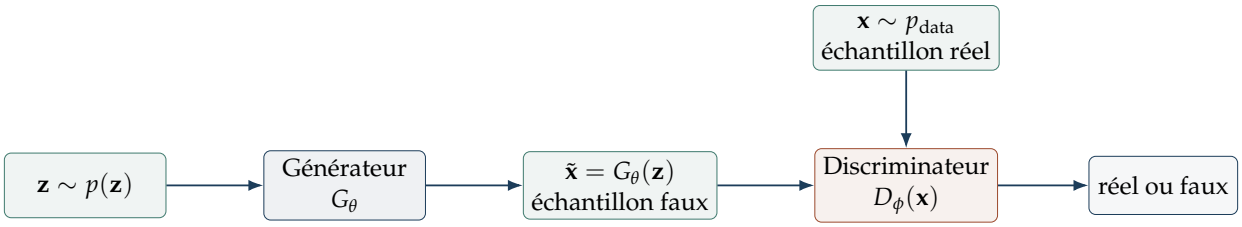


FIGURE 1 – Architecture d'un GAN : le générateur produit des échantillons et le discriminateur apprend à distinguer données réelles et données générées.

Le GAN est un modèle à variable latente dirigé avec une transformation déterministe entre $\mathbf{z}$ et $\mathbf{x}$, donnée par G_θ. Il est similaire, par son idée de transformation d'une variable latente, à un modèle à flot, mais la transformation G_θ n'a pas besoin d'être inversible. La distribution induite sur $\mathbf{x}$ est définie **implicitement** par la transformation du bruit latent. Dans la formulation GAN standard, sa densité n'est généralement pas disponible sous une forme directement calculable.

3.2 Objectif d'entraînement

L'objectif d'entraînement du GAN est :

$$\min_G \max_D V(G,D) = \mathbb{E}_{\mathbf{x}\sim p_{\text{data}}}[\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z}\sim p(\mathbf{z})}[\log(1 - D(G(\mathbf{z})))]$$

DU CONCEPT AU CODE — UNE ÉTAPE GAN

Le code ci-dessous traduit directement l'alternance entre discriminateur et générateur :

```
# 1) apprendre D sur reel et faux
loss_D = bce(D(x_real), ones) + bce(D(G(z).detach()), zeros)
loss_D.backward(); opt_D.step()

# 2) apprendre G a tromper D
loss_G = bce(D(G(z)), ones)
loss_G.backward(); opt_G.step()
```

À observer : pendant la mise à jour de D, on détache les sorties de G ; pendant la mise à jour de G, le gradient traverse D jusqu'au générateur.

Le générateur essaie de minimiser cette valeur (pour que le discriminateur ne puisse pas distinguer ses échantillons), tandis que le discriminateur essaie de la maximiser (pour mieux distinguer).

3.3 Lien avec la divergence de Jensen-Shannon

Avant de suivre les équations, retenez l'idée : si le discriminateur est optimal, le jeu GAN peut être interprété comme une comparaison entre la distribution réelle et la distribution générée. La dérivation suivante formalise cette intuition.

En utilisant le discriminateur optimal D^*_G, nous pouvons réécrire l'objectif :

$$
\begin{aligned}
V(G, D_G^*) &= \mathbb{E}_{\mathbf{x}\sim p_{\text{data}}}\left[\log \frac{p_{\text{data}}(\mathbf{x})}{p_{\text{data}}(\mathbf{x}) + p_G(\mathbf{x})}\right] + \mathbb{E}_{\mathbf{x}\sim p_G}\left[\log \frac{p_G(\mathbf{x})}{p_{\text{data}}(\mathbf{x}) + p_G(\mathbf{x})}\right] \\
&= \mathbb{E}_{\mathbf{x}\sim p_{\text{data}}}\left[\log \frac{p_{\text{data}}(\mathbf{x})}{\frac{p_{\text{data}}(\mathbf{x})+p_G(\mathbf{x})}{2}}\right] + \mathbb{E}_{\mathbf{x}\sim p_G}\left[\log \frac{p_G(\mathbf{x})}{\frac{p_{\text{data}}(\mathbf{x})+p_G(\mathbf{x})}{2}}\right] - \log 4 \\
&= D_{\text{KL}}\left(p_{\text{data}} \,\middle\|\, \frac{p_{\text{data}} + p_G}{2}\right) + D_{\text{KL}}\left(p_G \,\middle\|\, \frac{p_{\text{data}} + p_G}{2}\right) - \log 4 \\
&= 2 \cdot D_{\text{JSD}}(p_{\text{data}} \,\|\, p_G) - \log 4
\end{aligned}
$$

Définition 3.2 — Divergence de Jensen-Shannon. La divergence de Jensen-Shannon est définie comme :

$$D_{\text{JSD}}(p \,\|\, q) = \frac{1}{2}\left(D_{\text{KL}}\left(p \,\middle\|\, \frac{p+q}{2}\right) + D_{\text{KL}}\left(q \,\middle\|\, \frac{p+q}{2}\right)\right)$$

Propriété 3.1 — Propriétés de la divergence JSD.

— $D_{\text{JSD}}(p \,\|\, q) \geq 0$

— $D_{\text{JSD}}(p \,\|\, q) = 0$ si et seulement si $p = q$

— $D_{\text{JSD}}(p \,\|\, q) = D_{\text{JSD}}[q, p]$ (symétrique)

— $\sqrt{D_{\text{JSD}}(p \,\|\, q)}$ satisfait l'inégalité triangulaire → distance de Jensen-Shannon

Pour le générateur optimal G^* et le discriminateur optimal correspondant $D_{G^*}^*$, nous avons :

$$V(G^*, D_{G^*}^*) = -\log 4$$

3.4 Algorithme d'entraînement

L'entraînement des GAN procède par optimisation alternée :

Algorithm 1 Entraînement d'un GAN

Initialiser les paramètres du générateur θ et du discriminateur ϕ

for nombre d'itérations **do**

Échantillonner un minibatch de m points d'entraînement $\{\mathbf{x}^{(1)}, \ldots, \mathbf{x}^{(m)}\}$ de $\mathcal{D}$

Échantillonner un minibatch de m vecteurs de bruit $\{\mathbf{z}^{(1)}, \ldots, \mathbf{z}^{(m)}\}$ de p_z

Mettre à jour le discriminateur par ascent de gradient stochastique :

$$\nabla_\phi V = \frac{1}{m}\nabla_\phi \sum_{i=1}^{m}[\log D_\phi(\mathbf{x}^{(i)}) + \log(1 - D_\phi(G_\theta(\mathbf{z}^{(i)})))]$$

Échantillonner un nouveau minibatch de m vecteurs de bruit $\{\mathbf{z}^{(1)}, \ldots, \mathbf{z}^{(m)}\}$

Mettre à jour le générateur par descente de gradient stochastique :

$$\nabla_\theta V = \frac{1}{m}\nabla_\theta \sum_{i=1}^{m}\log(1 - D_\phi(G_\theta(\mathbf{z}^{(i)})))$$

end for

Remarque 3.1. En pratique, on utilise souvent la **perte non saturante** du générateur : au lieu de minimiser $\log(1 - D(G(\mathbf{z})))$, on maximise $\log D(G(\mathbf{z}))$. Cela fournit des gradients plus forts au début de l'entraînement.

3.5 Architectures détaillées

3.5.1 DCGAN (Deep Convolutional GAN)

Proposition par Radford et al. (2015) :

— **Générateur** : Utilise des couches de convolution transposée (ConvTranspose)
— **Discriminateur** : Utilise des couches de convolution classiques
— **Spécificités** : Batch Normalization après chaque couche, pas de couches fully connected

DU CONCEPT AU CODE — BLOC DCGAN TYPIQUE

Un bloc DCGAN standard combine trois opérations : convolution transposée (upsampling), normalisation, puis activation.

```
# Un bloc DCGAN typique : upsampling + normalisation + activation
nn.ConvTranspose2d(in_ch, out_ch, 4, 2, 1, bias=False),
nn.BatchNorm2d(out_ch),
nn.ReLU(True)
```

À observer : ce même bloc se répète pour doubler la résolution à chaque étape ($4\times4 \to 8\times8 \to 16\times16 \to \cdots$), jusqu'à la dernière couche qui utilise `Tanh` pour produire une image dans $[-1, 1]$ au lieu de `BatchNorm+ReLU`.

3.5.2 StyleGAN

Présenté par Karras et al. (2019), StyleGAN introduit plusieurs innovations :

— **Mapping network** : Transforme le bruit latent en un espace intermédiaire
— **Adaptive Instance Normalization (AdaIN)** : Contrôle le style à différentes échelles
— **Noise injection** : Ajoute du bruit stochastique pour les détails aléatoires
— **Mixing regularization** : Mélange de styles pour éviter les corrélations

3.6 Propriétés et garanties théoriques

Théorème 3.1 — Convergence théorique, informel. Si les mises à jour du générateur sont effectuées dans l'espace des fonctions et que le discriminateur est optimal à chaque étape, alors le générateur est garanti de converger vers la distribution des données.

Cependant, ces hypothèses sont irréalistes en pratique. Dans les implémentations réelles, les pertes du générateur et du discriminateur oscillent continuellement pendant l'entraînement, et il n'existe pas de critère d'arrêt robuste (contrairement à la maximisation de vraisemblance).

3.7 Défis pratiques des GAN

3.7.1 Effondrement des modes

Définition 3.3 — Effondrement des modes. Phénomène où le générateur ne couvre qu'une partie limitée des modes de la distribution réelle : plusieurs régions ou types d'exemples présents dans les données sont peu ou pas générés. Le générateur peut produire des sorties variées à l'intérieur de quelques modes tout en négligeant le reste de la distribution.

Ce problème survient lorsque le générateur découvre qu'il peut tromper le discriminateur en concentrant sa masse sur un sous-ensemble limité d'échantillons ou de modes faciles à faire accepter, plutôt que d'apprendre à générer toute la diversité des données.

3.7.2 Solutions empiriques

Les solutions à l'effondrement des modes sont principalement empiriques :

— **Architectures alternatives** : DCGAN, StyleGAN, etc.
— **Fonctions de perte modifiées** :
  — WGAN (Wasserstein GAN) : Utilise la distance de Wasserstein

  - LSGAN (Least Squares GAN) : Remplace l'entropie croisée par une perte quadratique
  - Hinge GAN : Utilise une perte hinge
- **Termes de régularisation** :
  - Gradient penalty (WGAN-GP)
  - Spectral normalization
  - Consistency regularization
- **Techniques d'entraînement et de diversité** :
  - Minibatch discrimination
  - Unrolling GAN
  - PacGAN

Une ressource pratique très utile est le dépôt GitHub "How to Train a GAN ?" de Soumith Chintala : `https://github.com/soumith/ganhacks`

3.8 Applications

Les GAN ont produit certaines des applications les plus impressionnantes des modèles génératifs :

- **Génération d'images** : Visages humains photoréalistes (StyleGAN)
- **Art génératif** : Œuvres d'art créées par GAN vendues aux enchères
- **Super-résolution** : Amélioration de la résolution d'images (SRGAN)
- **Traduction d'images** : CycleGAN pour transformer des photos en peintures
- **Génération de texte vers image** : StackGAN, AttnGAN
- **Imagerie médicale** : Synthèse d'images médicales pour l'augmentation de données

Exemple 3.1 — Art généré par GAN. En 2018, *Edmond de Belamy*, créé par le collectif Obvious à l'aide d'un GAN, a été vendu chez Christie's à New York pour $432 500 USD, alors que l'estimation avant-vente était de $7 000 à $10 000 USD.

4 MMD-GAN : une alternative basée sur les noyaux

4.1 Maximum Mean Discrepancy (MMD)

Définition 4.1 — Maximum Mean Discrepancy. Le MMD mesure un **écart entre deux distributions** P et Q via leurs plongements moyens dans un espace de Hilbert à noyau reproduisant (RKHS). Lorsque le noyau est **caractéristique**, cet écart sépare les distributions : $\mathrm{MMD}(P, Q) = 0$ implique $P = Q$.

Formellement, soit $\mathcal{H}$ un RKHS avec noyau k. Le plongement moyen (kernel mean embedding) d'une distribution P est :

$$\mu_P = \mathbb{E}_{\mathbf{x}\sim P}[k(\mathbf{x}, \cdot)] \in \mathcal{H}$$

Le MMD au carré entre P et Q est alors :

$$\mathrm{MMD}^2(P, Q) = \|\mu_P - \mu_Q\|^2_{\mathcal{H}}$$

En développant cette expression, nous obtenons :

$$\mathrm{MMD}^2(P, Q) = \mathbb{E}_{\mathbf{x},\mathbf{x}'\sim P}[k(\mathbf{x}, \mathbf{x}')] + \mathbb{E}_{\mathbf{y},\mathbf{y}'\sim Q}[k(\mathbf{y}, \mathbf{y}')] - 2\mathbb{E}_{\mathbf{x}\sim P,\mathbf{y}\sim Q}[k(\mathbf{x}, \mathbf{y})]$$

Exemple 4.1 — Estimation empirique. Étant donné des échantillons $\{\mathbf{x}_i\}_{i=1}^n \sim P$ et $\{\mathbf{y}_j\}_{j=1}^m \sim Q$, une estimation non biaisée du MMD est :

$$\widehat{\mathrm{MMD}}^2 = \frac{1}{n(n-1)} \sum_{i\neq j} k(\mathbf{x}_i, \mathbf{x}_j) + \frac{1}{m(m-1)} \sum_{i\neq j} k(\mathbf{y}_i, \mathbf{y}_j) - \frac{2}{nm} \sum_{i,j} k(\mathbf{x}_i, \mathbf{y}_j)$$

DU CONCEPT AU CODE — ESTIMATION MMD

```
Kxx = kernel(x, x)
Kyy = kernel(y, y)
Kxy = kernel(x, y)
n, m = len(x), len(y)
mmd2 = ((Kxx.sum() - Kxx.diag().sum()) / (n*(n-1))
      + (Kyy.sum() - Kyy.diag().sum()) / (m*(m-1))
      - 2 * Kxy.mean())
```

À observer : pour rester cohérent avec l'estimateur non biaisé écrit juste au-dessus, on retire les termes diagonaux $k(x_i, x_i)$ et $k(y_j, y_j)$. Le MMD ne nécessite aucune densité explicite.

4.2 Choix du noyau

Le choix du noyau k est crucial. Les options courantes incluent :

— **Noyau Gaussien** : $k(\mathbf{x}, \mathbf{y}) = \exp\left(-\frac{\|\mathbf{x}-\mathbf{y}\|^2}{2\sigma^2}\right)$

— **Noyau Laplacien** : $k(\mathbf{x}, \mathbf{y}) = \exp\left(-\frac{\|\mathbf{x}-\mathbf{y}\|}{\sigma}\right)$

— **Noyau polynomial** : $k(\mathbf{x}, \mathbf{y}) = (\mathbf{x}^T\mathbf{y} + c)^d$

— **Noyau multi-échelles** : combinaison de plusieurs noyaux gaussiens

LIMITATION IMPORTANTE DU NOYAU POLYNOMIAL

Un noyau polynomial de degré fini n'est **pas caractéristique en général** sur $\mathbb{R}^d$. Il peut donc arriver que $\mathrm{MMD}(P, Q) = 0$ sans que $P = Q$. Les noyaux gaussien et laplacien usuels sont, sous des conditions classiques, des exemples de noyaux caractéristiques. Le choix du noyau détermine donc quelles différences entre distributions le MMD peut détecter.

4.3 Architecture MMD-GAN

Le MMD-GAN, proposé par Li et al. (2017), remplace le discriminateur binaire des GAN classiques par un critère basé sur le MMD avec un noyau appris.

Définition 4.2 — MMD-GAN. L'objectif d'entraînement du MMD-GAN est :

$$\min_G \max_{k \in \mathcal{K}} \mathrm{MMD}_k(P_{\text{data}}, P_G)$$

où $\mathcal{K}$ est une famille de noyaux (par exemple, des réseaux de neurones produisant des caractéristiques).

Le "discriminateur" est ici remplacé par l'apprentissage du noyau qui maximise la distance MMD entre les distributions réelle et générée. Le générateur, quant à lui, cherche à minimiser cette distance.

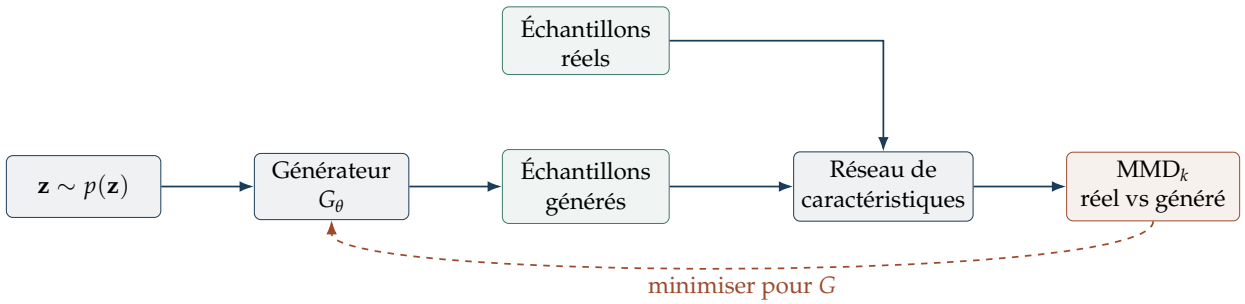


FIGURE 2 – Architecture conceptuelle d'un MMD-GAN : le générateur minimise un écart MMD calculée dans un espace de caractéristiques appris.

4.4 Avantages du MMD-GAN

— **Objectif fondé sur des échantillons** : aucune densité explicite n'est requise.

— **Signal de distribution** : avec un noyau adapté, le MMD compare plusieurs aspects de la distribution et peut aider à détecter une couverture insuffisante.

— **Noyau caractéristique** : dans ce cas, $\mathrm{MMD}(P, Q) = 0$ seulement si les distributions coïncident.

— **Stabilité potentielle** : certains réglages de MMD-GAN peuvent être plus stables que le GAN classique, mais ce n'est pas une garantie générale et cela dépend du noyau, du critique et de l'optimisation.

4.5 Défis du MMD-GAN

— **Choix de la famille de noyaux** : La performance dépend crucialement de la famille $\mathcal{K}$. En pratique, on utilise souvent des réseaux de neurones pour apprendre une représentation, puis un noyau RBF sur cette représentation.

— **Coût de calcul** : Le calcul du MMD a une complexité $O(n^2)$ où n est la taille du batch, ce qui peut être prohibitif pour de grands batches.

— **Sensibilité aux hyperparamètres** : Comme pour les GAN, il existe de nombreuses variations et réglages délicats.

— **Compromis qualité–couverture** : le résultat dépend du noyau, du critique appris et des hyperparamètres ; aucune amélioration systématique de la diversité ou de la qualité n'est garantie.

5 Absence de vraisemblance dans les modèles implicites

5.1 Caractéristiques fondamentales

Les modèles génératifs implicites, comme les GAN et MMD-GAN, partagent une caractéristique fondamentale : ils sont principalement spécifiés par une procédure de génération. La distribution induite existe, mais sa densité $p_\theta(\mathbf{x})$ n'est généralement pas disponible sous une forme directement calculable. On peut néanmoins échantillonner à partir du modèle.

Propriété 5.1 — Modèles implicites. Un modèle génératif implicite est défini par une procédure d'échantillonnage :

$$\mathbf{z} \sim p(\mathbf{z}), \quad \mathbf{x} = G_\theta(\mathbf{z})$$

sans nécessairement pouvoir calculer $p_\theta(\mathbf{x})$.

5.2 Avantages de l'absence de vraisemblance

— **Flexibilité architecturale** : N'importe quelle architecture de réseau de neurones définissant une procédure d'échantillonnage est valide. Le générateur peut être un réseau profond complexe sans contraintes d'inversibilité.

— **Vitesse d'échantillonnage** : Dans un GAN standard, la génération se fait par un passage du bruit latent dans le générateur. Elle est donc hautement parallélisable, contrairement à l'échantillonnage ancestral exact de nombreux modèles autorégressifs, qui reste séquentiel selon l'ordre de factorisation.

— **Qualité visuelle** : Les GAN ont historiquement obtenu une excellente qualité perceptuelle sur plusieurs tâches d'image. Cette observation dépend toutefois de l'architecture, du jeu de données, du protocole d'évaluation et de la période considérée ; elle ne constitue pas une supériorité générale des modèles implicites.

— **Distribution implicitement définie** : La distribution $p_\theta(\mathbf{x})$ peut être très complexe et ne pas avoir de forme analytique simple, ce qui n'est pas un problème.

— **Représentations latentes riches** : L'espace latent peut présenter des directions utiles ou sémantiquement interprétables, mais cette organisation n'est pas garantie sans structure ou objectifs adaptés.

5.3 Inconvénients de l'absence de vraisemblance

— **Pas d'évaluation de la vraisemblance** : Dans un modèle implicite standard, $\log p_\theta(\mathbf{x})$ n'est généralement pas directement disponible. L'évaluation doit donc s'appuyer sur d'autres critères, qui mesurent des propriétés différentes et possèdent leurs propres limites.
— **Entraînement difficile** : L'optimisation antagoniste est notoirement instable et sensible aux hyperparamètres.
— **Peu de garanties théoriques en pratique** : Bien que des théorèmes de convergence existent sous des hypothèses idéales, ils ne s'appliquent pas aux implémentations réelles.
— **Évaluation subjective** : La qualité des modèles est souvent évaluée par des métriques heuristiques ou par évaluation humaine, ce qui est moins rigoureux que la vraisemblance.
— **Manque d'interprétabilité** : Il est difficile de comprendre ce que le modèle a appris.

6 Évaluation des modèles génératifs implicites

6.1 Métriques quantitatives

6.1.1 Inception Score (IS)

Définition 6.1 — Inception Score. L'Inception Score utilise un classificateur pré-entraîné (Inception) pour évaluer :
— La **qualité** : $p(y|\mathbf{x})$ doit être concentrée sur une classe (confiance élevée)
— La **diversité** : $p(y)$ doit être proche de l'uniforme

$$\mathrm{IS} = \exp\left(\mathbb{E}_{\mathbf{x}\sim p_G}[D_{\mathrm{KL}}(p(y \mid \mathbf{x}) \,\|\, p(y))]\right)$$

6.1.2 Fréchet Inception Distance (FID)

Le FID ne compare pas directement les pixels. Il compare des représentations extraites par un réseau pré-entraîné, puis résume chaque ensemble d'images par une moyenne et une covariance.

Définition 6.2 — FID. Le FID compare les statistiques des caractéristiques extraites par un réseau Inception :

$$\mathrm{FID} = \|\mu_r - \mu_g\|^2 + \mathrm{Tr}\left(\Sigma_r + \Sigma_g - 2(\Sigma_r\Sigma_g)^{1/2}\right)$$

où (μ_r, Σ_r) et (μ_g, Σ_g) sont les moyennes et covariances des caractéristiques pour les échantillons réels et générés.

6.1.3 Kernel Inception Distance (KID)

Le KID compare, comme le FID, des représentations extraites par un réseau Inception, mais utilise un estimateur de **MMD** au lieu d'ajuster une gaussienne aux caractéristiques. Une forme courante emploie le noyau polynomial cubique

$$k(\mathbf{u}, \mathbf{v}) = \left(\frac{1}{d}\mathbf{u}^\top\mathbf{v} + 1\right)^3.$$

L'un de ses avantages est de disposer d'un estimateur non biaisé de MMD^2 pour un échantillon fini. En revanche, ce noyau polynomial n'est pas caractéristique en général : le KID est donc une métrique pratique d'évaluation en espace Inception, mais il ne faut pas interpréter $\mathrm{KID} = 0$ comme une preuve universelle d'égalité entre toutes les distributions possibles.

FID OU KID ?

FID : très répandu, simple à comparer à la littérature, mais son estimateur est biaisé à taille d'échantillon finie et repose sur une approximation gaussienne des caractéristiques.
KID : fondé sur le MMD et estimable sans biais avec l'estimateur en U ; particulièrement utile comme métrique complémentaire lorsque le nombre d'échantillons est limité.

6.1.4 Précision et rappel

Ces métriques désentrelacent qualité et diversité :

— **Precision** : Proportion d'échantillons générés qui ressemblent aux données réelles
— **Recall** : Proportion d'échantillons réels couverts par le modèle

6.1.5 Density et Coverage

La précision et le rappel améliorés ont notamment été étudiés par Kynkäänniemi et al. (2019). Les métriques **Density** et **Coverage** ont ensuite été proposées par Naeem et al. (2020) pour mieux caractériser fidélité et couverture.

— **Density** : Moyenne du nombre de voisins réels pour chaque échantillon généré
— **Coverage** : Proportion d'échantillons réels qui ont au moins un voisin généré

6.2 Comparaison des familles de modèles génératifs

TABLE 1 – Comparaison des différentes familles de modèles génératifs

Modèle	Vraisemblance	Échantillonnage	Stabilité	Qualité	Diversité
Autorégressif	Explicite	Séquentiel	Généralement stable	Bonne	Dépend du modèle et du décodage
VAE	ELBO (approx.)	Rapide	Stable	Moyenne	Bonne
Flow	Explicite	Rapide	Stable	Bonne	Bonne
GAN	Implicite	Rapide et parallélisable	Sensible au réglage	Souvent élevée	Variable ; effondrement possible
MMD-GAN	Implicite	Rapide et parallélisable	Variable	Bonne à élevée	Variable selon noyau et entraînement

LECTURE PRUDENTE DU TABLEAU

Ces qualificatifs sont **indicatifs et non universels**. Pour un modèle autorégressif, la diversité dépend notamment de la distribution apprise et, pour les séquences discrètes, de la stratégie de décodage (température, top-k, top-p, etc.). De même, la qualité et la diversité d'un GAN varient fortement selon l'architecture, le jeu de données et l'entraînement.

7 Résumé et perspectives

7.1 Points clés à retenir

1. **Limites de la vraisemblance** : Une vraisemblance élevée n'implique pas nécessairement de bons échantillons, et inversement.
2. **Tests à deux échantillons** : Ils fournissent un cadre théorique pour comparer des distributions sans utiliser les densités, uniquement des échantillons.
3. **GAN** : Ils mettent en œuvre ce principe via un jeu antagoniste entre un générateur et un discriminateur, et sont équivalents à minimiser la divergence de Jensen-Shannon sous conditions idéales.
4. **Défis pratiques** : L'entraînement des GAN est difficile (instabilité, effondrement des modes), nécessitant de nombreuses astuces empiriques.

5. **MMD-GAN** : Une alternative plus stable qui utilise la distance MMD avec un noyau appris.
6. **Modèles implicites** : Ils offrent une grande flexibilité et une excellente qualité d'échantillons au prix de l'absence de vraisemblance calculable et d'un entraînement délicat.
7. **Évaluation** : Des métriques complémentaires (FID, KID, IS, précision/rappel) sont nécessaires pour évaluer ces modèles.

7.2 Orientations actuelles de la recherche

La recherche sur les modèles génératifs implicites est très active et explore plusieurs directions :

— **Architectures GAN modernes** : StyleGAN, BigGAN et leurs descendants ont amélioré la qualité, le contrôle et la stabilité sur certaines tâches d'image.

— **Objectifs alternatifs** :
  — Wasserstein GAN (distance de Wasserstein)
  — LSGAN (perte quadratique)
  — f-GAN (divergences de f)
  — Energy-based GAN

— **Régularisation** :
  — Gradient penalty
  — Spectral normalization
  — Consistency regularization

— **Évaluation** : Développement de meilleures métriques que la vraisemblance pour évaluer les modèles implicites.

— **Suite du cours** : les modèles de diffusion seront étudiés en S12 et les modèles hybrides en S14 ; ils ne sont donc pas développés ici.

8 Références essentielles

— Goodfellow, I. et al. (2014). *Generative Adversarial Nets*. NeurIPS.

— Radford, A., Metz, L. et Chintala, S. (2016). *Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks*. ICLR.

— Karras, T. et al. (2019). *A Style-Based Generator Architecture for Generative Adversarial Networks*. CVPR.

— Gretton, A. et al. (2012). *A Kernel Two-Sample Test*. Journal of Machine Learning Research.

— Li, C.-L. et al. (2017). *MMD GAN : Towards Deeper Understanding of Moment Matching Network*. NeurIPS.

— Bińkowski, M. et al. (2018). *Demystifying MMD GANs*. ICLR. (Introduction du KID.)

— Heusel, M. et al. (2017). *GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium*. NeurIPS. (FID.)

— Kynkäänniemi, T. et al. (2019). *Improved Precision and Recall Metric for Assessing Generative Models*. NeurIPS.

— Naeem, M. F. et al. (2020). *Reliable Fidelity and Diversity Metrics for Generative Models*. ICML. (Density et Coverage.)

9 Synthèse de la semaine 10 et transition vers S11

CE QU'IL FAUT RETENIR

— Un modèle implicite définit une **procédure d'échantillonnage** sans nécessiter une densité calculable.
— Les GAN apprennent par un **jeu antagoniste** entre générateur et discriminateur.
— Le MMD fournit une autre façon de comparer deux distributions à partir d'échantillons.
— L'absence de vraisemblance apporte de la flexibilité, mais rend l'**évaluation** plus délicate.
— Les métriques comme FID, KID, IS et précision/rappel cherchent à mesurer des aspects complémentaires de qualité et de diversité.

TRANSITION VERS LA S11

*Après les modèles implicites, la S11 introduira le **score matching**. L'idée centrale sera différente : au lieu d'apprendre directement une densité ou un discriminateur, on apprendra le **gradient du log de la densité**. Cette notion constituera le pont vers les modèles de diffusion étudiés en S12.*