SEMAINE 11

Score Matching

Hyvärinen score · Denoising score matching · Langevin

S11 — OBJECTIFS (CE QUE VOUS SAUREZ FAIRE À LA FIN)

1. Définir la fonction de score $\mathbf{s}(x) = \nabla_x \log p(x)$ et expliquer son intérêt.
2. Comprendre le score matching de Hyvärinen et sa relation à la divergence de Fisher.
3. Expliquer pourquoi le score matching classique devient coûteux en haute dimension.
4. Comprendre le denoising score matching et le lien entre bruit, score et débruitage.
5. Expliquer le principe du **sliced score matching**, pourquoi les projections aléatoires remplacent le calcul complet du Jacobien et sous quelles conditions cette approximation reste informative.
6. Utiliser un score appris pour générer avec la dynamique de Langevin.
7. Expliquer le lien conceptuel **EBM** $\leftrightarrow$ **score** $\leftrightarrow$ **diffusion**.

MISE EN CONTEXTE — DE S9–S10 À S11

En S9, un EBM modélisait $p_\theta(x) \propto e^{-E_\theta(x)}$, mais la constante de normalisation compliquait l'apprentissage. En S10, les modèles implicites ont montré qu'on peut éviter complètement la vraisemblance. En S11, nous suivons une troisième voie : apprendre directement le ***gradient du log de la densité****, appelé* ***score****.*

QUESTION CENTRALE DE LA SEMAINE

Peut-on apprendre la direction vers les régions de forte probabilité sans connaître ni normaliser explicitement la densité $p(x)$?

LIEN AVEC LE PLAN DU COURS

Le plan de S11 met l'accent sur trois idées : **Hyvärinen score**, **denoising score matching** et **lien EBM** $\leftrightarrow$ **diffusion**. Le sliced score matching est conservé ici comme complément utile pour comprendre les solutions au problème de scalabilité.

1 Pourquoi représenter une distribution par son score ?

1.1 Des densités aux champs de vecteurs

Les modèles vus jusque-là représentent une distribution de plusieurs manières : densité explicite (autorégressifs, flows), densité non normalisée (EBM), ou procédure d'échantillonnage (GAN). Une autre possibilité consiste à modéliser directement le **score**.

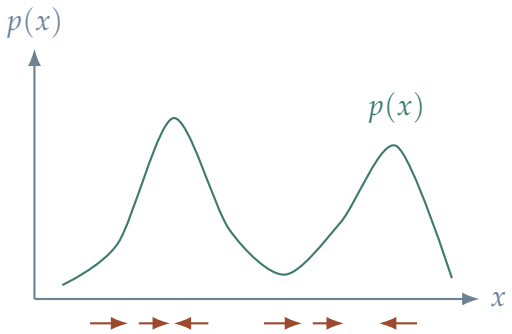
Famille	Représentation	Limite principale
Autorégressifs	$p_\theta(x) = \prod_i p_\theta(x_i \mid x_{<i})$	génération séquentielle
Flows	changement de variables exact	inversibilité / Jacobien
EBM	$p_\theta(x) \propto e^{-E_\theta(x)}$	fonction de partition
GAN	$x = G_\theta(z)$	pas de densité explicite

DÉFINITION — FONCTION DE SCORE

Pour une densité différentiable $p(x)$,

$$\boxed{\mathbf{s}(x) = \nabla_x \log p(x) = \frac{\nabla_x p(x)}{p(x)}}.$$

Le score est un champ de vecteurs : en chaque point, il indique localement la direction de plus forte augmentation de la log-densité.



1.2 Pourquoi le score contourne la fonction de partition

Pour un EBM,

$$p_\theta(x) = \frac{e^{-E_\theta(x)}}{Z(\theta)}.$$

Alors

$$\nabla_x \log p_\theta(x) = \nabla_x[-E_\theta(x) - \log Z(\theta)] = -\nabla_x E_\theta(x),$$

car $Z(\theta)$ ne dépend pas de x.

> LIEN EBM ↔ SCORE
>
> Le score supprime automatiquement la constante de normalisation. Pour un EBM, apprendre le paysage d'énergie ou apprendre son gradient sont donc deux points de vue étroitement liés.

> POURQUOI LE SCORE EST INTÉRESSANT
>
> — il ne dépend pas de la constante de normalisation ;
> — sous des conditions appropriées, il détermine la log-densité à une constante additive près ;
> — il fournit directement une direction pour l'échantillonnage par gradient ;
> — un réseau peut modéliser $\mathbf{s}_\theta(x)$ sans contrainte d'inversibilité.

2 Score matching classique : Hyvärinen

2.1 La divergence de Fisher

Pour rapprocher le score du modèle du score réel, on considère

$$D_F(p\|q) = \mathbb{E}_{x\sim p}\left[\frac{1}{2}\|\nabla_x \log p(x) - \nabla_x \log q(x)\|^2\right].$$

Le problème apparent est que $\nabla_x \log p_{\text{data}}(x)$ est inconnu : nous ne disposons que d'échantillons.

2.2 L'astuce de Hyvärinen

> CONDITIONS DE RÉGULARITÉ POUR L'INTÉGRATION PAR PARTIES
>
> La transformation de la divergence de Fisher en objectif de score matching suppose notamment que les densités et les champs considérés soient suffisamment réguliers et que les termes de bord s'annulent. Intuitivement, on exige que $p(x)$ décroisse assez vite aux frontières de son support (ou à l'infini) pour que l'intégration par parties ne laisse pas de terme résiduel.

Sous ces hypothèses,

$$D_F(p\|q) = \mathbb{E}_{x\sim p}\left[\frac{1}{2}\|\nabla_x \log q(x)\|^2 + \operatorname{tr}\left(\nabla_x^2 \log q(x)\right)\right] + \text{constante}.$$

Le terme contenant le score inconnu de p disparaît de l'objectif optimisé.

DÉRIVATION ADMISE

Dans ce cours, on **admet** le passage complet de la divergence de Fisher à l'objectif de Hyvärinen. Le calcul ci-dessous montre seulement l'étape essentielle : le terme croisé contenant $\nabla \log p$ est éliminé par intégration par parties.

POURQUOI L'INTÉGRATION PAR PARTIES CHANGE TOUT

En développant la divergence de Fisher, on obtient un terme croisé

$$\mathbb{E}_p[(\nabla \log p)^T (\nabla \log q)].$$

Comme $p(x)\nabla \log p(x) = \nabla p(x)$, une intégration par parties transforme ce terme en

$$-\mathbb{E}_p[\mathrm{tr}(\nabla_x^2 \log q(x))],$$

ce qui élimine le score inconnu de la distribution des données. C'est le cœur mathématique du score matching de Hyvärinen.

OBJECTIF DU SCORE MATCHING

Pour un modèle de score $\mathbf{s}_\theta(x)$,

$$\boxed{J_{\mathrm{SM}}(\theta) = \mathbb{E}_{x\sim p_{\mathrm{data}}}\left[\frac{1}{2}\|\mathbf{s}_\theta(x)\|^2 + \mathrm{tr}(\nabla_x \mathbf{s}_\theta(x))\right].}$$

On peut donc apprendre le score à partir des seules données, sans connaître explicitement $p_{\mathrm{data}}(x)$.

LE PROBLÈME DE SCALABILITÉ

Le terme $\mathrm{tr}(\nabla_x \mathbf{s}_\theta(x))$ demande l'information diagonale du Jacobien du champ de score. En dimension D, un calcul naïf requiert un coût proportionnel à D, ce qui devient prohibitif pour des images de grande taille. **Solution :** modifier l'objectif pour éviter ce calcul complet.

3 Denoising Score Matching (DSM)

3.1 Ajouter du bruit pour rendre la cible accessible

On perturbe une donnée propre x par un bruit gaussien :

$$\tilde{x} \sim q_\sigma(\tilde{x} \mid x) = \mathcal{N}(x, \sigma^2 I).$$

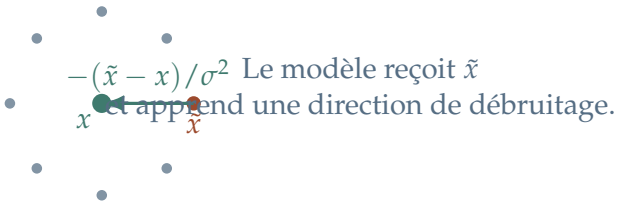
Le score conditionnel du bruit gaussien est connu exactement :

$$\nabla_{\tilde{x}} \log q_\sigma(\tilde{x} \mid x) = -\frac{\tilde{x} - x}{\sigma^2}.$$

OBJECTIF DU DENOISING SCORE MATCHING

$$\boxed{J_{\mathrm{DSM}}(\theta) = \mathbb{E}_{x\sim p_{\mathrm{data}}}\mathbb{E}_{\tilde{x}\sim\mathcal{N}(x,\sigma^2 I)}\left[\frac{1}{2}\left\|\mathbf{s}_\theta(\tilde{x}) + \frac{\tilde{x} - x}{\sigma^2}\right\|^2\right].}$$

Le réseau apprend donc à prédire le vecteur qui ramène une observation bruitée vers la région où se trouve la donnée propre.



DU CONCEPT AU CODE — DSM EN QUATRE LIGNES

```
noise = torch.randn_like(x)
x_tilde = x + sigma * noise
target = -noise / sigma
loss = 0.5 * ((score_net(x_tilde) - target)**2).mean()
```

À observer : aucune densité $p(x)$ n'est calculée ; la cible est construite directement à partir du bruit ajouté.

POURQUOI DSM EST SCALABLE

Contrairement au score matching classique, l'objectif DSM ne nécessite pas la trace complète du Jacobien. Une paire $(x, \tilde{x})$ fournit directement une cible supervisée $-(\tilde{x}-x)/\sigma^2$. L'entraînement ressemble donc à une régression vectorielle standard.

IDÉE DU THÉORÈME DSM

Le score de la distribution bruitée satisfait

$$\nabla_{\tilde{x}} \log p_\sigma(\tilde{x}) = \mathbb{E}_{x|\tilde{x}}[\nabla_{\tilde{x}} \log q_\sigma(\tilde{x} \mid x)].$$

Ainsi, prédire le score conditionnel du bruit au sens quadratique conduit au même optimum que prédire le score marginal de la distribution bruitée.

3.2 Lien avec le débruitage optimal : formule de Tweedie

Pour un bruit gaussien,

$$\boxed{\mathbb{E}[x \mid \tilde{x}] = \tilde{x} + \sigma^2 \nabla_{\tilde{x}} \log p_\sigma(\tilde{x}).}$$

Cette formule montre que connaître le score de la distribution bruitée revient à savoir dans quelle direction corriger une observation bruitée.

LECTURE DE LA FORMULE DE TWEEDIE

On **admet** ici la dérivation complète. À partir de Bayes et du noyau gaussien, on obtient

$$\nabla_{\tilde{x}} \log p_\sigma(\tilde{x}) = -\frac{\tilde{x} - \mathbb{E}[x \mid \tilde{x}]}{\sigma^2},$$

puis, en réarrangeant,

$$\mathbb{E}[x \mid \tilde{x}] = \tilde{x} + \sigma^2 \nabla_{\tilde{x}} \log p_\sigma(\tilde{x}).$$

Interprétation : le score indique la correction moyenne optimale à appliquer à une observation bruitée pour revenir vers une donnée plausible.

LIMITE DU DSM À UN SEUL NIVEAU DE BRUIT

DSM estime le score de la distribution bruitée p_σ, pas directement celui de p_{data}. Un petit σ rapproche p_σ des données, mais les régions de faible densité restent difficiles à couvrir correctement.

4 Sliced Score Matching

Le score matching classique contient le terme

$$\mathrm{tr}(\nabla_x \mathbf{s}_\theta(x)),$$

c'est-à-dire la trace du Jacobien du champ de score. En grande dimension, former explicitement ce Jacobien peut devenir coûteux. Le **sliced score matching** évite ce calcul complet en étudiant seulement des **projections directionnelles** du score.

4.1 Pourquoi projeter le score ?

Soit $v \in \mathbb{R}^D$ un vecteur aléatoire, par exemple

$$v \sim \mathcal{N}(0, I).$$

Au lieu de comparer directement deux vecteurs de score en dimension D, on compare leurs projections scalaires :

$$v^T \nabla_x \log p(x) \qquad \text{et} \qquad v^T \mathbf{s}_\theta(x).$$

IDÉE DE LA PROJECTION

Une seule projection ne décrit qu'une direction. Mais si les directions v sont tirées aléatoirement avec une distribution suffisamment riche, répéter ces projections explore l'ensemble de l'espace. On remplace ainsi un objet vectoriel de grande dimension par une succession de problèmes scalaires moins coûteux.

Une forme de divergence de Fisher projetée est

$$\overline{D_F}(p\|q) = \mathbb{E}_v \mathbb{E}_{x\sim p}\left[\frac{1}{2}\left(v^T \nabla_x \log p(x) - v^T \nabla_x \log q(x)\right)^2\right].$$

POURQUOI LES PROJECTIONS RESTENT INFORMATIVES ?

Si la distribution de v possède une covariance non dégénérée, par exemple $\mathbb{E}[vv^T] = I$, alors les projections aléatoires sondent toutes les directions. Intuitivement, si deux champs de score diffèrent, cette différence apparaîtra avec probabilité positive dans au moins certaines projections.

Dans ce cours, on **admet** le résultat théorique reliant cette divergence projetée à l'objectif pratique ci-dessous.

4.2 Objectif pratique

Après le même type d'intégration par parties que pour le score matching classique, on obtient, à une constante près :

$$\boxed{J_{\mathrm{SSM}}(\theta) = \mathbb{E}_{x\sim p_{\mathrm{data}}} \mathbb{E}_v \left[\frac{1}{2}(v^T \mathbf{s}_\theta(x))^2 + v^T(\nabla_x \mathbf{s}_\theta(x))v\right].}$$

Le second terme est une **dérivée directionnelle**. Il peut être évalué par autodifférentiation sans former explicitement toute la matrice jacobienne.

LECTURE TERME PAR TERME

$$\frac{1}{2}(v^T \mathbf{s}_\theta(x))^2$$

pénalise l'amplitude du score projeté dans la direction v, tandis que

$$v^T(\nabla_x \mathbf{s}_\theta(x))v$$

mesure comment cette projection varie localement dans la même direction.

APERÇU ALGORITHMIQUE — SLICED SCORE MATCHING

À chaque itération :

1. échantillonner une donnée $x \sim p_{\text{data}}$;
2. échantillonner une direction v ;
3. calculer $v^T \mathbf{s}_\theta(x)$;
4. calculer la dérivée directionnelle $v^T(\nabla_x \mathbf{s}_\theta(x))v$;
5. mettre à jour θ à partir de la somme des deux termes.

Une ou quelques directions par donnée peuvent déjà fournir un estimateur stochastique utile ; augmenter leur nombre réduit la variance mais augmente le coût.

Méthode	Cible principale	Idée de calcul
Score matching	score de p_{data}	trace complète du Jacobien
Denoising score matching	score de p_σ	cible explicite grâce au bruit
Sliced score matching	score de p_{data}	projections aléatoires et dérivées directionnelles

CE QUE LE SLICED SCORE MATCHING NE RÉSOUT PAS

Il réduit le coût lié au calcul du Jacobien, mais il ne supprime pas les autres difficultés du score matching : estimation dans les régions de faible densité, sensibilité à la qualité des données et besoin de conditions de régularité pour les dérivations théoriques.

5 Du score à la génération : dynamique de Langevin

Une fois $\mathbf{s}_\theta(x) \approx \nabla_x \log p(x)$ appris, il faut encore transformer ce champ de vecteurs en procédure de génération. Une convention courante pour l'algorithme de Langevin non ajusté est :

$$\boxed{x_{t+1} = x_t + \frac{\epsilon}{2}\mathbf{s}_\theta(x_t) + \sqrt{\epsilon}\, z_t, \qquad z_t \sim \mathcal{N}(0, I).}$$

CONVENTION DU FACTEUR $\frac{1}{2}$

Le facteur $\frac{1}{2}$ dépend de la convention choisie pour paramétrer le temps et l'amplitude du bruit. Une écriture équivalente très fréquente est

$$x_{t+1} = x_t + \eta\, \mathbf{s}_\theta(x_t) + \sqrt{2\eta}\, z_t.$$

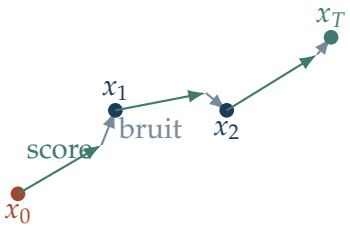
Les deux formes coïncident en posant $\epsilon = 2\eta$. L'important est de conserver une convention cohérente entre le terme de dérive et le terme de bruit.

STATIONNARITÉ ET CONDITIONS IDÉALES

La distribution cible est stationnaire pour la dynamique continue de Langevin sous des hypothèses de régularité appropriées sur p et son score. Pour la discrétisation ci-dessus, un pas fini introduit une erreur de discrétisation : on obtient une approximation de la distribution cible, sauf si l'on ajoute une correction de type Metropolis–Hastings.

En outre, un bon mélange suppose que les régions pertinentes du support puissent être reliées par la dynamique ; des supports fortement séparés ou des barrières de faible densité peuvent conduire à un mélange très lent.

Intuitivement, le terme de score attire les particules vers les régions probables tandis que le bruit maintient l'exploration.



Le score attire vers les zones de forte densité ;
le bruit évite une simple descente déterministe.

DU CONCEPT AU CODE — UN PAS DE LANGEVIN

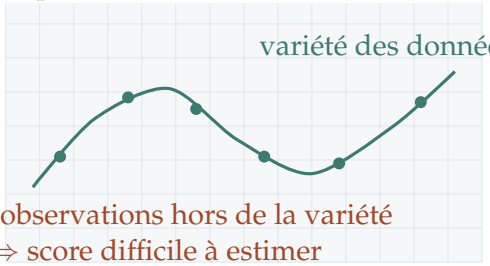
```
for _ in range(T):
    z = torch.randn_like(x)
    x = x + 0.5 * eps * score_net(x) + eps**0.5 * z
```

À observer : la génération n'utilise toujours pas $p(x)$ directement ; elle n'a besoin que du score appris.

6 Défis sur les données réelles

6.1 Hypothèse des variétés

Les données de haute dimension occupent souvent une structure de dimension intrinsèque plus faible. Hors de cette région, le score peut être mal estimé car les données y sont rares.



Deux difficultés en découlent : les régions périphériques donnent des estimations de forte variance, et la chaîne de Langevin peut mélanger très lentement entre deux modes séparés par une région de faible densité. Si le support effectif est fortement déconnecté, une dynamique locale peut même ne pas passer d'une composante à l'autre en pratique.

— **Support de faible dimension :** le score est surtout appris là où des données sont observées.

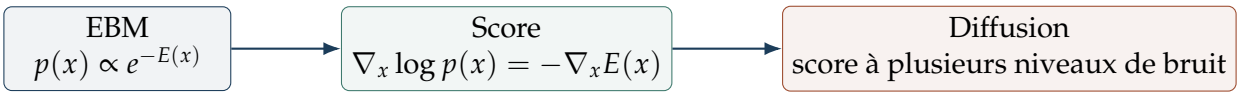
— **Faible densité :** peu d'observations impliquent une forte variance de l'estimation.

— **Mélange entre modes :** une chaîne locale peut rester longtemps piégée autour d'un même mode.

POURQUOI PLUSIEURS NIVEAUX DE BRUIT ?

Un bruit fort remplit davantage l'espace et facilite le déplacement entre les modes ; un bruit faible permet ensuite d'affiner les détails près des données. Cette idée conduit naturellement aux modèles de diffusion de S12.

7 Lien EBM ↔ score ↔ diffusion



FIL CONCEPTUEL

— **EBM :** représente la densité par une énergie, mais la normalisation est difficile.
— **Score matching :** dérive le log de la densité et élimine la constante de normalisation.
— **Diffusion :** apprend ces scores pour une suite de distributions de plus en plus bruitées, puis inverse progressivement le bruit pour générer.

8 Synthèse de la semaine 11 et transition vers S12

À RETENIR

— Le score $\nabla_x \log p(x)$ indique localement la direction vers les régions de plus forte densité.
— Hyvärinen permet d'apprendre ce score sans connaître la densité des données.
— DSM remplace le calcul coûteux du Jacobien par une tâche de débruitage à cible explicite.
— Sliced score matching utilise des projections pour réduire le coût de calcul.
— Langevin transforme un score appris en mécanisme d'échantillonnage.
— Le passage à plusieurs niveaux de bruit prépare directement les modèles de diffusion.

APERÇU DE LA S12

En S12, nous étudierons le **processus direct** qui ajoute progressivement du bruit, le **processus inverse** qui le retire, puis les **DDPM**. Le score appris en S11 devient alors l'un des outils mathématiques centraux de la génération progressive.