SEMAINE 13

Modèles hiérarchiques

Latents multi-niveaux · génération multi-échelle · StyleGAN · diffusion hiérarchique

S13 — OBJECTIFS (CE QUE VOUS SAUREZ FAIRE À LA FIN)

1. Expliquer le rôle de **latents multi-niveaux** dans une représentation hiérarchique.
2. Comprendre la **génération multi-échelle**, du global vers le local.
3. Définir le **modèle hiérarchique aléatoire (RHM)** : alphabet, arbre, règles de production et distribution conditionnelle.
4. Comprendre comment des expériences forward–backward révèlent des changements corrélés, une longueur de corrélation et une transition d'échelle.
5. Relier ces idées à des architectures réelles : **StyleGAN** et, comme aperçu multi-échelle, les **modèles de diffusion latente**.

MISE EN CONTEXTE — DE S12 À S13

En S12, nous avons vu qu'un modèle de diffusion construit une donnée progressivement, en passant du bruit à une structure cohérente. La S13 pose une question plus profonde : ***les données elles-mêmes possèdent-elles plusieurs niveaux d'organisation ?*** *Si oui, un bon modèle génératif doit être capable de représenter et de produire ces niveaux du global vers le local.*

QUESTION CENTRALE DE LA SEMAINE

Comment représenter et générer une donnée complexe en organisant ses facteurs latents à plusieurs niveaux et plusieurs échelles ?

LIEN AVEC LE PLAN DU COURS

Cette semaine couvre les éléments prévus pour S13 : **latents multi-niveaux**, **génération multi-échelle**, **StyleGAN** et **diffusion hiérarchique**. L'étude du RHM et des expériences forward–backward sert ici de cadre théorique pour comprendre pourquoi une organisation hiérarchique est pertinente.

1 Pourquoi des modèles hiérarchiques ?

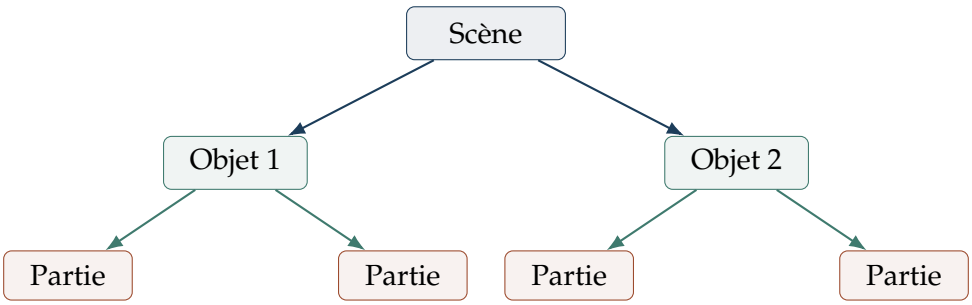
Les données naturelles sont de très haute dimension : une image RGB 256×256 contient 196 608 valeurs, et une longue séquence de texte admet un nombre gigantesque de configurations possibles. Pourtant, ces données sont apprenables. Une explication centrale est qu'elles ne sont pas arbitraires : elles présentent une **structure hiérarchique**.

COMPOSITIONNALITÉ HIÉRARCHIQUE

Des caractéristiques globales peuvent être décomposées en caractéristiques plus locales. Pour une image, on peut raisonner ainsi :

$$\text{scène} \to \text{objets} \to \text{parties} \to \text{textures/pixels}.$$

Chaque niveau décrit une échelle différente de la donnée.



Le niveau supérieur fixe une structure globale ; les niveaux inférieurs ajoutent progressivement les détails.

LECTURE POUR L'ÉTUDIANT

Le mot *hiérarchique* ne signifie pas seulement « réseau profond ». Il signifie ici que des variables ou caractéristiques de haut niveau organisent des variables plus locales. C'est cette dépendance entre niveaux que nous voulons modéliser.

2 Latents multi-niveaux : le modèle hiérarchique aléatoire

Le modèle hiérarchique aléatoire (RHM) est un modèle théorique conçu pour rendre explicite la composition hiérarchique des données. Il ne représente pas une architecture utilisée telle quelle en pratique : il sert de **modèle contrôlé** pour raisonner sur les dépendances entre niveaux.

DÉFINITION FORMELLE DU RHM

On considère :

— un alphabet $\mathcal{A} = \{a_1, \ldots, a_v\}$ de v symboles ;

— un arbre de profondeur L et de facteur de branchement s ;

— une racine $h^{(L)}$ tirée, dans le cas le plus simple, uniformément parmi v classes/symboles ;

— pour chaque symbole parent $a \in \mathcal{A}$, un ensemble $\mathcal{R}_a$ de m règles de production, chacune transformant a en un s-uplet de symboles du niveau inférieur.

Si $(b_1, \ldots, b_s) \in \mathcal{R}_a$, une écriture simple de la loi de production est

$$P(h_1 = b_1, \ldots, h_s = b_s \mid h_{\text{parent}} = a) = \begin{cases} 1/m, & (b_1, \ldots, b_s) \in \mathcal{R}_a, \\ 0, & \text{sinon.} \end{cases}$$

Dans le RHM, les règles sont échantillonnées aléatoirement parmi les v^s productions possibles, avec les contraintes du modèle. La génération répète cette opération du sommet vers les feuilles.

DIMENSIONS ET ÉCHELLES

Après L niveaux, le nombre de variables visibles aux feuilles est

$$\boxed{d = s^L.}$$

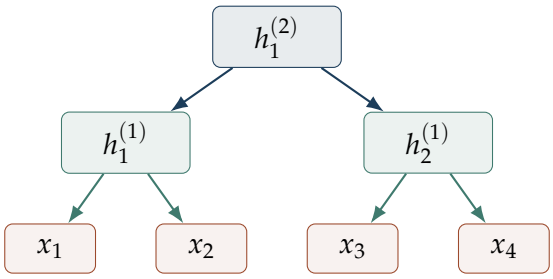
Un latent situé ℓ niveaux au-dessus des feuilles contrôle un bloc de l'ordre de

$$\boxed{s^\ell}$$

jetons visibles. C'est ce qui donne au modèle une notion explicite d'échelle : plus le latent est profond dans l'arbre, plus son influence est globale.

RHM : ORGANISATION DES NIVEAUX

— niveau $\ell = 0$: jetons observables ;
— niveaux intermédiaires : latents locaux ou régionaux ;
— niveau $\ell = L$: latent racine, associé à une structure globale ou une classe ;
— chaque symbole d'un niveau choisit une règle de production vers le niveau inférieur.



Exemple : $L = 2$, $s = 2$; latents internes → observations aux feuilles.

La génération procède du haut vers le bas : on choisit la racine, puis une règle de production à chaque niveau jusqu'aux feuilles. Ainsi, la génération est naturellement **multi-échelle** : les décisions globales sont prises avant les détails locaux.

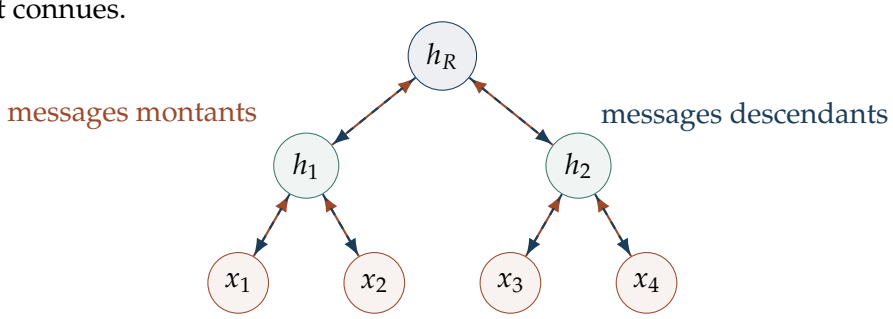
DU CONCEPT AU CODE — GÉNÉRATION HIÉRARCHIQUE MINIMALE

```
h = sample_root()
for level in reversed(range(L)):
    h = expand_with_rule(h, level)
x = leaves(h)
```

À observer : le code traduit uniquement l'idée « global → local » ; il ne cherche pas à implémenter tout le RHM.

2.1 Corrélations et débruitage exact

Deux feuilles proches dans l'arbre partagent des ancêtres communs : elles ne sont donc pas indépendantes. Le RHM permet aussi un débruitage exact par **Belief Propagation** lorsque les règles du modèle sont connues.



3 Diffusion sur une hiérarchie et transition de phase

VOCABULAIRE DE PHYSIQUE STATISTIQUE — LECTURE MINIMALE

*Les notions ci-dessous sont utilisées comme **outils descriptifs**. Il n'est pas nécessaire d'avoir suivi un cours de physique statistique.*

— ϵ *: niveau de corruption dans le processus de bruit simplifié ;*
— ϵ^* *: valeur critique de corruption où le comportement du latent global change brutalement ;*
— ξ *: **longueur de corrélation**, c'est-à-dire l'échelle typique sur laquelle deux changements restent*

corrélés ;

— ν : ***exposant critique***, *qui décrit la vitesse de croissance de ξ près de la transition ;*

— χ : ***susceptibilité dynamique***, *ici une mesure agrégée de l'étendue des changements corrélés ;*

— t^* *: temps d'inversion où l'on observe le maximum de corrélation collective dans le protocole forward–backward.*

*Une **transition de phase** signifie ici qu'une propriété globale — par exemple la capacité à reconstruire la classe/racine — change de régime autour d'un seuil critique, alors que les caractéristiques locales peuvent évoluer plus progressivement.*

Le contenu source considère deux façons de bruiter les données hiérarchiques : un ϵ-process et une diffusion par masquage. Dans le premier cas, on réduit progressivement la confiance accordée au jeton original ; dans le second, des jetons passent progressivement à un symbole [MASK].

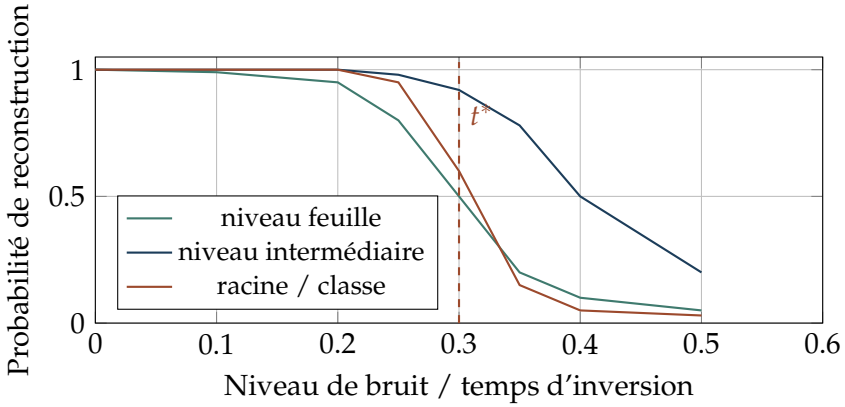
DEUX PROCESSUS DE BRUIT

Pour le ϵ-process, si la valeur correcte est a dans un vocabulaire de taille v :

$$\nu_\uparrow(h_i^{(0)} = a) = 1 - \epsilon + \frac{\epsilon}{v}, \qquad \nu_\uparrow(h_i^{(0)} = a') = \frac{\epsilon}{v}.$$

Pour la diffusion par masquage, chaque jeton non masqué reste inchangé ou devient [MASK] selon un taux β_t.

Une observation importante est qu'il peut exister un niveau de bruit critique où la reconstruction du latent global change brutalement : c'est une **transition de phase**. Les niveaux locaux et globaux ne réagissent donc pas de la même manière au bruit.



4 Signature expérimentale : changements corrélés et susceptibilité

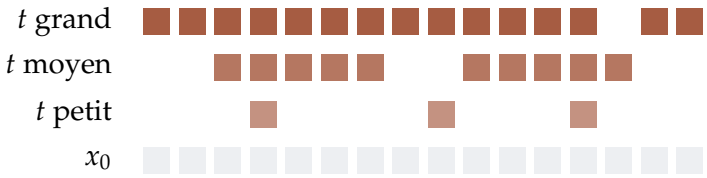
Dans une expérience **forward–backward**, on part d'une donnée x_0, on la bruite jusqu'à un temps t, puis on applique le processus inverse pour reconstruire $\hat{x}_0(t)$. On observe alors quelles positions ont changé.

VARIABLE DE CHANGEMENT

$$\sigma_i(t) = \begin{cases} +1 & \text{si } x_{0,i} \neq \hat{x}_{0,i}(t), \\ -1 & \text{si } x_{0,i} = \hat{x}_{0,i}(t). \end{cases}$$

La corrélation entre deux changements s'écrit

$$C_{ij}(t) = \langle \sigma_i(t)\sigma_j(t) \rangle - \langle \sigma_i(t) \rangle \langle \sigma_j(t) \rangle.$$



Les changements deviennent progressivement des blocs corrélés.

SUSCEPTIBILITÉ DYNAMIQUE

La susceptibilité résume la taille typique des blocs qui changent ensemble :

$$\chi(t) = \frac{\sum_i \sum_j \mathcal{C}_{ij}(t)}{\sum_i \mathcal{C}_{ii}(t)}.$$

Un pic de $\chi(t)$ indique que des changements se produisent simultanément sur une grande échelle.

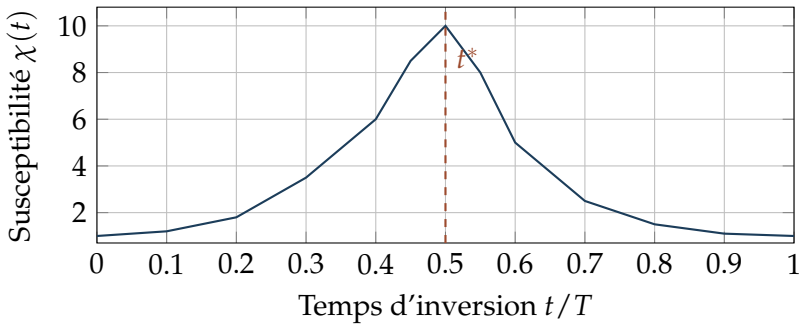
La **longueur de corrélation** ξ mesure jusqu'à quelle distance deux changements de jetons restent statistiquement liés. Près du niveau de bruit critique ϵ^*, la théorie prédit

$$\boxed{\xi(\epsilon) \sim |\epsilon - \epsilon^*|^{-\nu}},$$

où $\nu > 0$ est l'exposant critique. Lorsque $\epsilon \to \epsilon^*$, cette expression signifie que la taille caractéristique des régions qui changent ensemble augmente fortement.

LECTURE DE LA TRANSITION

Loin de ϵ^*, les modifications concernent surtout des blocs limités. Près de ϵ^*, des latents de plus haut niveau deviennent incertains : modifier un tel latent peut affecter simultanément un grand nombre de feuilles. Le pic de χ et la croissance de ξ sont donc deux signatures du même changement d'échelle.



QUELQUES VALEURS QUANTITATIVES À RETENIR

Pour les expériences RHM publiées avec $v = 32$, $m = 8$, $s = 2$ et $L = 9$:

— le nombre de feuilles vaut $d = s^L = 2^9 = 512$ jetons ;

— pour le processus ϵ, la transition est observée vers $\epsilon^* \simeq 0.74$;

— l'exposant de longueur de corrélation rapporté pour ces paramètres est $\nu \simeq 1.78$;

— pour la diffusion par masquage, le pic apparaît vers $t^* \simeq 0.3\,T$;

— la susceptibilité atteint alors un maximum d'environ 3 sur la figure publiée pour la diffusion par masquage ; pour le processus ϵ, le pic est d'environ 8. Ces deux dernières valeurs sont des **lectures graphiques approximatives**, pas des constantes universelles.

La taille d'un bloc n'est pas unique : dans l'arbre, un latent à profondeur ℓ au-dessus des feuilles influence s^ℓ jetons, soit ici $2, 4, 8, \ldots, 512$. La susceptibilité est donc mieux comprise comme une **taille effective de changements corrélés** que comme la taille fixe d'un bloc.

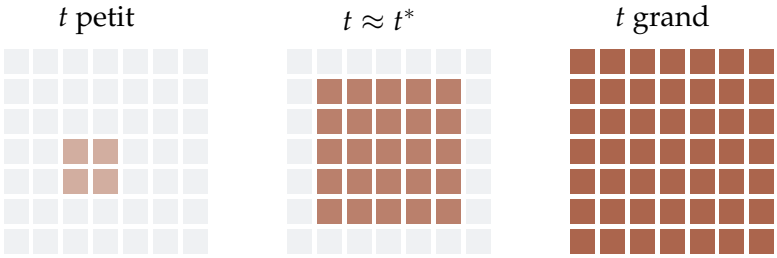
DU CONCEPT AU CODE — ESTIMER UNE SUSCEPTIBILITÉ

```
C = torch.cov(changes.T)        # correlations entre positions
chi = C.sum() / torch.diag(C).sum()
```

À observer : une grande valeur de `chi` signifie que de nombreuses positions changent de manière coordonnée.

5 Validation sur texte et images

Le contenu source rapporte que la même phénoménologie apparaît sur des données réelles. Pour le texte, des modèles de langage à diffusion masquée sur WikiText2 montrent des blocs de plusieurs jetons changeant ensemble. Pour les images, les patches peuvent être analysés dans un espace de représentation ; près d'un temps critique, des régions entières changent simultanément.



Des détails locaux aux changements de blocs puis à la restructuration globale.

INTERPRÉTATION PRUDENTE

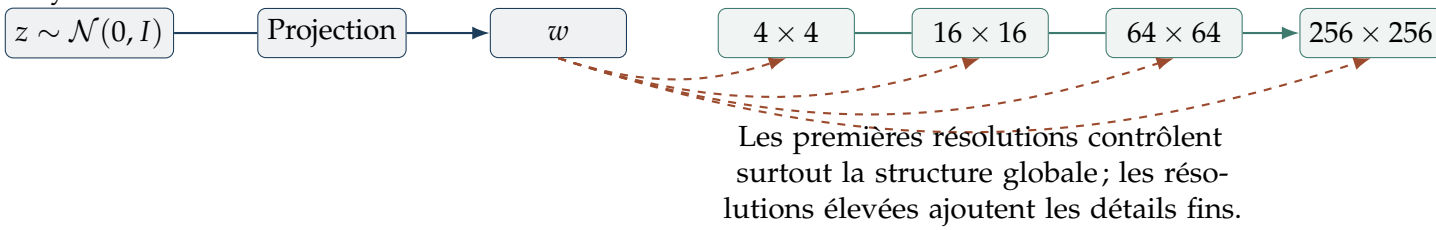
Ces expériences suggèrent une organisation multi-échelle des changements, mais elles ne signifient pas qu'un modèle de diffusion contient explicitement un arbre latent identique au RHM. Le RHM sert de modèle théorique pour interpréter une phénoménologie hiérarchique observée.

6 StyleGAN : génération explicite du grossier vers le fin

StyleGAN constitue un exemple architectural de génération multi-échelle. Un latent initial z est d'abord transformé par un réseau de projection

$$z \longmapsto w,$$

puis des transformations affines de w produisent des **styles** injectés à différentes résolutions du réseau de synthèse.



6.1 AdaIN : injecter le style à une échelle donnée

Dans le StyleGAN original, une transformation affine de w fournit des paramètres de style qui contrôlent les statistiques des cartes de caractéristiques. L'opération AdaIN peut être résumée par

$$\mathrm{AdaIN}(x_i, y) = y_{s,i} \frac{x_i - \mu(x_i)}{\sigma(x_i)} + y_{b,i},$$

où x_i est une carte de caractéristiques et $(y_{s,i}, y_{b,i})$ sont les paramètres issus du style.

INTERPRÉTATION

Le réseau ne fournit pas le même style à toutes les résolutions. Les couches grossières influencent davantage pose, disposition ou forme globale ; les couches fines agissent davantage sur textures et détails. Il s'agit d'une tendance architecturale, pas d'une séparation sémantique parfaite.

6.2 Injection de bruit : variation stochastique locale

StyleGAN injecte aussi des cartes de bruit indépendantes dans les couches de synthèse :

$$x_i' = x_i + b_i \eta, \qquad \eta \sim \mathcal{N}(0, I),$$

avec un coefficient appris b_i par canal. Ce bruit fournit au générateur une source de variation locale qui n'a pas besoin d'être codée dans w : placement de cheveux, pores, petites irrégularités, etc.

STYLEGAN ET STYLEGAN2

AdaIN est caractéristique du StyleGAN original. StyleGAN2 remanie ce mécanisme et remplace notamment AdaIN par une modulation/démodulation des poids afin de réduire certains artefacts. Pour S13, l'objectif est de comprendre le principe multi-échelle, pas de détailler toutes les variantes.

CORRESPONDANCE CONCEPTUELLE

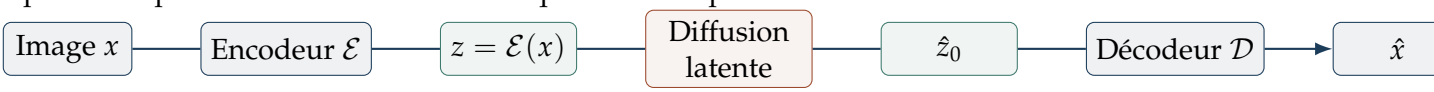
Le parallèle avec une hiérarchie est le suivant :

$$\text{structure globale} \rightarrow \text{formes intermédiaires} \rightarrow \text{textures et détails.}$$

Le vecteur w influence plusieurs échelles, mais il ne faut pas l'identifier littéralement aux latents d'un arbre RHM.

7 Diffusion latente : aperçu multi-échelle

Les modèles de diffusion latente (LDM) appliquent la diffusion dans un espace latent appris par un autoencodeur plutôt que directement dans l'espace des pixels. Ils ne constituent pas à eux seuls un « arbre hiérarchique » comme le RHM : ils illustrent ici comment une représentation comprimée peut séparer une partie de la structure sémantique du détail pixel.



7.1 Première étape : apprendre l'autoencodeur

L'autoencodeur doit comprimer l'image tout en conservant les détails perceptuellement importants. Une écriture pédagogique de sa perte est

$$\boxed{\mathcal{L}_{\text{AE}} = \lambda_{\text{rec}}\mathcal{L}_{\text{rec/percept}} + \lambda_{\text{adv}}\mathcal{L}_{\text{adv}} + \lambda_{\text{reg}}\mathcal{L}_{\text{reg}}.}$$

— $\mathcal{L}_{\text{rec/percept}}$: reconstruction, souvent complétée par une distance perceptuelle ;
— $\mathcal{L}_{\text{adv}}$: terme antagoniste permettant de préserver des détails visuels fins ;
— $\mathcal{L}_{\text{reg}}$: régularisation de l'espace latent, par exemple de type KL ou quantification vectorielle selon la variante.

DIMENSION DU LATENT

Si l'image a une taille $H \times W$ et que l'encodeur réduit chaque dimension spatiale d'un facteur f, alors

$$z \in \mathbb{R}^{(H/f)\times(W/f)\times c}.$$

Par exemple, avec $H = W = 512$ et $f = 8$, la diffusion travaille sur une grille spatiale 64×64 au lieu de 512×512 ; le nombre de canaux c dépend de l'architecture.

7.2 Deuxième étape : diffuser dans z

Une fois l'autoencodeur entraîné, le modèle de diffusion apprend le processus de bruit/débruitage dans l'espace latent :

$$z_t = \sqrt{\bar{\alpha}_t}\, z_0 + \sqrt{1 - \bar{\alpha}_t}\, \epsilon.$$

Le décodeur transforme ensuite le latent débruité en image.

POURQUOI C'EST UTILE

— **Efficacité** : la diffusion opère dans un espace spatialement plus compact ;

— **Préservation sémantique** : l'autoencodeur cherche à conserver l'information perceptuellement pertinente ;

— **Reconstruction détaillée** : le décodeur remet le latent dans l'espace pixel.

DU CONCEPT AU CODE — DIFFUSION DANS UN LATENT

```
z = encoder(x)
z_t = add_noise(z, t)
noise_hat = denoiser(z_t, t)
x_hat = decoder(reverse_step(z_t, noise_hat, t))
```

À observer : la diffusion travaille sur une représentation comprimée ; le décodage pixel intervient seulement après le débruitage latent.

PORTÉE DE S13

Nous présentons ici seulement les mécanismes nécessaires pour comprendre l'idée multi-échelle. L'hybridation détaillée autoencodeur/VAE + diffusion et les modèles génératifs modernes à grande échelle restent au programme de S14.

8 Références essentielles

Références

[1] F. Cagnetta et al., *How Deep Neural Networks Learn Compositional Data : The Random Hierarchy Model*, Physical Review X, 14, 031001, 2024.

[2] A. Sclocchi, A. Favero, M. Wyart, *A Phase Transition in Diffusion Models Reveals the Hierarchical Nature of Data*, PNAS, 122(1), e2408799121, 2025.

[3] A. Sclocchi et al., *Probing the Latent Hierarchical Structure of Data via Diffusion Models*, Journal of Statistical Mechanics : Theory and Experiment, 084005, 2025.

[4] T. Karras, S. Laine, T. Aila, *A Style-Based Generator Architecture for Generative Adversarial Networks*, CVPR, 2019.

[5] T. Karras et al., *Analyzing and Improving the Image Quality of StyleGAN*, CVPR, 2020.

[6] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, B. Ommer, *High-Resolution Image Synthesis with Latent Diffusion Models*, CVPR, 2022.

9 Synthèse de la semaine 13 et transition vers S14

CE QU'IL FAUT RETENIR

— Les données naturelles peuvent présenter une organisation **hiérarchique** et **multi-échelle**.

— Des **latents multi-niveaux** représentent des facteurs globaux, intermédiaires et locaux.

— Le RHM fournit un cadre théorique simple pour étudier ces dépendances.

— Les expériences forward–backward peuvent révéler des changements corrélés, un pic de susceptibilité et une transition d'échelle.

— StyleGAN contrôle plusieurs échelles via la projection $z \to w$, l'injection de styles et une source de bruit stochastique.

— Les LDM entraînent d'abord un autoencodeur puis réalisent la diffusion dans son espace latent compact ; leur hybridation détaillée sera reprise en S14.

TRANSITION VERS LA S14

*Après avoir étudié plusieurs familles séparément, la S14 examinera leur **hybridation**. Nous verrons comment combiner VAE et diffusion, flots et diffusion, puis comment ces idées s'inscrivent dans les modèles génératifs modernes à grande échelle.*

APERÇU DE LA S14

VAE + diffusion | Flow + diffusion | Scaling et foundation models