SEMAINE 14

Hybridation et modèles modernes

VAE + diffusion · flot + diffusion · Lois d'échelle · Modèles génératifs de fondation

S14 — OBJECTIFS (CE QUE VOUS SAUREZ FAIRE À LA FIN)

1. Expliquer pourquoi on cherche à **hybrider** plusieurs familles de modèles génératifs.
2. Décrire le principe d'un **modèles de diffusion latente** : autoencodeur, diffusion latente, conditionnement et guidage.
3. Définir l'**appariement de flot** : chemin de probabilités, champ de vecteurs conditionnel, perte de régression et génération par EDO.
4. Interpréter une **loi d'échelle** reliant performance, taille du modèle, quantité de données et calcul.
5. Définir un **modèles génératifs de fondation**, identifier ses compromis pratiques et discuter brièvement ses principaux enjeux éthiques.

MISE EN CONTEXTE — DE S13 À S14

En S13, nous avons étudié les représentations hiérarchiques et la génération multi-échelle. La S14 élargit cette perspective : les systèmes modernes ne reposent plus nécessairement sur une seule famille de modèles. Ils combinent souvent plusieurs mécanismes — représentation latente, diffusion, transport continu et pré-entraînement massif — afin d'obtenir un meilleur compromis entre qualité, coût, stabilité et contrôle.

QUESTION CENTRALE DE LA SEMAINE

Comment combiner les forces de plusieurs modèles génératifs et les faire évoluer vers des systèmes modernes à grande échelle ?

LIEN AVEC LE PLAN DU COURS

Cette semaine couvre exactement les quatre axes prévus pour S14 : **VAE + diffusion**, **flot + diffusion**, **lois d'échelle** et **modèles génératifs de fondation**. L'objectif n'est plus d'étudier une nouvelle famille isolée, mais de comprendre comment les idées vues depuis S6 se combinent dans des architectures modernes.

1 Pourquoi hybrider les modèles génératifs ?

Chaque famille de modèles génératifs a ses forces et ses faiblesses. L'hybridation vise à combiner plusieurs mécanismes complémentaires plutôt qu'à demander à une seule architecture de résoudre tous les problèmes.

Famille	Forces	Faiblesses	Hybridation avec
VAE	Inférence, espace latent	Qualité d'échantillons parfois limitée	GAN, flot, diffusion
Flot	Vraisemblance exacte	Contraintes d'architecture	VAE, diffusion
GAN	Qualité visuelle	Instabilité, effondrement des modes	VAE
Diffusion	Qualité, stabilité	Échantillonnage itératif	VAE, flot

IDÉE À RETENIR

Une hybridation est utile lorsque les composants jouent des rôles différents. Par exemple, un autoencodeur peut réduire la dimension tandis qu'un modèle de diffusion apprend la distribution complexe dans cet espace latent.

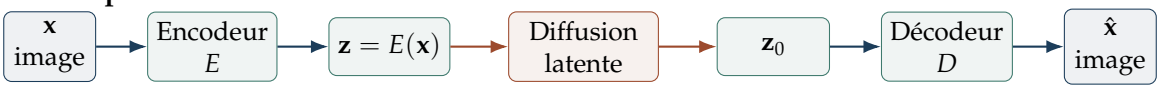
2 VAE + diffusion : modèles de diffusion latente

2.1 Pourquoi hybrider VAE et diffusion ?

Les VAE apprennent un espace latent compact et structuré. Les modèles de diffusion excellent dans la modélisation de distributions complexes. Leur combinaison permet d'effectuer la diffusion dans un espace beaucoup plus petit que l'espace des pixels.

> MODÈLES DE DIFFUSION LATENTE (LDM)
>
> Un LDM est composé de :
>
> 1. un **autoencodeur** (souvent de type VAE) qui projette une image $\mathbf{x}$ vers un latent $\mathbf{z}$ de plus basse dimension ;
> 2. un **modèle de diffusion** qui apprend à générer dans cet espace latent ;
> 3. un **décodeur** qui reconstruit l'image finale à partir du latent généré.

Avant de lire le schéma, suivez le trajet en deux idées : **compresser d'abord**, puis **générer dans l'espace compressé**.



Le modèle de diffusion ne travaille pas directement sur tous les pixels : il opère sur une représentation latente compressée.

2.2 Comment l'autoencodeur est-il entraîné ?

Le premier étage du LDM est appris avant le modèle de diffusion. L'objectif est de compresser l'image tout en conservant les structures perceptuellement importantes. Une écriture pédagogique de la perte est

$$\boxed{\mathcal{L}_{\text{AE}} = \lambda_{\text{rec}}\,\mathcal{L}_{\text{rec/percept}} + \lambda_{\text{adv}}\,\mathcal{L}_{\text{adv}} + \lambda_{\text{reg}}\,\mathcal{L}_{\text{reg}}.}$$

La composante de reconstruction peut inclure une distance perceptuelle ; un terme antagoniste peut aider à préserver les détails fins ; la régularisation du latent dépend de la variante, par exemple une régularisation KL pour un autoencodeur de type VAE ou une quantification vectorielle dans une variante discrète.

> DIMENSION DU LATENT
>
> Si l'image a une taille $H \times W$ et que l'encodeur réduit chaque dimension spatiale d'un facteur f, alors
>
> $$z \in \mathbb{R}^{(H/f)\times(W/f)\times c}.$$
>
> Pour une image 512×512 et $f = 8$, on travaille par exemple sur une grille 64×64 avec quelques canaux latents au lieu de diffuser directement dans tous les pixels.

2.3 Conditionnement par attention croisée

Pour une génération conditionnelle, une représentation de la condition c — par exemple un plongement de texte — est injectée dans le U-Net latent. Un mécanisme fréquent est l'**attention croisée** : les caractéristiques visuelles intermédiaires produisent les requêtes Q, tandis que la condition produit les clés et valeurs K, V :

$$\text{Attn}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right) V.$$

Le débruiteur peut ainsi modifier ses prédictions en fonction du contenu de la consigne textuelle ou d'une autre condition.

GUIDAGE SANS CLASSIFICATEUR — RAPPEL DE S12

À l'échantillonnage, on peut combiner une prédiction non conditionnelle et une prédiction conditionnelle :

$$\hat{\epsilon} = \epsilon_\theta(z_t, t, \varnothing) + w\left[\epsilon_\theta(z_t, t, c) - \epsilon_\theta(z_t, t, \varnothing)\right].$$

Le paramètre w renforce le respect de la condition mais peut réduire la diversité lorsqu'il est trop grand.

2.4 Avantages des LDM

— **Efficacité** : l'espace latent est bien plus petit que l'espace des pixels ; par exemple $64 \times 64 \times 4$ au lieu de $512 \times 512 \times 3$.

— **Focalisation sur la sémantique** : l'autoencodeur compresse l'information perceptuellement importante, tandis que la diffusion modélise la structure latente.

— **Qualité** : cette approche permet une génération de haute qualité tout en réduisant le coût de la diffusion.

2.5 Exemple : Stable Diffusion

Dans l'exemple classique présenté ici, une image 512×512 est encodée dans un latent de taille $4 \times 64 \times 64$. Un U-Net réalise ensuite le débruitage dans cet espace latent et peut être conditionné par une représentation textuelle.

DU CONCEPT AU CODE — DIFFUSION DANS UN LATENT

```
z = encoder(x)                    # compression
z_t = add_noise(z, eps, t)        # diffusion dans z
noise_hat = unet(z_t, t, cond)    # prediction du bruit
x_hat = decoder(z_denoised)       # retour vers l'image
```

À observer : le principe important est que la diffusion agit sur z, pas directement sur x.

3 Flot + diffusion : appariement de flot

3.1 Idée générale : apprendre un transport continu

L'**appariement de flot** entraîne un champ de vecteurs dépendant du temps afin de transporter une distribution simple p_0 vers la distribution des données p_1. La génération suit ensuite une **équation différentielle ordinaire (EDO)** :

$$\boxed{\frac{dx_t}{dt} = v_\theta(x_t, t), \qquad t \in [0, 1].}$$

Si $x_0 \sim p_0$ et si le champ est appris correctement, l'intégration de cette EDO conduit à un échantillon distribué approximativement selon p_1.

3.2 Chemin conditionnel

Pour rendre l'apprentissage supervisable, on construit d'abord un chemin conditionnel reliant un bruit x_0 à une donnée x_1. Un exemple simple est l'interpolation linéaire

$$\boxed{x_t = (1 - t)x_0 + tx_1,}$$

dont la vitesse conditionnelle est

$$\boxed{u_t(x_t \mid x_0, x_1) = x_1 - x_0.}$$

D'autres chemins sont possibles, notamment des chemins gaussiens ou issus du transport optimal.

PERTE D'APPARIEMENT DE FLOT

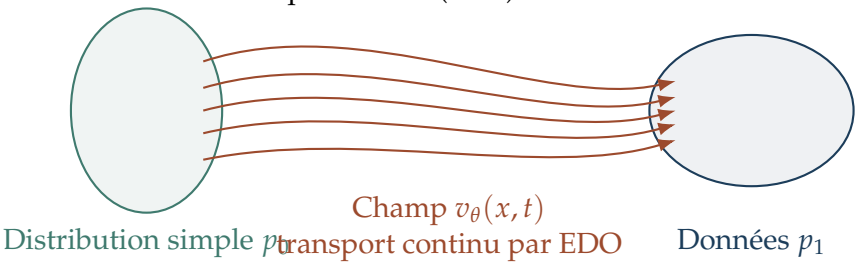
On entraîne le réseau à régresser vers le champ de vitesse conditionnel :

$$\mathcal{L}_{\mathrm{FM}}(\theta) = \mathbb{E}_{t,x_0,x_1}\left[\|v_\theta(x_t,t) - u_t(x_t \mid x_0,x_1)\|^2\right].$$

Le point important est que la cible u_t est connue sur le chemin choisi : on peut donc apprendre le champ sans simuler toute la trajectoire d'une dynamique stochastique pendant l'entraînement.

3.3 Pourquoi parle-t-on de *appariement de flot conditionnel* ?

Le champ marginal idéal dépend seulement de (x_t, t), mais sa forme est généralement inconnue. Le résultat central de Flow Matching permet d'apprendre ce champ marginal en régressant vers des champs **conditionnels** faciles à calculer. Dans ce cours, on admet cette égalité d'optimum ; la dérivation complète est donnée dans Lipman et al. (2023).



3.4 Appariement de flot versus diffusion

	Diffusion	**appariement de flot**
Objet appris	score/bruit ou dynamique inverse	champ de vitesse $v_\theta(x,t)$
Dynamique de génération	souvent stochastique (SDE/chaîne) ou ODE associée	EDO déterministe une fois le champ fixé
Chemin d'entraînement	imposé par le processus de bruit	famille plus générale de chemins conditionnels
Perte typique	débruitage / appariement de score	régression sur une vitesse cible

NUANCE IMPORTANTE

Il ne faut pas opposer trop fortement l'appariement de flot et la diffusion. Les chemins de diffusion constituent un cas particulier de chemins de probabilités utilisables en appariement de flot. La différence tient surtout à l'objet de régression et au cadre de transport continu utilisé pour l'apprentissage.

DU CONCEPT AU CODE — ENTRAÎNEMENT CONCEPTUEL

```
t = torch.rand(batch, 1)
x0 = torch.randn_like(x1)
xt = (1 - t) * x0 + t * x1
u = x1 - x0
loss = ((v_model(xt, t) - u)**2).mean()
```

À observer : le modèle apprend une vitesse locale ; à la génération, on intègre ensuite $dx/dt = v_\theta(x,t)$ avec un solveur d'EDO.

4 Lois d'échelle

4.1 Qu'est-ce qu'une loi d'échelle ?

Les **scaling laws** décrivent empiriquement comment la performance d'un modèle évolue lorsque l'on augmente ses ressources : nombre de paramètres, quantité de données et budget de calcul. Kaplan et al. (2020) ont montré, pour les modèles de langage, des relations de type loi de puissance entre perte, taille de modèle, données et calcul. Hoffmann et al. (2022) ont ensuite montré qu'à budget de calcul fixé, il faut équilibrer davantage la croissance de la taille du modèle et celle du nombre de tokens d'entraînement.

> FORME SCHÉMATIQUE D'UNE LOI D'ÉCHELLE
>
> Une relation empirique peut être résumée par
>
> $$\text{Perte}(N, D, C) \approx aN^{-\alpha} + bD^{-\beta} + cC^{-\gamma},$$
>
> où N représente le nombre de paramètres, D la taille des données et C le budget de calcul. Cette formule doit être lue comme un **modèle empirique de tendance**, pas comme une loi universelle valable pour toute architecture.

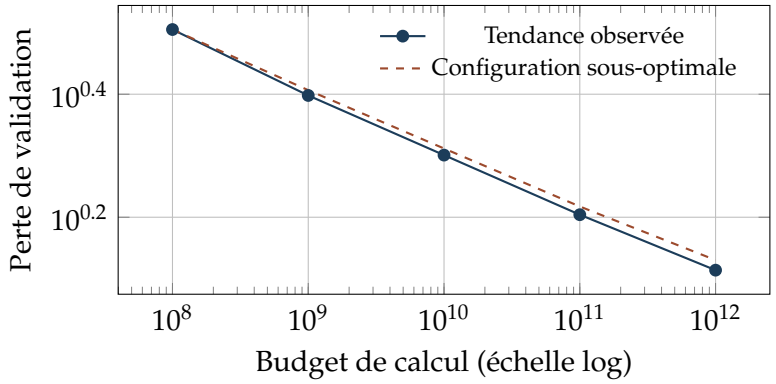
4.2 Lois d'échelle pour les modèles de diffusion

Le contenu source souligne trois idées :

— la perte de validation peut décroître selon une loi de puissance avec le budget de calcul ;

— taille du modèle, données et représentation des données doivent être dimensionnées conjointement ;

— pour un budget donné, une configuration peut être plus efficace qu'une autre.



4.3 Implications pratiques

— **Allocation des ressources** : choisir une taille de modèle cohérente avec le budget disponible.

— **Prédiction de performance** : extrapoler prudemment une tendance avant un entraînement plus coûteux.

— **Comparaison** : étudier l'efficacité relative de plusieurs configurations à budget comparable.

TABLE 1 – Compromis selon le budget — exemple théorique du contenu source

Budget	Taille modèle	Données	Perte prédite
10^9 TFlops	100M	10B jetons	2.5
10^{10} TFlops	300M	30B jetons	2.0
10^{11} TFlops	1B	100B jetons	1.6
10^{12} TFlops	3B	300B jetons	1.3

5 Modèles génératifs de fondation

5.1 Définition

MODÈLE FONDATION GÉNÉRATIF

Un modèle fondation est un modèle pré-entraîné à grande échelle sur des données massives et diverses, puis réutilisable ou adaptable pour de nombreuses tâches. Dans le contexte génératif, il sert de base commune à plusieurs capacités de génération et de compréhension.

5.2 Exemples cités dans le contenu

Le contenu source mentionne plusieurs familles contemporaines :

— **GPT-4, Claude, Gemini** : modèles de langage et systèmes multimodaux ;

— **CLIP, DINO** : modèles de représentation utiles dans des pipelines vision ou vision-langage ;

— **Stable Diffusion, DALL-E, Imagen, FLUX** : génération texte-image ;

— **Sora, Veo, Runway** : génération vidéo ;

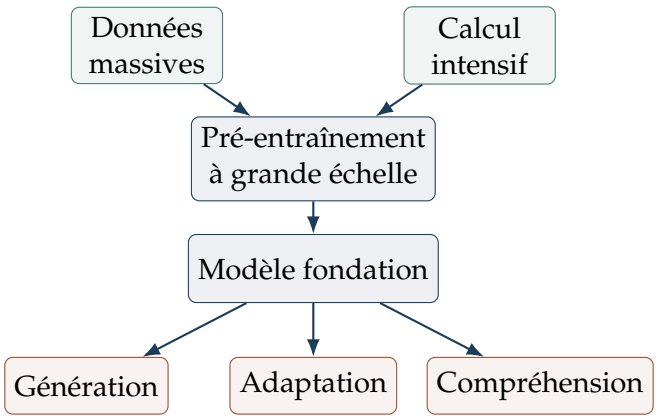
— **SAM** : modèle fondation pour la segmentation d'images.

NUANCE IMPORTANTE

Tous les modèles fondation cités ne sont pas eux-mêmes des modèles génératifs. Par exemple, CLIP, DINO ou SAM sont surtout des modèles de représentation ou de perception, mais ils peuvent participer à des systèmes génératifs modernes.

5.3 Caractéristiques communes

1. **Pré-entraînement à grande échelle** sur de vastes corpus ;
2. **architectures profondes modernes**, souvent fondées sur des transformeurs ou des composants apparentés ;
3. capacités **zero-shot / few-shot** pour certains modèles ;
4. **multimodalité** croissante : texte, image, audio et vidéo peuvent être combinés dans un même système.



5.4 Faut-il toujours utiliser un modèle fondation ?

Le contenu source termine par une comparaison pratique entre modèle fondation et modèle spécialisé. Cette comparaison ne donne pas un choix universel : elle montre surtout les critères à examiner avant de décider.

Critère	Modèle fondation	Modèle custom
Coût de développement	Souvent faible via API/-modèle existant	Plus élevé
Coût d'inférence	Peut être élevé	Peut être réduit par spécialisation
Latence	Peut être élevée	Peut être optimisée
Tâches larges	Généralisation large	Plus limité hors domaine
Tâche spécifique	Bonne si domaine couvert	Peut être excellente après spécialisation
Contrôle	Plus limité	Plus important
Confidentialité	Dépend du mode de déploiement	Peut être maîtrisée localement
Expertise requise	Faible à élevée selon usage	Souvent plus élevée

QUAND CHOISIR ?

— **Modèle fondation** : prototype rapide, tâches variées, réutilisation d'un modèle pré-entraîné.

— **Modèle custom** : fortes contraintes de latence ou de coût, données sensibles, tâche très spécialisée ou besoin de contrôle fin.

6 Enjeux responsables des modèles de fondation

L'échelle de ces modèles apporte des capacités nouvelles mais aussi des risques qui doivent être considérés dès la conception et le déploiement.

QUATRE ENJEUX À CONNAÎTRE

— **Biais et représentativité** : un modèle peut reproduire ou amplifier des biais présents dans ses données d'entraînement.

— **Droits d'auteur et provenance des données** : l'entraînement massif soulève des questions de licences, de consentement et d'attribution.

— **Coût énergétique et matériel** : pré-entraînement et inférence à grande échelle demandent des ressources de calcul importantes ; l'impact dépend toutefois du matériel, du mix énergétique, du taux d'utilisation et de la durée de vie du modèle.

— **Usages abusifs et traçabilité** : génération de contenus trompeurs, usurpation ou automatisation à grande échelle nécessitent des mécanismes de gouvernance et d'évaluation adaptés.

L'objectif de S14 n'est pas d'étudier toute la gouvernance de l'IA, mais de rappeler qu'un choix architectural ou une loi d'échelle n'est jamais uniquement une question de performance.

7 Références essentielles

Références

[1] Y. Lipman, R. T. Q. Chen, H. Ben-Hamu, M. Nickel, M. Le, *Flow Matching for Generative Modeling*, ICLR, 2023.

[2] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, B. Ommer, *High-Resolution Image Synthesis with Latent Diffusion Models*, CVPR, 2022.

[3] J. Kaplan et al., *Scaling Laws for Neural Language Models*, 2020.

[4] J. Hoffmann et al., *Training Compute-Optimal Large Language Models*, 2022.

[5] J. Ho, T. Salimans, *Classifier-Free Diffusion Guidance*, 2022.

8 Synthèse de la semaine 14 et transition vers S15

CE QU'IL FAUT RETENIR

1. L'**hybridation** combine des mécanismes complémentaires plutôt que de rechercher un modèle unique parfait.
2. Les **LDM** associent autoencodeur, diffusion latente et conditionnement pour réduire le coût tout en conservant un contrôle riche.
3. L'**appariement de flot** apprend par régression un champ de vecteurs qui transporte une distribution simple vers les données via une EDO.
4. Les **lois d'échelle** décrivent empiriquement comment la performance évolue avec paramètres, données et calcul.
5. Les **modèles de fondation** misent sur le pré-entraînement massif et la réutilisation, avec des compromis techniques, économiques et responsables.

TRANSITION VERS LA S15

La S14 clôt l'étude des grandes familles et de leurs hybridations modernes. En S15, l'objectif ne sera plus d'introduire une nouvelle architecture : vous devrez mobiliser les concepts des semaines précédentes pour analyser, comparer et présenter des projets génératifs selon différentes modalités, puis discuter leurs limites et leurs perspectives de recherche.

APERÇU DE LA S15

Projet → comparaison des choix → discussion critique → perspectives.