SEMAINE 15

Projet & synthèse

Projet final · comparaison des familles · discussion critique · perspectives

S15 — OBJECTIFS (CE QUE VOUS SAUREZ FAIRE À LA FIN)

1. Relier les principales familles de modèles génératifs étudiées de S1 à S14.
2. Comparer leurs compromis : qualité, diversité, vitesse, vraisemblance et stabilité.
3. Réutiliser un même socle expérimental pour conduire une comparaison cohérente.
4. Choisir, développer et défendre un projet final parmi plusieurs modalités génératives.
5. Analyser de manière critique les résultats, les échecs et les limites du modèle choisi.
6. Identifier les principales perspectives de recherche en modélisation générative.

MISE EN CONTEXTE — DE S1 À S15

Depuis S1, le cours a progressivement introduit les représentations, les fondements probabilistes, les modèles autorégressifs, les VAE, les flows, les EBM, les GAN, le score matching, la diffusion, les modèles hiérarchiques et les modèles hybrides. La S15 ne présente pas une nouvelle famille : elle vous demande de ***mobiliser l'ensemble de ces idées dans une démarche expérimentale cohérente et critique****.*

QUESTION CENTRALE DE LA SEMAINE

Comment mobiliser les modèles étudiés pour concevoir, comparer et défendre un projet génératif complet ?

LIEN AVEC LE PLAN DU COURS

La S15 correspond à la **synthèse finale du cours** : présentation de projets pour différentes modalités, discussion critique et perspectives de recherche. Le projet est introduit en S15 afin de mobiliser, dans une seule activité de synthèse, les concepts étudiés pendant les semaines précédentes.

1 Cadre du projet final de la S15

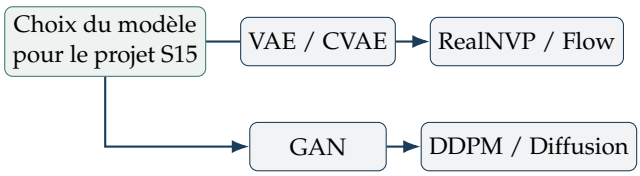
Le projet est introduit **uniquement dans cette dernière semaine**. Les semaines S1 à S14 ont construit les connaissances nécessaires ; la S15 vous demande maintenant de mobiliser ces acquis dans une expérience générative complète, reproductible et argumentée.

TERRAIN EXPÉRIMENTAL CONSEILLÉ POUR LA S15

Dataset principal : `MNIST` / `Fashion-MNIST`.
Pourquoi ? Ces jeux de données sont rapides à entraîner, stables et adaptés à une comparaison simple de plusieurs familles de modèles génératifs.

CADRE PRATIQUE PROPOSÉ — À ADAPTER PAR L'ÉQUIPE ENSEIGNANTE

— **Taille du groupe :** travail individuel ou en binôme (2 personnes maximum).
— **Ressources :** les projets sur MNIST/Fashion-MNIST doivent rester réalisables sur CPU ; un GPU est recommandé pour GAN/DDPM mais ne doit pas être indispensable à la compréhension du projet.
— **Soutenance :** 10 minutes de présentation suivies d'environ 3 minutes de questions.
— **Projet hors liste :** possible s'il reste dans la portée du cours, avec une question scientifique claire et validation préalable de la personne enseignante.
— **Principe de faisabilité :** privilégier un protocole réduit et reproductible plutôt qu'un entraînement long sur un grand dataset.



Chaque option correspond à une question scientifique différente : contrôle latent, vraisemblance exacte, stabilité antagoniste ou génération progressive.

1.1 Structure conseillée du projet S15

```
projet-s15/
|-- data/                  # donnees utilisees pour le projet
|-- model.py               # modele choisi
|-- train.py               # entrainement
|-- evaluate.py            # metriques et evaluation
|-- figures/               # visualisations et generations
|-- notebook.ipynb         # experience reproductible
‘-- rapport.pdf            # analyse finale
```

1.2 Interface minimale conseillée

L’objectif est de garder une organisation simple : une fonction de coût pour entraîner le modèle et une procédure d’échantillonnage pour produire des données.

DU CONCEPT AU CODE — INTERFACE MINIMALE DU PROJET S15

```python
class ModeleGeneratif:
    def loss(self, batch): ...
    def sample(self, n): ...

loss = model.loss(batch)
samples = model.sample(64)
```

À observer : ces deux opérations suffisent pour structurer l’entraînement et l’évaluation du projet final sans imposer une infrastructure complexe.

CE QUE LE PROJET DOIT PERMETTRE DE MONTRER

À la fin de la S15, votre expérience doit rendre visibles quatre éléments : **la méthode choisie**, **la qualité des générations**, **au moins une mesure ou comparaison**, et **une analyse critique des limites observées**.

2 S15 : projet de synthèse — choix parmi quatre

En S15, vous choisissez **un** projet parmi les quatre suivants et vous le développez comme activité de synthèse finale. Le projet compte pour une part significative de la note finale.

PROJET 1 — CVAE CONTRÔLÉ

Objectif : améliorer le CVAE de S7 pour générer des chiffres avec contrôle fin.
Extensions possibles : interpolation entre deux chiffres ; classifieur pour mesurer la contrôlabilité ; déambulation latente pour visualiser des attributs désintriqués.
Livrables : notebook commenté + rapport 3 pages + grille d’images + analyse quantitative de la contrôlabilité.

PROJET 2 — REALNVP DU TOY 2D À MNIST

Objectif : étendre le RealNVP de S8 pour obtenir une vraisemblance réellement calculable.
Extensions possibles : comparer log-likelihood VAE (ELBO) vs Flow (exact) ; analyser transformations inverses et conditionnement du Jacobien ; échantillonner et visualiser.
Livrables : notebook commenté + rapport 3 pages + tableau comparatif des log-likelihoods + visualisations.

PROJET 3 — DCGAN STABLE + ABLATION STUDY

Objectif : stabiliser le DCGAN de S10 et analyser l'impact de ses composantes.
Extensions possibles : GAN standard vs WGAN-GP ; normalisation spectrale ; détection/visualisation du mode collapse par nearest neighbors.
Livrables : notebook commenté + rapport 3 pages + courbes de loss comparatives + analyse du mode collapse.

PROJET 4 — DDPM AMÉLIORÉ

Objectif : améliorer le DDPM de S12 avec des techniques modernes.
Extensions possibles : scheduler cosine vs linear ; classifier-free guidance simple ; DDIM pour échantillonnage accéléré.
Livrables : notebook commenté + rapport 3 pages + visualisation de l'effet du guidance + comparaison vitesse/qualité.

PROJET LIBRE

Un projet différent des quatre propositions peut être accepté s'il mobilise explicitement une famille étudiée en S1–S14, formule une question testable, reste compatible avec les ressources disponibles et prévoit une évaluation reproductible. La portée doit être validée avant l'implémentation.

COMMENT CHOISIR ?

Choisissez le projet dont la **question scientifique** vous intéresse le plus : contrôle latent (CVAE), vraisemblance exacte (RealNVP), stabilité antagoniste (GAN) ou génération progressive/accélération (DDPM). Le meilleur projet n'est pas celui qui utilise le modèle le plus complexe, mais celui dont la comparaison et l'analyse sont les plus propres.

3 Discussion critique : comparer les familles

Famille	Qualité	Diversité	Vitesse	Vraisemblance	Stabilité
Autorégressif	Bonne	Bonne	Lente	Exacte	Stable
VAE	Moyenne	Bonne	Rapide	ELBO	Stable
Flow	Bonne	Bonne	Rapide	Exacte	Stable
GAN	Excellente	Faible	Très rapide	Aucune	Instable
EBM	Moyenne	Moyenne	Lente	Intractable	Instable
Diffusion	Excellente	Excellente	Lente	ELBO	Stable
Hybrides	Excellente	Excellente	Modérée	ELBO	Stable

COMMENT LIRE CE TABLEAU ?

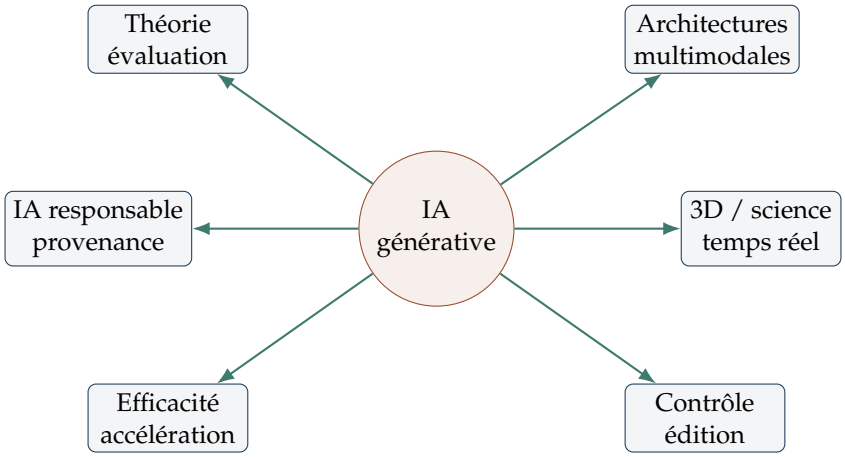
Ces qualificatifs sont des **repères pédagogiques**, pas des lois universelles. Les résultats dépendent du dataset, de l'architecture, de l'entraînement et de la métrique. Dans votre projet, remplacez autant que possible ces jugements qualitatifs par vos propres mesures et observations.

4 Perspectives de recherche

Cette dernière semaine ne vise pas à ouvrir un nouveau chapitre théorique, mais à montrer où les idées du cours restent actives en recherche. Les six directions ci-dessous doivent être lues comme des **questions ouvertes**, avec un exemple concret pour chacune.

1. **Accélération de l'échantillonnage.** Les modèles de diffusion restent coûteux à l'inférence. DDIM, distillation et consistency models cherchent à réduire fortement le nombre d'étapes ; les consistency models peuvent viser une génération en une ou quelques étapes [1].
2. **Contrôle et édition.** La génération conditionnelle cherche à suivre plus précisément une classe, un texte, une structure ou une image de référence tout en préservant diversité et fidélité. Les LDM utilisent notamment le conditionnement par attention croisée [2] et le guidage sans classificateur fournit un compromis qualité–diversité [3].
3. **Efficacité du calcul.** Réduire le coût d'entraînement et d'inférence reste central : compression latente, quantification, distillation, modèles plus petits et meilleurs solveurs sont autant de pistes. Les LDM illustrent directement le gain obtenu en déplaçant la diffusion dans un espace latent [2].
4. **Multimodalité.** Les systèmes modernes cherchent à relier texte, image, audio et vidéo au sein de représentations et de modèles génératifs communs. Le défi n'est pas seulement de générer chaque modalité, mais de préserver la cohérence entre elles.
5. **IA responsable et provenance.** Les questions de biais, données d'entraînement, droits d'auteur, deepfakes et traçabilité des contenus générés deviennent indissociables du déploiement. Le watermarking est un exemple de mécanisme étudié pour rendre certaines sorties détectables [4].
6. **Génération 3D, scientifique et temps réel.** Les mêmes principes génératifs sont étendus aux molécules, protéines, scènes 3D, simulation physique et applications interactives, avec de nouvelles contraintes géométriques et de coût.

> COMMENT LIRE CES PERSPECTIVES ?
>
> Une perspective de recherche n'est pas seulement une nouvelle architecture. Elle part généralement d'une **limite mesurable** d'un modèle existant : temps d'échantillonnage, coût, contrôle insuffisant, manque de robustesse, biais ou difficulté d'évaluation. Une bonne question de recherche transforme cette limite en hypothèse testable.



5 Conseils pour réussir le projet

1. **Cadrez d'abord la question** : définissez clairement ce que vous voulez mesurer ou comparer.
2. **Gardez une implémentation simple** : privilégiez un pipeline minimal, lisible et reproductible.
3. **Documentez vos choix** : architecture, hyperparamètres, fonction de coût, métriques.
4. **Visualisez systématiquement** : courbes, grilles d'images et exemples d'échec.

5. **Comparez** : mettez toujours votre approche en perspective avec au moins une baseline.
6. **Soyez critique** : analysez les échecs autant que les réussites.
7. **Si le modèle ne converge pas** : ne cachez pas l'échec. Vérifiez d'abord le pipeline sur un petit sous-ensemble, contrôlez les ordres de grandeur des pertes et gradients, simplifiez l'architecture, comparez à une baseline minimale et documentez précisément les essais. Un échec expliqué scientifiquement vaut mieux qu'un résultat non reproductible.

PLAN DE SECOURS EXPÉRIMENTAL

Si l'entraînement complet est trop coûteux ou instable, vous pouvez réduire le nombre d'époques, la taille du modèle ou le dataset, puis présenter une **ablation courte** ou une analyse diagnostique. Le projet est évalué sur la qualité du raisonnement expérimental, pas sur la production d'images spectaculaires.

DU CONCEPT AU CODE — UNE EXPÉRIENCE REPRODUCTIBLE

```
torch.manual_seed(42)
train(model, train_loader)
samples = model.sample(64)
metrics = evaluate(samples, test_loader)
```

À observer : quelques lignes suffisent pour imposer le même protocole : même seed, même jeu de test, même nombre d'échantillons et mêmes métriques.

RAPPEL IMPORTANT

Le projet doit rester suffisamment simple pour que l'analyse scientifique soit prioritaire sur la quantité de code.
Barème indicatif : 40% code fonctionnel, 30% analyse/visualisation, 30% rapport.

6 Déroulement du projet pendant la S15

Étape	Moment	Description
1. Choix	Début de S15	Choisir l'une des quatre propositions et formuler la question étudiée
2. Implémentation	S15	Obtenir une première version fonctionnelle
3. Évaluation	S15	Produire métriques, comparaisons et visualisations
4. Rendu / soutenance	Fin de S15	Notebook + rapport + visualisations + présentation de 10 minutes + environ 3 minutes de questions



Toutes les étapes du projet appartiennent à la semaine 15.

7 Quelques références pour prolonger les perspectives

Références

[1] Y. Song, P. Dhariwal, M. Chen, I. Sutskever, *Consistency Models*, ICML, 2023.

[2] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, B. Ommer, *High-Resolution Image Synthesis with Latent Diffusion Models*, CVPR, 2022.

[3] J. Ho, T. Salimans, *Classifier-Free Diffusion Guidance*, 2022.

[4] J. Kirchenbauer et al., *A Watermark for Large Language Models*, ICML, 2023.

8 Synthèse finale du cours

LA CARTE CONCEPTUELLE À RETENIR

— **S1–S4 : fondations.** Représentations → distributions → maximum de vraisemblance → variables latentes et inférence.

— **Autorégressifs / flows :** deux façons de conserver une vraisemblance calculable : factorisation séquentielle pour les premiers, transformations inversibles pour les seconds.

— **VAE :** introduit un latent probabiliste et l'ELBO ; ce même principe de compression latente réapparaît dans les **LDM** où la diffusion s'effectue dans l'espace d'un autoencodeur.

— **EBM ↔ score :** pour $p(x) \propto e^{-E(x)}$, le score vérifie $\nabla_x \log p(x) = -\nabla_x E(x)$; dériver la log-densité élimine la constante de normalisation.

— **Score ↔ diffusion :** le denoising score matching apprend des champs de score à plusieurs niveaux de bruit ; ces champs fournissent précisément la direction nécessaire au processus inverse des modèles de diffusion.

— **GAN / modèles implicites :** abandonnent le calcul direct de la vraisemblance et apprennent à rapprocher échantillons réels et générés via un discriminateur ou une discrepancy.

— **Diffusion ↔ Flow Matching :** les deux décrivent un transport d'une distribution simple vers les données ; la diffusion est naturellement liée à des dynamiques stochastiques/score-based, tandis que Flow Matching apprend directement un champ de vitesse pour une EDO.

— **Hiérarchiques / hybrides / foundation models :** organisent plusieurs échelles ou combinent plusieurs mécanismes pour améliorer efficacité, contrôle et réutilisation à grande échelle.

FIL ROUGE DES 14 SEMAINES

$$\boxed{\text{représenter}} \rightarrow \boxed{\text{modéliser une distribution}} \rightarrow \boxed{\text{apprendre}} \rightarrow \boxed{\text{échantillonner}} \rightarrow \boxed{\text{évaluer et contrôler}}$$

Chaque famille du cours propose une réponse différente à ces cinq questions.

CONCLUSION DU COURS

La compétence finale n'est pas de mémoriser une liste de modèles. Elle consiste à savoir poser les bonnes questions : quelle distribution est modélisée ? quelle loss est optimisée ? comment échantillonne-t-on ? que peut-on mesurer exactement ? quels compromis accepte-t-on ? Votre projet final doit rendre ces réponses visibles dans le code, les résultats et l'analyse.